



**universidad
de león**



**Escuela de Ingenierías
Industrial, Informática y Aeroespacial**

GRADO EN INGENIERÍA INFORMÁTICA

Trabajo de Fin de Grado

**Predicción de diagnósticos psiquiátricos mediante
modelos de aprendizaje automático.**

**Prediction of psychiatric diagnoses using machine
learning models**

Autor: Raúl Fernández Rodríguez

Tutor: Sergio Rubio Martín

Co-Tutor: Arturo Crespo Álvaro

(Junio, 2026)

UNIVERSIDAD DE LEÓN Escuela de Ingenierías Industrial, Informática y Aeroespacial GRADO EN INGENIERÍA INFORMÁTICA Trabajo de Fin de Grado
ALUMNO: Raúl Fernández Rodríguez
TUTORA: Sergio Rubio Martín
CO-TUTOR: Arturo Crespo Álvaro
TÍTULO: Predicción de diagnósticos psiquiátricos mediante modelos de aprendizaje automático
CONVOCATORIA: Julio, 2026
RESUMEN: La esquizofrenia es un trastorno psiquiátrico complejo con una gran heterogeneidad clínica, planteando el desafío crítico para el diagnóstico temprano y la personalización del tratamiento. Este trabajo de investigación presenta el estudio y desarrollo de un sistema experimental orientado al análisis relacional y la predicción de diagnósticos psiquiátricos mediante el uso de datos clínicos anonimizados de pacientes de la provincia de Castilla y León con esquizofrenia y sus distintas variantes. El objetivo principal de este proyecto es identificar patrones ocultos y correlaciones significativas entre síntomas, comorbilidades y evoluciones patológicas que puedan servir como guía a psiquiatras expertos. Para abordar este problema, se ha implementado una metodología híbrida que combina la ciencia de datos, técnicas de aprendizaje automático (<i>Machine Learning</i> y <i>Deep Learning</i>) y bases de datos orientadas a grafos. En primer lugar, se realizó la limpieza y acondicionamiento del <i>dataset</i> clínico inicial, compuesto por una lista anonimizada de 3134 registros de pacientes, garantizando la consistencia mediante la imputación de datos faltantes y normalización de los diagnósticos. Posteriormente, se construyó un grafo de conocimiento utilizando Neo4j, modelando de manera estructurada las relaciones multivariantes entre los pacientes y los diagnósticos. Este enfoque permitió realizar un análisis de comunidades y evaluar la cercanía topológica de los datos clínicos. En paralelo, se integraron modelos de lenguaje (<i>LLMs</i>) para el procesamiento de texto clínico y la búsqueda de relaciones semánticas entre diagnósticos. Asimismo, se entrenaron diferentes clasificadores para predecir la aparición de las distintas patologías. Se llevó a cabo un proceso de entrenamiento de varios modelos distintos, buscando demostrar mediante los resultados obtenidos la viabilidad del uso de los modelos como apoyo. Los modelos basados en <i>Machine Learning</i> tradicional mostraron un mayor rendimiento y mejores resultados en comparación con las aproximaciones de <i>Deep Learning</i> y <i>LLMs</i>. Asimismo, el estudio de comunidades en Neo4j reveló patrones de comorbilidad específicos que validan hipótesis clínicas previas, junto a la formación de comunidades de diagnósticos relacionados. Por último, se ha desarrollado una aplicación web funcional que integra un conversor de códigos ICD, mejorando la accesibilidad y la interpretabilidad de los resultados para el personal médico. Como conclusión, este proyecto demuestra el potencial de combinar grafos de conocimiento y aprendizaje automático en el ámbito de la salud mental, proporcionando una herramienta complementaria de apoyo a la decisión clínica de expertos y a la investigación psiquiátrica.
PALABRAS CLAVE: Esquizofrenia, Grafos de Conocimiento, Neo4j, Machine Learning, Deep Learning, Predicción Clínica, Códigos ICD.

UNIVERSIDAD DE LEÓN Escuela de Ingenierías Industrial, Informática y Aeroespacial GRADO EN INGENIERÍA INFORMÁTICA Trabajo de Fin de Grado
ALUMNO: Raúl Fernández Rodríguez
TUTOR: Sergio Rubio Martín
CO-TUTOR: Arturo Crespo Álvaro
TITLE: Prediction of psychiatric diagnoses using machine learning models
CONVOCATORIA: July, 2026
ABSTRACT: Schizophrenia is a complex psychiatric disorder characterized by high clinical heterogeneity, which poses a critical challenge for early diagnosis and personalized treatment. This research paper presents the study and development of an experimental system oriented towards relational analysis and the prediction of psychiatric diagnoses, utilizing anonymized clinical data from patients with schizophrenia and its various subtypes in the region of Castilla y León. The main objective of this project is to identify hidden patterns and significant correlations among symptoms, comorbidities, and pathological evolutions to serve as a guide for medical practitioners and expert psychiatrists. To address this problem, a hybrid methodology has been implemented, combining data science, machine learning, deep learning techniques, and graph-oriented databases. First, the cleaning and conditioning of the initial clinical dataset—comprising an anonymized list of 3,134 patient records—was performed, ensuring data consistency through missing data imputation and the normalization of diagnoses. Subsequently, a knowledge graph was constructed using Neo4J, structurally modeling the multivariate relationships between patients and diagnoses. This approach enabled community detection analysis and the evaluation of the topological proximity of the clinical data. In parallel, Large Language Models (LLMs) were integrated for clinical text processing and the identification of semantic relationships between diagnoses. Furthermore, different classifiers were trained to predict the onset of distinct pathologies. An optimization and evaluation process of various architectures was carried out to demonstrate the viability of these systems as support tools. Traditional Machine Learning models demonstrated higher performance and better results compared to Deep Learning approaches and LLMs. On the other hand, the community analysis in Neo4J revealed specific comorbidity patterns that validate previous clinical hypotheses, showcasing the formation of related diagnostic clusters. Lastly, a functional web application integrating an ICD code converter was developed, thereby improving the accessibility and interpretability of the results for medical personnel. In conclusion, this project demonstrates the potential of combining knowledge graphs and machine learning within the mental health domain, providing a complementary clinical decision support tool and advancing psychiatric research.
KEYWORDS: Schizophrenia, Knowledge Graphs, Neo4J, Machine Learning, Deep Learning, Clinical Prediction, ICD Codes.

Índice general

Índice de figuras	viii
Índice de tablas	x
Glosario y Acrónimos	xii
1. Introducción y objetivos	2
1.1. Contexto del problema	2
1.2. Hipótesis de trabajo	3
1.2.1. Hipótesis clínicas y relacionales (El enfoque de grafos)	3
1.2.2. Hipótesis tecnológicas y predictivas (El enfoque de IA)	3
1.2.3. Hipótesis epidemiológicas y de transferencia (El enfoque geográfico y de usuario)	4
1.3. Motivación	4
1.4. Objetivos del TFG	5
1.5. Marco legal, normativo y ético	7
1.5.1. Protección de datos y privacidad clínica	7
1.5.2. Regulación de la Inteligencia Artificial de la Unión Europea	7
1.5.3. Principios bioéticos y sesgo algorítmico	8
1.5.4. Regulación de la documentación clínica y autonomía del paciente	8
1.5.5. Marco de la investigación biomédica	8
1.5.6. Secreto profesional y consideraciones éticas en salud mental	9
1.5.7. Marco de Seguridad y Cumplimiento (ENS)	9
1.6. Estructura de la memoria	10
2. Estado del Arte	12
2.1. Encuadre Clínico y Desafíos de la Esquizofrenia	12
2.2. Medios de Detección y Monitoreo de la Esquizofrenia: El Puente hacia los Sistemas de Soporte	15

2.3.	Modelado de Redes y Grafos de Conocimiento: El Rol de Neo4j en la Inteligencia Artificial Clínica	17
2.4.	Algoritmos de Machine Learning y Deep Learning en Psiquiatría Computacional	19
2.4.1.	El Paradigma Tabular: Algoritmos basados en Ensamblados de Árboles	19
2.4.2.	El Paradigma Semántico: Arquitecturas de Atención Bidireccional (Transformers)	20
2.4.3.	Clasificación en Espacios Latentes Continuos (Perceptrón Multicapa)	21
2.5.	La Paradoja Multimodal y la Solución de Ingeniería Propuesta	22
2.5.1.	Gestión de Datos Sintéticos y el Desbalanceo en Psiquiatría	24
3.	Datos y preparación del dataset	25
3.1.	Fuente de datos	25
3.2.	Variables utilizadas	30
3.2.1.	Variables predictoras o características (<i>Features</i>)	30
3.2.2.	Variable objetivo (<i>Target</i>)	30
3.2.3.	Variables para el análisis estructural y geográfico	31
3.2.4.	Variables derivadas y de enriquecimiento semántico (<i>Feature Engineering</i>)	32
3.2.5.	Variables excluidas y justificación del descarte	33
3.3.	Limpieza y Preprocesamiento de Datos	34
3.3.1.	Anonimización y Seguridad de la Información	34
3.3.2.	Filtrado de Registros e Imputación de Valores Nulos	35
3.3.3.	Sanitización y Normalización Textual (NLP Prep)	35
3.3.4.	Unificación Semántica mediante Mapeo de Códigos	35
3.3.5.	Generalización y Normalización de Diagnóstica	36
3.4.	División del Conjunto de Datos: Entrenamiento, Validación y Test . .	36
3.4.1.	Prevención de Fuga de Datos (<i>Data Leakage</i>)	37
3.4.2.	Control de Aleatoriedad y Reproducibilidad	38
3.5.	Estratificación y Gestión del Desbalanceo de Datos	38
3.5.1.	El Rol de la Estratificación	39
3.5.2.	Estrategia Experimental: Gestión del Desbalanceo Mediante Tres Datasets	39
3.6.	Mapas y Frecuencias Geoespaciales	40
3.6.1.	Extracción y Agregación de Frecuencias Espaciales	41

3.6.2. Integración GeoJSON y Renderizado con Folium	41
4. Metodología	45
4.1. Baselines iniciales (Machine Learning vs Deep Learning)	46
4.1.1. Paradigma Tabular (ML Tradicional)	46
4.1.2. El Paradigma Semántico (Deep Learning con BERT)	46
4.2. Cross-validation y Estrategia de Evaluación	47
4.3. Modelos evaluados	48
4.3.1. Enfoque Tabular: Algoritmos de Ensamble y Árboles de Decisión	48
4.3.2. Enfoque Semántico: Modelos del Lenguaje Basados en Transformers (BERT)	49
4.4. Búsqueda de hiperparámetros y optimización de modelos	51
4.4.1. Impacto y justificación metodológica de Grid Search	51
4.4.2. Espacio de búsqueda e hiperparámetros evaluados	52
4.5. Propuesta final de experimentación	54
4.5.1. Configuración Definitiva del Ecosistema Tabular (Machine Learning)	55
4.5.2. Ajuste Fino (Fine-Tuning) del Ecosistema Semántico (Transformers)	56
4.6. Métricas empleadas y su justificación	57
5. Resultados	61
5.1. Evaluación y Comparativa de Modelos de Aprendizaje Profundo . . .	61
5.1.1. Análisis Cualitativo e Interpretación de Resultados	62
5.2. Evaluación y Comparativa de Modelos de Aprendizaje Tradicional . .	63
5.2.1. Análisis Cualitativo e Interpretación de Resultados: Modelos Tradicionales	65
5.3. Análisis de resultados	67
5.3.1. Hegemonía del Enfoque Combinado y de los Modelos de Lenguaje en el Espacio Original	67
5.3.2. El Colapso del Submuestreo (RUS) y la Resiliencia de la Entrada Combinada	68
5.3.3. La Reconstrucción con VAE y la Especialización de LightGBM	69
5.4. Justificación de la Propuesta Final y Transferencia Tecnológica . . .	69
5.5. Estudio de grafos	71
5.5.1. Análisis de Comunidades	71
5.5.2. Análisis de Centralidad y Comorbilidades	74
5.6. Estudio de mapas	75

5.6.1.	Segmentación Geográfica mediante K-Means	76
5.6.2.	Análisis de Dominancia Clínica	77
5.6.3.	Índice de Comorbilidad y Complejidad Asistencial	78
5.6.4.	Efecto de Proximidad y Sesgo de Detección	79
5.6.5.	Hallazgo Principal: El Contraste Urbano-Rural	79
5.7.	Conversión de códigos	80
6.	Aplicación desarrollada	83
6.1.	Ecosistema Tecnológico Integrado y Flujo de Datos	83
6.2.	Objetivo y Visualización	85
6.3.	Requisitos	86
6.3.1.	Requisitos Funcionales	86
6.3.2.	Requisitos No Funcionales	86
6.3.3.	Historias de Usuario	86
6.4.	Elementos de la interfaz y paneles de datos	86
6.5.	Navegación	90
6.6.	Accesibilidad de la aplicación	92
6.7.	Conversor de ICD	94
6.8.	Procesamiento masivo y automatización por lotes	96
6.9.	Visualizador de Mapas	98
7.	Planificación y Gestión del Proyecto	99
7.1.	Metodología de Desarrollo: Scrum Adaptado	99
7.2.	Desglose de Sprints y Asignación de Tareas	99
7.3.	Gestión y Mitigación de Riesgos	101
7.3.1.	Identificación de Riesgos	101
7.3.2.	Detalle de Riesgos y Acciones de Contención	101
7.3.3.	Justificación Técnica y Gestión del Entorno Virtual mediante Mamba	104
7.4.	Gestión de Configuración y Control de Versiones mediante GitHub . .	107
8.	Presupuesto	109
8.1.	Recursos hardware utilizados	109
8.2.	Software y librerías empleadas	110
8.3.	Estimación de costes	111
8.3.1.	Costes de personal (Mano de obra)	112
8.3.2.	Costes indirectos y gastos generales	113
8.3.3.	Resumen del presupuesto total	113

8.4. Viabilidad de implantación o escalado	114
9. Conclusiones y trabajo futuro	116
9.1. Principales aportaciones	116
9.2. Contextualización en el Estado del Arte	117
9.3. Limitaciones	118
9.4. Posibles mejoras futuras	119
Bibliografía	121
A. Anexos	127

Índice de figuras

3.1. Ejemplo de mapa coroplético generado para la provincia de León, mostrando la distribución de casos diagnosticados con trastornos del espectro esquizofrénico por código postal.	43
3.2. Ejemplo de mapa coroplético generado para la provincia de León, mostrando la frecuencia de casos diagnosticados con trastornos del espectro esquizofrénico por código postal.	43
3.3. Ejemplo de mapa coroplético generado para España, mostrando la frecuencia de casos diagnosticados con Esquizofrenia (cualquier tipo) por código postal.	44
4.1. Matriz de Confusión Binaria, donde se definen los conceptos de Verdaderos Positivos (TP), Falsos Positivos (FP), Falsos Negativos (FN) y Verdaderos Negativos (TN).	58
5.1. Grafico por columnas comparando los resultados de los modelos de aprendizaje profundo segun su F1-Score	64
5.2. Grafico por columnas comparando los resultados de los modelos de aprendizaje tradicional segun su F1-Score.	67
5.3. Curva ROC para el modelo BETO-cased en el dataset desbalanceado combinado	71
5.4. Curva ROC para el clasificador ROC en el dataset sintetico por codigos	72
5.5. Mapa de comunidades de diagnosticos general.	73
5.6. Mapa de comunidades de diagnosticos con mas 2 conexiones.	74
5.7. Mapa de centralidad de diagnosticos con mas de 50 apariciones.	76
5.8. Curva de Inercia para la Determinación del Número Óptimo de Clústeres.	77
5.9. Mapa de Dominancia Clínica de Códigos Postales.	78
5.10. Mapa de Comorbilidad Media por Código Postal.	79
5.11. Mapa de clústeres geográficos.	80

6.1. Mapa de sinergia tecnológica y flujo de información del proyecto. . . .	84
6.2. Diseño de la interfaz principal de la aplicación: panel de conversión de códigos e histórico de registros.	89
6.3. Diagrama de flujo de la aplicación web, mostrando la secuencia de interacción del usuario desde la selección de funcionalidad hasta la obtención de resultados.	93
6.4. Módulo del Conversor Individual: interfaz de búsqueda polivalente y panel de resultados de correspondencias ICD-9/ICD-10.	95
6.5. Módulo del Conversor por Lotes: interfaz de carga de archivos	97
6.6. Módulo del Conversor por Lotes: Panel de previsualización de datos cargados y selección de criterios de conversión.	97
6.7. Módulo del Conversor por Lotes: Resultados de la conversión seleccionada, con opción de descarga en formato CSV.	97
6.8. Módulo de Visualizador de Mapas.	98
A.1. Cronograma del Proyecto - Diagrama de Gantt	128

Índice de tablas

2.1. Comparativa técnica de algoritmos de IA aplicados a la predicción de resultados en esquizofrenia.	23
3.1. Distribución empírica y desbalanceo de la variable objetivo en el dataset de estudio.	38
4.1. Espacio de búsqueda de hiperparámetros para el ecosistema de Machine Learning tradicional.	53
4.2. Espacio de búsqueda de hiperparámetros para la optimización de modelos BERT.	54
4.3. Configuración óptima de hiperparámetros para el algoritmo XGBoost.	55
4.4. Configuración óptima de hiperparámetros para el algoritmo LightGBM.	56
4.5. Hiperparámetros óptimos de entrenamiento para los modelos Transformers en el escenario Original.	56
4.6. Hiperparámetros óptimos de entrenamiento para los modelos Transformers en el escenario con submuestreo (RUS).	57
4.7. Hiperparámetros de entrenamiento del clasificador MLP en el escenario expandido con VAE.	57
5.1. Métricas de rendimiento de los mejores modelos Transformers para el dataset original.	61
5.2. Métricas de rendimiento de los mejores modelos Transformers para el dataset undersampling.	61
5.3. Métricas de rendimiento de los mejores modelos Transformers para el dataset expandido con VAE.	62
5.4. Métricas de rendimiento de los mejores modelos tradicionales para el dataset original.	64
5.5. Métricas de rendimiento de los mejores modelos tradicionales para el dataset reducido.	64

5.6. Métricas de rendimiento de los mejores modelos tradicionales para el dataset expandido.	65
6.1. Catálogo de Requisitos Funcionales del sistema.	87
6.2. Catálogo de Requisitos No Funcionales del sistema.	88
6.3. Especificación de la Historia de Usuario HU-01: Mapeo CIE.	89
6.4. Especificación de la Historia de Usuario HU-02: Análisis Espacial. . .	90
6.5. Especificación de la Historia de Usuario HU-03: Exportación de Códigos Convertidos por Lotes.	91
7.1. Resumen de riesgos identificados en el ciclo de vida del proyecto. . . .	102
8.1. Especificaciones técnicas del equipamiento hardware en el ordenador de sobremesa.	109
8.2. Especificaciones técnicas del equipamiento hardware en el ordenador portátil.	110
8.3. Desglose de costes y amortización del hardware del proyecto.	110
8.4. Desglose de costes de licencias del software y librerías utilizadas. . . .	112
8.5. Desglose del coste de personal directo según roles metodológicos. . . .	113
8.6. Resumen consolidado del presupuesto general del TFG.	114

Glosario y Acrónimos

AUC-ROC (*Area Under the Receiver Operating Characteristic curve*): Métrica de rendimiento para evaluar la calidad de un modelo de clasificación a diferentes umbrales.

Deep Learning (DL) Aprendizaje Profundo. Subcampo del *Machine Learning* basado en redes neuronales artificiales de múltiples capas que permiten modelar relaciones complejas en los datos.

Recall Exhaustividad. Métrica de rendimiento que mide la proporción de verdaderos positivos correctamente identificados por un modelo.

ICD/ CIE (*International Classification of Diseases* / Clasificación Internacional de Enfermedades): Sistema de codificación de trastornos, enfermedades y signos clínicos publicado por la Organización Mundial de la Salud (OMS).

Large Language Model (LLM) Modelo de Lenguaje de Gran Tamaño. Algoritmo de inteligencia artificial basado en arquitecturas de *deep learning* (generalmente *Transformers*) entrenado con textos masivos para procesar y generar lenguaje natural.

Machine Learning (ML) Aprendizaje Automático. Rama de la inteligencia artificial enfocada en el desarrollo de algoritmos que permiten a los ordenadores aprender patrones, tomar decisiones y hacer predicciones a partir de datos sin ser programados explícitamente.

Neo4j Sistema de gestión de bases de datos orientado a grafos, desarrollado en Java, que almacena la información en forma de nodos, relaciones y propiedades.

Topología de Grafos Estudio de la estructura y disposición de los elementos (nodos y aristas) dentro de una red o grafo de conocimiento, analizando métricas de conectividad y centralidad.

Deep Learning (DL) Aprendizaje Profundo. Subcampo del *Machine Learning* basado en redes neuronales artificiales de múltiples capas (ocultas) que permiten extraer y modelar de forma automática características complejas y abstractas a partir de datos en bruto.

Comorbilidad Presencia de uno o más trastornos (o enfermedades) además de la enfermedad o trastorno primario en un mismo paciente.

ICD / CIE (*International Classification of Diseases* / Clasificación Internacional de Enfermedades): Sistema de codificación de trastornos, enfermedades y signos clínicos publicado por la Organización Mundial de la Salud (OMS).

Minería de Textos (Text Mining) Proceso de analizar colecciones de textos en lenguaje natural para extraer patrones, conceptos o información estructurada de alto valor que no es directamente accesible para un algoritmo tradicional.

F1-Score Métrica de rendimiento que combina la precisión y el recall en un solo valor, calculada como la media armónica de ambas.

Clinical Decision Support System (CDSS) Sistema de Soporte a la Decisión Clínica. Herramienta tecnológica de salud interactiva diseñada para asistir a los profesionales médicos en las tareas de toma de decisiones clínicas, utilizando datos de pacientes y bases de conocimiento para mejorar la calidad asistencial

Overfitting Sobreentrenamiento. Fenómeno en el que un modelo de aprendizaje automático se ajusta demasiado a los datos de entrenamiento, capturando ruido o patrones específicos que no generalizan bien a datos nuevos o no vistos.

Betweenness Centrality Centralidad de Intermediación. Métrica de teoría de grafos que mide la importancia de un nodo en función del número de veces que actúa como puente o intermediario en el camino más corto entre otros nodos.

Embedding Técnica de representación de datos en un espacio vectorial continuo, donde la proximidad entre vectores refleja la similitud semántica o relacional.

PLN Procesamiento del Lenguaje Natural. Subcampo de la inteligencia artificial que se ocupa de la interacción entre las computadoras y el lenguaje humano, permitiendo a las máquinas entender, interpretar y generar texto en lenguaje natural.

Escalabilidad Capacidad de un sistema de software o base de datos para manejar una cantidad creciente de trabajo o usuarios (por ejemplo, pasar de un entorno local a toda la red hospitalaria regional) sin perder rendimiento.

UX / UI (*User Experience / User Interface*) Conceptos del diseño de software enfocados en la experiencia del usuario (lo intuitivo y fluido que resulta el sistema) y la interfaz de usuario (el diseño visual de las pantallas y controles)

Open-Source Código Abierto. Modelo de desarrollo de software basado en la colaboración abierta, donde el código fuente se pone a disposición del público de forma gratuita, permitiendo que cualquiera lo inspeccione, modifique, reutilice y distribuya bajo ciertas licencias libres.

Redes Neuronales de Grafos (*Graph Neural Networks, GNNs*) Tipo de arquitectura de aprendizaje profundo diseñada para procesar datos estructurados de forma nativa como grafos, permitiendo realizar predicciones a nivel de nodos, relaciones o del grafo completo al capturar las dependencias complejas entre los elementos vecinos.

Umbral de PANSS Puntos de corte porcentuales en la Escala de los Síndromes Positivo y Negativo (como reducciones del 20 % o 30 %) para definir el éxito terapéutico en psicosis; su falta de estandarización genera heterogeneidad muestral en los modelos predictivos.

Black Box Caja Negra. Término utilizado para describir sistemas o modelos de inteligencia artificial cuya lógica interna es opaca o difícil de interpretar, lo que dificulta la comprensión de cómo se toman las decisiones o se generan las predicciones.

EHR Electronic Health Record (Historia Clínica Electrónica): Registro digitalizado, sistemático y estructurado de la información médica y sociodemográfica de un paciente a lo largo del tiempo.

Capítulo 1

Introducción y objetivos

1.1. Contexto del problema

La esquizofrenia es uno de los trastornos psiquiátricos más severos y complejos en el ámbito de la salud mental. Se caracteriza por una profunda heterogeneidad clínica que abarca desde síntomas positivos (como delirios y alucinaciones) hasta síntomas negativos (apatía, retraimiento social) y disfunciones cognitivas. Esta variabilidad no solo dificulta el diagnóstico temprano, sino que también complica el seguimiento a largo plazo, ya que los pacientes suelen presentar un alto índice de comorbilidades médicas y psiquiátricas.

Tradicionalmente, la práctica psiquiátrica se ha apoyado en manuales diagnósticos estandarizados (como el DSM o el CIE/ICD) y en la experiencia acumulada del facultativo. Sin embargo, los sistemas de salud pública actuales generan un volumen masivo de datos clínicos desestructurados o aislados de forma diaria. En el contexto de la comunidad autónoma de Castilla y León, la gestión de estos historiales plantea un desafío evidente: la información existe, pero se encuentra almacenada en formatos que impiden una visión relacional y holística del recorrido del paciente.

La dificultad intrínseca de manejar estos diagnósticos radica en que las patologías mentales raramente se presentan de forma aislada. Un paciente diagnosticado con un subtipo de esquizofrenia puede desarrollar de manera adyacente otros trastornos conductuales o somáticos. Identificar estas transiciones y patrones relacionales a gran escala es inasumible mediante el análisis clínico tradicional paciente a paciente.

Es en este escenario donde la intersección entre la psiquiatría y las tecnologías de la información cobra una relevancia crítica. La disponibilidad de un conjunto de datos

clínicos regionales abre la puerta a la aplicación de técnicas avanzadas de Ciencia de Datos. El reto actual no es la recolección de los datos, sino su explotación: transformar un listado plano de registros médicos en un ecosistema de conocimiento interconectado que permita descubrir comunidades de diagnósticos, tendencias epidemiológicas y, en última instancia, ofrecer herramientas tecnológicas de soporte que sirvan de guía en la toma de decisiones clínicas.

1.2. Hipótesis de trabajo

La génesis de este proyecto se fundamenta en la oportunidad de explotar un conjunto de datos clínicos regionales para extraer conocimiento de alto valor en el ámbito de la salud mental. Antes de iniciar la fase de desarrollo y experimentación, el trabajo se estructuró en torno a una serie de conjeturas iniciales. Estas hipótesis actúan como el hilo conductor de la planificación tecnológica, dividiéndose en tres vertientes esenciales:

1.2.1. Hipótesis clínicas y relacionales (El enfoque de grafos)

Coexistencia patológica estructurada: Se parte de la premisa de que las comorbilidades asociadas a los trastornos del espectro esquizofrénico (F20) no se distribuyen de manera aleatoria en la población de la provincia. Se hipotetiza que existen patrones relacionales ocultos y agrupaciones de síntomas que pueden ser descubiertos mediante el análisis topológico.

Eficacia del paradigma NoSQL: Se plantea que la migración de un modelo tabular tradicional a una base de datos orientada a grafos (Neo4j) no solo optimizará el almacenamiento, sino que permitirá usar métricas de centralidad y detección de comunidades para identificar patologías "núcleo" que actúan como puentes diagnósticos. Esto se justificara con las investigaciones analizadas en el estado del arte [1].

1.2.2. Hipótesis tecnológicas y predictivas (El enfoque de IA)

Superioridad de los modelos de lenguaje en texto libre: En el registro de historias clínicas, la jerga médica en texto libre suele ser caótica. Se establece como hipótesis que los modelos basados en transformadores (BERT), entrenados para la clasificación multiclase de diagnósticos finales, ofrecerán una comprensión

semántica muy superior y una mayor tolerancia al ruido textual en comparación con los algoritmos tradicionales basados en árboles de decisión (XGBoost y Random Forest).

Interoperabilidad latente: Se sospecha la existencia de una desconexión informática en el histórico de registros debido a la coexistencia de las codificaciones ICD-9 e ICD-10. Se plantea que es posible unificar esta brecha mediante un motor de traducción bidireccional automatizado, resolviendo un problema de compatibilidad sin necesidad de alterar los registros originales.

1.2.3. Hipótesis epidemiológicas y de transferencia (El enfoque geográfico y de usuario)

Heterogeneidad geográfica: Se asume que la prevalencia y la frecuencia de los diagnósticos del espectro esquizofrénico presentan variaciones espaciales significativas dentro de la provincia, las cuales pueden ser visibilizadas mediante cartografía digital para apoyar la toma de decisiones en salud pública.

Viabilidad de la transferencia tecnológica: Por último, se hipotetiza que la complejidad de los modelos predictivos de inteligencia artificial y de las consultas de grafos puede ser encapsulada con éxito en una interfaz web minimalista de una sola página, garantizando que una herramienta de alta densidad tecnológica sea adoptada de forma inmediata por el personal médico en su consulta diaria.

1.3. Motivación

La principal motivación de este trabajo radica en la oportunidad de transformar datos clínicos estáticos y tabulares en conocimiento médico dinámico e interpretable. El análisis tradicional de datos en salud mental ha dependido históricamente de bases de datos relacionales orientadas a tablas. Aunque eficaces para el almacenamiento básico, estas estructuras carecen de la flexibilidad necesaria para representar la naturaleza interconectada de los trastornos psiquiátricos, donde un único diagnóstico puede bifurcarse en múltiples variantes o asociarse de forma compleja con otras patologías.

En este sentido, la adopción de las bases de datos orientadas a grafos, específicamente mediante el entorno Neo4j, se presenta como una alternativa tecnológica idónea. Los grafos permiten mapear directamente la realidad clínica: los pacientes y sus diagnósticos se convierten en nodos, mientras que las relaciones

médicas actúan como aristas. Esta estructura no solo facilita una visualización intuitiva para el personal médico, sino que habilita el uso de algoritmos de teoría de grafos para la detección de comunidades, permitiendo descubrir agrupaciones de patologías que conviven en el dataset y que podrían pasar desapercibidas en un análisis estadístico convencional.

Por otro lado, la incorporación de técnicas de aprendizaje automático (*Machine Learning* y *Deep Learning*) responde a la necesidad de dotar al sistema de capacidades predictivas. En el ámbito de la esquizofrenia, anticipar la evolución de un cuadro clínico o clasificar correctamente sus variantes basándose en el historial del paciente puede abrir nuevas vías de investigación en la optimización de recursos sanitarios. Comparar enfoques tradicionales de *Machine Learning* frente a arquitecturas complejas de *Deep Learning* añade un valor experimental crítico a este proyecto, permitiendo evaluar el balance entre la precisión del modelo y su coste computacional.

Finalmente, la reciente emergencia de los Modelos de Lenguaje de Gran Tamaño (*LLMs*) ofrece un puente lingüístico inédito para la informática médica. Los historiales clínicos y las descripciones de los diagnósticos suelen estar cargados de texto natural complejo; motivar el uso de *LLMs* para procesar conceptualmente esta información y buscar relaciones semánticas responde al desafío actual de la minería de textos en salud. En conjunto, la convergencia de estas tres tecnologías sobre un dataset real de 3134 pacientes de Castilla y León constituye el motor de este proyecto, buscando demostrar que las herramientas de la ciencia de datos actual pueden integrarse de forma viable en entornos de soporte a la decisión clínica.

1.4. Objetivos del TFG

El objetivo general de este Trabajo de Fin de Grado consiste en el diseño, desarrollo y evaluación de un ecosistema tecnológico experimental que combine la analítica de grafos y el aprendizaje automático para el estudio relacional y la predicción de diagnósticos en pacientes con esquizofrenia de la comunidad de Castilla y León. Con ello, se busca transformar datos clínicos tabulares en herramientas de soporte que faciliten la identificación de patrones y comunidades de patologías asociadas.

Para alcanzar este objetivo general, se han establecido y completado los siguientes objetivos específicos:

- **Exploración y curación del conjunto de datos:** Analizar en profundidad el *dataset* clínico inicial, aplicando técnicas de preprocesamiento, imputación de valores faltantes y normalización de las variables diagnósticas para garantizar la consistencia y calidad de los datos de los 3134 pacientes.
- **Modelado relacional mediante Grafos de Conocimiento:** Diseñar e implementar una base de datos orientada a grafos en Neo4j para representar las conexiones multivariantes entre pacientes y patologías, permitiendo el estudio de la cercanía topológica y la detección de comunidades de diagnósticos relacionados.
- **Procesamiento semántico con Modelos de Lenguaje:** Integrar modelos de lenguaje (*LLMs*) para el análisis del texto clínico y la extracción de relaciones semánticas subyacentes entre las diferentes variantes de la esquizofrenia y sus comorbilidades.
- **Desarrollo y optimización de modelos predictivos:** Entrenar, afinar modelos de IA y evaluar diversas arquitecturas de clasificación basándose en técnicas de *Machine Learning* tradicional y *Deep Learning* para predecir la probabilidad de aparición o el tipo de patología psiquiátrica, comparando su rendimiento computacional y métricas de acierto, como puede ser el *AUC-ROC* o el *F1-Score*.
- **Diseño e integración de la interfaz del sistema:** Desarrollar una plataforma web funcional que articule de manera unificada los modelos predictivos, las visualizaciones del grafo y un conversor automatizado de códigos ICD, garantizando una transferencia tecnológica limpia desde el entorno de desarrollo hacia una interfaz accesible.

En última instancia, el verdadero objetivo final consiste en demostrar cómo la convergencia de la analítica relacional y el aprendizaje automático puede consolidarse en una herramienta viable, intuitiva y robusta de soporte a la decisión clínica (*Clinical Decision Support System, CDSS*). Con ello, se pretende proporcionar a los facultativos y expertos psiquiatras un marco analítico complementario que agilice la interpretación de historiales complejos, visibilice tendencias epidemiológicas regionales y actúe como un catalizador en la optimización y personalización del diagnóstico de la esquizofrenia.

1.5. Marco legal, normativo y ético

El desarrollo de soluciones tecnológicas aplicadas al ámbito de la salud mental conlleva una profunda responsabilidad legal y bioética. Dado que este proyecto interactúa con registros clínicos de pacientes diagnosticados con esquizofrenia y despliega modelos predictivos automatizados, su diseño y ejecución se han supeditado estrictamente al marco normativo vigente, estructurado en tres dimensiones esenciales:

1.5.1. Protección de datos y privacidad clínica

El tratamiento del conjunto de datos de los 3134 pacientes de Castilla y León se rige por el Reglamento (UE) 2016/679 sobre protección de datos personales (RGPD) [2] y por la Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD) [3]. Al clasificarse los datos de salud como «categorías especiales de datos» (Art. 9 del RGPD), se aplicó un protocolo estricto de anonimización irreversible previo al análisis. Esto garantiza la imposibilidad de reidentificar a los sujetos, protegiendo el secreto médico y los derechos fundamentales de los pacientes, salvaguardando simultáneamente la integridad estadística necesaria para el entrenamiento de los algoritmos.

1.5.2. Regulación de la Inteligencia Artificial de la Unión Europea

En consonancia con la normativa comunitaria actual, específicamente la Ley de Inteligencia Artificial de la Unión Europea (*EU AI Act*), los sistemas de software destinados a actuar como herramientas de soporte al diagnóstico o cribado médico entran dentro de la consideración de sistemas de alto riesgo o requieren estrictas salvaguardas de transparencia. Este proyecto se ha diseñado respetando rigurosamente los requisitos de dicha ley:

- **Trazabilidad y calidad del dato:** Garantizada mediante el proceso documentado de curación en el Capítulo 3.
- **Transparencia e interpretabilidad:** Mitigando el efecto «caja negra» mediante la capa visual de grafos en Neo4j, permitiendo al clínico comprender la lógica relacional del sistema.
- **Supervisión humana:** El sistema se define exclusivamente como una herramienta de apoyo (*CDSS*); la decisión diagnóstica final y la responsabilidad prescriptiva recaen de manera unívoca en el facultativo especialista y no en

el modelo predictivo de apoyo, evitando así cualquier riesgo de delegación indebida o automatización excesiva.

1.5.3. Principios bioéticos y sesgo algorítmico

Desde una perspectiva puramente ética, el proyecto se alinea con los principios fundamentales de la bioética moderna: beneficencia (buscar el máximo beneficio analítico para optimizar tratamientos) y no maleficencia (evitar diagnósticos erróneos mediante la validación exhaustiva de métricas). Un desafío ético crítico abordado en el diseño ha sido la prevención del *sesgo de automatización* (la tendencia humana a confiar ciegamente en los sistemas automatizados). Los modelos predictivos desarrollados mitigan este riesgo presentando las predicciones probabilísticas no como sentencias definitivas, sino como indicadores complementarios acompañados de la sintomatología relacional del paciente, fomentando el pensamiento crítico del experto psiquiatra.

1.5.4. Regulación de la documentación clínica y autonomía del paciente

Al trabajar con un *dataset* extraído de historiales médicos, el proyecto se alinea con la Ley 41/2002, de 14 de noviembre, básica reguladora de la autonomía del paciente y de derechos y obligaciones en materia de información y documentación clínica [4]. Esta ley establece que la historia clínica es un instrumento destinado fundamentalmente a garantizar una asistencia adecuada, pero permite su uso con fines de investigación científica. El proyecto cumple rigurosamente con el artículo 16 de dicha norma, el cual estipula que el acceso a la historia clínica con fines de investigación debe preservar el derecho del paciente a la confidencialidad, separando obligatoriamente los datos de identificación de los de carácter clínico-asistencial.

1.5.5. Marco de la investigación biomédica

Dado el carácter analítico y científico del estudio sobre la esquizofrenia, la actividad investigadora se encuadra en la Ley 14/2007, de 3 de julio, de Investigación Biomédica [5], específicamente en su Título V, que regula el tratamiento de datos de carácter personal en el ámbito sanitario. La normativa ampara el uso secundario de datos clínicos para investigación epidemiológica y de salud pública sin necesidad de requerir un nuevo consentimiento informado explícito, siempre y cuando los datos hayan sido

sometidos a una anonimización estricta por un equipo independiente, tal y como ocurre con las muestras del dataset nuestro utilizada en este trabajo.

Dado el carácter analítico y científico del estudio sobre la esquizofrenia, la actividad investigadora se encuadra en la Ley 14/2007, de 3 de julio, de Investigación Biomédica [5], específicamente en su Título V, que regula el tratamiento de datos de carácter personal en el ámbito sanitario. Esta normativa, siguiendo los criterios habituales de los Comités de Ética de la Investigación (CEI/CEIm) [6] y la Disposición Adicional 17.^a de la LOPDGDD [7], establece el uso secundario de datos clínicos para investigación epidemiológica sin necesidad de solicitar un nuevo consentimiento informado explícito, siempre que la muestra haya sido sometida a un proceso previo de anonimización irreversible por un equipo independiente, tal y como se ha garantizado en el conjunto de datos utilizado en este trabajo.

1.5.6. Secreto profesional y consideraciones éticas en salud mental

El diseño de la aplicación web respeta los principios éticos esenciales de la práctica médica y psicológica en España. En el ámbito de la psiquiatría, la confidencialidad es un factor crítico debido al estigma social que lamentablemente sigue asociado a la esquizofrenia. La herramienta desarrollada cumple con este requisito ético ya que tanto el conversor ICD como los gráficos relacionales funcionan exclusivamente con identificadores anónimos (códigos numéricos) en lugar de datos personales reales como nombres o números de historia clínica. De este modo, cualquier facultativo puede utilizar la aplicación en su consulta diaria con total seguridad, garantizando que la privacidad de los pacientes jamás se vea comprometida.

1.5.7. Marco de Seguridad y Cumplimiento (ENS)

Dada la naturaleza de los datos tratados, el proyecto ha sido diseñado bajo las directrices fundamentales del Esquema Nacional de Seguridad (ENS), de acuerdo con el Real Decreto 311/2022 [8]. Aunque el alcance de este Trabajo de Fin de Grado es de investigación, el sistema se ha estructurado siguiendo los principios de seguridad por diseño (security by design) para garantizar la protección de la confidencialidad, integridad y disponibilidad de la información:

- **Gestión de la Identidad:** Implementación de técnicas de anonimización que aseguran que el modelo de IA opera exclusivamente con datos anonimizados, cumpliendo con la necesidad de "principio de mínimo privilegio".

- **Trazabilidad:** El pipeline de preprocesamiento registra todas las transformaciones realizadas sobre el dataset, cumpliendo con la exigencia de auditabilidad del ENS.
- **Integridad del dato:** El uso de semillas aleatorias (`random_state`) y la reproducibilidad de los experimentos garantizan que los resultados no han sido manipulados, alineándose con el pilar de integridad del esquema.

Este enfoque asegura que cualquier futura escalada de este proyecto hacia un entorno de producción hospitalario real cuente con una base arquitectónica preparada para la certificación formal.

1.6. Estructura de la memoria

Para facilitar la lectura y el seguimiento detallado de la investigación realizada, esta memoria se encuentra organizada en ocho capítulos estructurados de la siguiente manera:

El **Capítulo 2 (Estado del arte)** ofrece una revisión de la literatura científica en torno a la esquizofrenia y el análisis de datos clínicos, identificando los métodos computacionales utilizados habitualmente y las limitaciones de los enfoques previos.

El **Capítulo 3 (Datos y preparación del dataset)** detalla el origen de los 3134 registros de la comunidad de Castilla y León, describiendo exhaustivamente el proceso de curación, imputación de datos faltantes y el modelado inicial en la base de datos orientada a grafos Neo4j.

A continuación, el **Capítulo 4 (Metodología)** desglosa el diseño experimental del proyecto, justificando la selección de las métricas, las técnicas de validación cruzada y los algoritmos de *Machine Learning*, *Deep Learning* y modelos de lenguaje evaluados.

Los resultados empíricos derivados de dicha experimentación, junto con la comparativa de rendimiento entre las distintas arquitecturas y el análisis de comunidades, se exponen y discuten en el **Capítulo 5 (Resultados)**.

Por su parte, el **Capítulo 6 (Aplicación desarrollada)** describe la arquitectura de la plataforma web funcional implementada, sus interfaces de visualización y el módulo conversor de códigos ICD.

El **Capítulo 7 (Planificación y gestión de proyecto)** expone la organización temporal del proyecto basada en la metodología ágil (*Scrum* adaptado), detallando el

desglose de los *Sprints* y sus objetivos y el análisis sistemático de los riesgos técnicos y operativos junto con sus correspondientes planes de mitigación.

Ademas, el **Capítulo 8 (Presupuesto)** analiza la viabilidad económica del proyecto a través de la estimación de costes de *hardware*, *software* y horas de ingeniería.

Finalmente, el **Capítulo 9 (Conclusiones y trabajo futuro)**, donde se sintetizan las principales aportaciones del estudio, sus limitaciones actuales y las líneas de desarrollo que quedan abiertas para próximas investigaciones.

Capítulo 2

Estado del Arte

2.1. Encuadre Clínico y Desafíos de la Esquizofrenia

La esquizofrenia se define como un trastorno psiquiátrico crónico, complejo, multifactorial y altamente heterogéneo que altera profundamente la capacidad de un individuo para pensar, sentir y comportarse con claridad [9, 10]. A nivel sintomatológico, la literatura clínica divide sus manifestaciones en dos grandes categorías de signos: los **síntomas positivos**, caracterizados por la presencia de delirios (creencias fijas e erróneas), alucinaciones auditivas o visuales, paranoia y un pensamiento o lenguaje gravemente desorganizado; y los **síntomas negativos**, que merman la iniciativa y expresión emocional del paciente a través del aplanamiento afectivo, la alogia y la abulia [10, 11].

Desde una perspectiva fisiopatológica y neurobiológica, las investigaciones de las últimas décadas han consolidado la concepción de la esquizofrenia como un **trastorno de desconexión** (*dysconnectivity*), caracterizado por una conectividad alterada entre las regiones cerebrales frontal, talámica y cerebelosa, con especial afectación y daño neuronal en el córtex prefrontal y el hipocampo [10, 11]. Epidemiológicamente, el trastorno presenta una prevalencia global relativamente baja, estimada en torno al 0,32 % [9]. No obstante, se posiciona de manera consistente entre las diez causas principales de discapacidad a nivel mundial, generando una severa disfunción funcional y un profundo sufrimiento subjetivo tanto en los pacientes como en sus entornos de apoyo familiar [9]. La aparición del trastorno suele situarse a finales de la adolescencia o en la adultez temprana, documentándose de manera consistente que los hombres experimentan un pico de incidencia aproximadamente una década antes que las mujeres [10]. Asimismo, un hallazgo desconcertante pero robustamente replicado es

el ligero exceso de nacimientos de personas con esquizofrenia durante los meses fríos de invierno, lo que sugiere la influencia de factores ambientales estacionales (como infecciones virales gestacionales o complicaciones en el parto) que inducen daños tempranos en el desarrollo neural del feto o neonato [10].

Evolución Temporal, Deterioro Cognitivo y cronicidad

Uno de los mayores desafíos de la esquizofrenia radica en su curso variable y frecuentemente deteriorante [11]. La literatura científica indica que aproximadamente el 80 % de los pacientes experimenta un curso clínico deteriorante de la enfermedad, de los cuales un 20 % no logra alcanzar una remisión completa de los síntomas [11]. Las recaídas y exacerbaciones de brotes psicóticos son comunes y recurrentes, estimándose que hasta el 80 % de los pacientes sufre al menos una recaída dentro de los primeros 10 años posteriores al episodio inicial [9]. Cada recaída se asocia directamente con un aumento de la resistencia farmacológica y una degradación acumulativa de las funciones cognitivas y sociales [9, 11].

La degradación cognitiva es, de hecho, una característica nuclear y definitoria de la enfermedad, y no un mero efecto secundario de la psicosis [11]. El deterioro neurocognitivo abarca deficiencias progresivas en:

- **La velocidad psicomotora y la atención:** Donde los pacientes muestran dificultades para mantener la concentración a medida que aumenta la complejidad de las tareas [11].
- **La memoria episódica:** Registrándose fallas severas para codificar, organizar y recuperar información contextual, mientras que la memoria semántica se ve comparativamente menos afectada [11].
- **Las funciones ejecutivas:** Lo que limita la capacidad de conceptualización, planificación, flexibilidad cognitiva y resolución de problemas complejos [11].

Investigaciones recientes sugieren que el declive cognitivo comienza a manifestarse sustancialmente antes de la aparición del primer episodio psicótico activo [12]. Identificar este declive temprano durante el desarrollo infanto-juvenil se ha convertido en un marcador y precursor fundamental para el diseño de intervenciones preventivas orientadas a detener la alteración de la trayectoria cognitiva antes de la consolidación de la psicosis [12].

Limitaciones del Abordaje Tradicional y el Rol de los Sistemas CAD/CDSS

El tratamiento estándar de la esquizofrenia se fundamenta en un enfoque biopsicosocial que combina la terapia psicológica con la farmacoterapia antipsicótica [11]. Sin embargo, la respuesta terapéutica es extremadamente heterogénea [9]. Aproximadamente el 23,6 % de los pacientes presenta una respuesta inadecuada al tratamiento inicial, y la resistencia al tratamiento afecta a casi un tercio de la población clínica total [9]. Además, los efectos adversos de los fármacos a menudo provocan la interrupción prematura de pautas de medicación que previamente resultaban eficaces [9].

Históricamente, la selección del tratamiento y el diagnóstico de transición han dependido exclusivamente de la pericia clínica del facultativo, de guías diagnósticas generalistas y de un proceso clínico de “ensayo y error” [9]. Este modelo de actuación comporta dos limitaciones críticas detectadas en el estado del arte:

1. **Retraso Diagnóstico Severo:** La confirmación diagnóstica definitiva de la esquizofrenia suele retrasarse varios años desde la aparición de los primeros síntomas prodrómicos, lo que dilata el inicio de tratamientos diana específicos e incrementa la duración de la psicosis no tratada (DUP), ensombreciendo el pronóstico a largo plazo [13].
2. **Falta de Explicabilidad y Personalización:** Las herramientas estadísticas tradicionales son incapaces de correlacionar de manera integral el historial longitudinal de comorbilidades físicas y conductuales secundarias del paciente con su riesgo individual de transición diagnóstica o de recaída [9, 13].

Ante estas deficiencias, la Inteligencia Artificial (IA) y el desarrollo de sistemas de Diagnóstico Asistido por Computadora (CAD), enmarcados como Sistemas de Soporte a la Decisión Clínica (CDSS), emergen como soluciones tecnológicas capaces de mitigar el retraso diagnóstico [13]. Mediante el procesamiento de grandes volúmenes de datos estructurados e historias clínicas electrónicas (EHR), junto a los informes psiquiátricos, los modelos de aprendizaje automático y procesamiento de lenguaje natural son capaces de extraer entidades semánticas y mapear patrones complejos de comorbilidad, permitiendo predecir la progresión diagnóstica hacia la esquizofrenia y guiar de manera personalizada la toma de decisiones clínicas [9, 13].

2.2. Medios de Detección y Monitoreo de la Esquizofrenia: El Puente hacia los Sistemas de Soporte

El seguimiento evolutivo de la esquizofrenia ha dependido tradicionalmente de evaluaciones psicométricas intermitentes aplicadas en la consulta clínica [9]. Entre los instrumentos diagnósticos y de monitorización más extendidos se encuentran la Escala de los Síndromes Positivo y Negativo (*Positive and Negative Syndrome Scale*, PANSS) [14] y la Escala de Valoración Psiquiátrica Breve (*Brief Psychiatric Rating Scale*, BPRS) [15]. Si bien estas escalas son indispensables para cuantificar la gravedad de síntomas como la desorganización conceptual o el enlentecimiento motor [15], presentan limitaciones metodológicas notables: son intrínsecamente subjetivas, dependen de la introspección puntual del paciente y consumen un tiempo clínico considerable, lo que impide un seguimiento continuo y objetivo del paciente en su entorno cotidiano [9, 16].

Ante estas deficiencias, la psiquiatría computacional ha comenzado a explorar el uso de herramientas de monitoreo pasivo continuo. En este ámbito, la **actigrafía**, práctica de registro continuo de la actividad motora mediante acelerómetros de muñeca de nivel médico, se ha consolidado como un biomarcador digital conductual sumamente potente [17]. Al recopilar datos de movimiento minuto a minuto durante periodos prolongados, la actigrafía permite caracterizar de forma objetiva las perturbaciones del sueño, el ritmo circadiano y la agitación psicomotriz [17]. De hecho, investigaciones pioneras como las de Berle et al. [17] han demostrado que el registro actigráfico revela diferencias estadísticas significativas en los patrones de comportamiento de pacientes psiquiátricos. Mediante el cálculo de variables no paramétricas como la estabilidad interdiaria (IS) y la variabilidad intradiaria (IV), se demostró que los pacientes con esquizofrenia presentan un ciclo de actividad-descanso más regular y un patrón de comportamiento significativamente más estructurado que aquellos diagnosticados con depresión mayor, quienes muestran una actividad motora altamente dispersa e irregular [17].

A la vez, la caracterización de la desorganización cerebral ha avanzado notablemente mediante el análisis basado en grafos, el cual permite modelar la topología de las redes complejas a través de métricas como la eficiencia local, la centralidad de intermediación y el coeficiente de agrupamiento [18]. De manera complementaria y a bajo coste, el Procesamiento del Lenguaje Natural (NLP) y los Modelos de Lenguaje (LLMs) emergen como una vía prometedora para cuantificar

patrones lingüísticos sutiles en el discurso desorganizado, actuando como proxies de la actividad neuronal subyacente [18].

Esta extracción de características lingüísticas y prosódicas a partir del habla espontánea de los pacientes se erige como una vía no invasiva y de bajo coste extremadamente útil para cuantificar objetivamente la desorganización del pensamiento y predecir la conversión psicótica a doce meses de forma automatizada [18,19].

Por otra parte, la información más valiosa sobre la trayectoria de un paciente suele residir de forma desestructurada en la narrativa libre de las historias clínicas electrónicas (*Electronic Health Records*, EHR) [13]. Como señalan Hansen et al. [13], las notas clínicas redactadas por los facultativos contienen descripciones exhaustivas de síntomas emergentes, respuestas sutiles a tratamientos farmacológicos e interacciones interpersonales que las variables tabulares tradicionales omiten por completo.

La coexistencia de estos flujos de información longitudinal genera la denominada “paradoja de la sobrecarga de datos psiquiátricos”: un psiquiatra en su consulta diaria no puede procesar manualmente miles de puntos de datos de series temporales actigráficas ni sintetizar de forma eficiente años de narrativa clínica libre de texto desestructurado en un tiempo limitado de consulta [13]. Esta barrera operativa genera retrasos críticos en el ajuste del tratamiento farmacológico y en la detección temprana de recaídas psicóticas, elevando de forma directa el riesgo de cronicidad del paciente [13,16].

Es en esta brecha del estado del arte donde se fundamenta el diseño de los Sistemas de Soporte a la Decisión Clínica (*Clinical Decision Support Systems*, CDSS) y, específicamente, la investigación desarrollada en este proyecto. Para que las tecnologías de soporte clínico actúen como un verdadero puente operativo, no deben limitarse al entrenamiento aislado de algoritmos en un entorno de laboratorio. Deben configurarse como ecosistemas integrales capaces de:

1. **Automatizar la interoperabilidad semántica:** Permitiendo la traducción y mapeo estructurado e inmediato de códigos diagnósticos complejos (como la conversión bidireccional entre CIE-9 y CIE-10).
2. **Optimizar la analítica predictiva local:** Empleando modelos de aprendizaje automático eficientes que estimen probabilidades diagnósticas en milisegundos sin requerir costosas infraestructuras de GPU.

3. **Garantizar la explicabilidad clínica:** Traduciendo las predicciones de caja negra mediante la representación relacional en grafos de conocimiento (Neo4j), permitiendo al psiquiatra correlacionar visualmente los factores somáticos, conductuales y de apoyo social que influyen en la patología del paciente.

Este enfoque híbrido e integrador define la naturaleza experimental y el desarrollo de software plasmado en las siguientes secciones de esta memoria.

2.3. Modelado de Redes y Grafos de Conocimiento: El Rol de Neo4j en la Inteligencia Artificial Clínica

La representación de entidades biomédicas y sus dependencias relacionales mediante estructuras de red constituye una de las metodologías de vanguardia más robustas en la medicina de precisión contemporánea [20]. La medicina de redes demuestra que las patologías humanas raramente son consecuencia de la perturbación aislada de un único gen o síntoma; por el contrario, representan fallos sistémicos distribuidos a lo largo de un complejo mapa de conexiones e interdependencias funcionales [20]. En este marco, el modelado relacional de comorbilidades concurrentes mediante un *Phenotypic Disease Network* (PDN) permite cuantificar el ecosistema clínico completo, demostrando empíricamente que la trayectoria patológica de un paciente progresa preferentemente a través de los caminos y vecindades adyacentes de la red, y que la centralidad y conectividad de un diagnóstico en el grafo actúa como un potente indicador clínico correlacionado directamente con la severidad del cuadro y la tasa de mortalidad esperada [1].

No obstante, la explotación efectiva de estas trayectorias relacionales exige superar las limitaciones físicas de los sistemas de almacenamiento de información tradicionales [21]. La literatura científica en informática médica advierte que la mayoría de los sistemas de Historia Clínica Electrónica (EHR) se han estructurado sobre bases de datos relacionales tradicionales (RDBMS) [21]. Estas arquitecturas rígidas basadas en tablas SQL fracasan al procesar la naturaleza dinámica, altamente interconectada y desestructurada de las variables clínicas y de los dispositivos médicos [21]. Al verse forzadas a mapear dependencias complejas mediante el uso intensivo de claves foráneas y uniones múltiples (*JOINS*), las RDBMS incurren en un elevado volumen de datos redundantes, experimentan serias dificultades para gestionar actualizaciones

concurrentes en tiempo real y sufren una degradación crítica del rendimiento de cómputo.

Para solventar esta paradoja relacional, las bases de datos orientadas a grafos NoSQL, con la plataforma de código abierto **Neo4j** posicionada como el estándar de facto en la industria, representan la opción de ingeniería de software más solvente [21, 22]. A diferencia de los esquemas planos tabulares, Neo4j organiza la información directamente como nodos y relaciones enriquecidas con atributos en un espacio vectorial orientado a propiedades. Esta flexibilidad arquitectónica permite que las interacciones clínicas se traten como objetos de primera clase, facilitando que los pacientes, comorbilidades, alertas clínicas e históricos se conecten de forma natural y adaptativa, soportando de manera óptima flujos de monitorización asistencial en tiempo real e ingestas masivas de datos de forma robusta y tolerante a fallos [21, 22].

En la analítica de redes sanitarias, el algoritmo de **Louvain** para la detección de comunidades se consolida en la literatura como el método óptimo para maximizar la modularidad, permitiendo agrupar de forma iterativa los diagnósticos que poseen una densidad de conexión interna significativamente alta. Asimismo, la literatura convalida el uso de la centralidad de intermediación (*Betweenness Centrality*) y grado para identificar comorbilidades críticas que actúan como puentes o catalizadores epidemiológicos en el historial clínico [23].

La eficiencia operativa de Neo4j frente a la analítica compleja de datos se asienta sobre su motor de consultas de grafos **Cypher**. Investigaciones previas sobre el rendimiento computacional de Neo4j confirman que la plataforma solventa con éxito el colapso que penaliza a las RDBMS debido a que el motor realiza recorridos topológicos (*graph traversals*) a una velocidad constante que es independiente del volumen de datos total almacenado, garantizando un tiempo de respuesta de milisegundos en la recuperación de caminos y relaciones profundas de múltiples niveles [21].

Finalmente, la integración de Neo4j en la ciencia de datos psiquiátrica abre un canal de sinergia inédito para el entrenamiento de modelos predictivos de aprendizaje automático [23]. Investigaciones recientes en la detección de patrones de comportamiento complejos han demostrado que la estructura de grafos de Neo4j puede ser aprovechada directamente como un extractor de características topológicas continuas para clasificadores tradicionales [23]. Mediante el uso de , se han implementado métodos de incrustación de grafos para transformar la conectividad y topología multidimensional de la red en vectores continuos de baja dimensión [23]. Al combinar estas incrustaciones o embeddings topológicos de la red con conjuntos

de datos tradicionales, los clasificadores predictivos experimentan un incremento drástico y consistente en sus métricas de precisión general, sensibilidad, especificidad y *F1-Score* [23]. En consecuencia, esta sinergia híbrida demuestra que el modelado relacional en grafos no se limita a ser una capa visual pasiva, sino que constituye un preprocesamiento semántico y predictivo de altísimo valor que justifica el diseño e integración del ecosistema híbrido propuesto en este Trabajo de Fin de Grado.

2.4. Algoritmos de Machine Learning y Deep Learning en Psiquiatría Computacional

La selección del paradigma algorítmico óptimo para el diagnóstico asistido de la esquizofrenia constituye un desafío crítico en la literatura actual, existiendo una marcada bifurcación entre el aprendizaje automático tradicional (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*) [19, 24]. Tradicionalmente, los clasificadores convencionales como las Máquinas de Vectores de Soporte (SVM) han dominado el espectro predictivo clínico debido a su probada estabilidad e inmunidad al sobreajuste en conjuntos de datos de tamaño moderado [9, 19]. Sin embargo, la creciente complejidad de los registros clínicos y el procesamiento masivo de datos multiseñal han impulsado el desarrollo de técnicas más sofisticadas [9, 25].

2.4.1. El Paradigma Tabular: Algoritmos basados en Ensamblados de Árboles

Para el procesamiento de datos clínicos estructurados y matrices de comorbilidades (datos tabulares estructurados), la literatura científica convalida la hegemonía de las técnicas de particionamiento recursivo del espacio y ensamble de árboles de decisión frente a las arquitecturas de redes neuronales profundas, representando el estándar de oro metodológico [26]. Este comportamiento diferencial se fundamenta en las características matemáticas intrínsecas de los modelos basados en árboles:

- **Random Forest y el control de la varianza:** Al basarse en el promediado de múltiples árboles de decisión independientes entrenados con subconjuntos aleatorios de datos y variables (*bagging*), este algoritmo ofrece una resistencia extraordinaria al sobreajuste (*overfitting*), consolidándose como una línea base analítica de alta estabilidad frente a muestras clínicas con datos faltantes [19, 26].
- **XGBoost y la optimización del gradiente regularizado:** La implementación de *Gradient Boosting* en XGBoost resulta idónea para

matrices de codificación diagnóstica altamente dispersas y asimétricas [9, 19]. Al inyectar una penalización formal $L1$ y $L2$ en su función objetivo, XGBoost controla la complejidad del modelo, ponderando las interacciones complejas de comorbilidades secundarias sin colapsar ante variables ruidosas o redundantes [9, 26].

- **LightGBM y el crecimiento orientado a hojas (*leaf-wise*):** En escenarios de alta densidad informativa, la estrategia de división asimétrica de LightGBM le confiere una flexibilidad matemática muy superior para trazar fronteras de decisión discontinuas, optimizando sustancialmente la velocidad de convergencia y reduciendo el consumo de memoria en la CPU de terminales informáticos convencionales de consulta hospitalaria [9, 26].

Además, la adopción de LightGBM resulta especialmente idónea tras el proceso de balanceo sintético mediante Autoencoders Variacionales (VAE) [9]. Su estrategia de crecimiento de árboles guiada por hojas (*leaf-wise*) permite segmentar el espacio latente continuo y denso generado por el VAE con una precisión matemática muy superior a la división simétrica por niveles (*level-wise*) de otros algoritmos tradicionales, reduciendo la latencia de inferencia a milisegundos en la CPU convencional de un terminal de consulta hospitalaria real [9].

2.4.2. El Paradigma Semántico: Arquitecturas de Atención Bidireccional (Transformers)

Para la explotación de la narrativa clínica desestructurada y las descripciones lingüísticas libres de los informes psiquiátricos, los algoritmos tradicionales de aprendizaje automático resultan insuficientes al ignorar las dependencias conceptuales de largo alcance y la polisemia clínica [25, 27]. En este ámbito, las redes neuronales de aprendizaje profundo basadas en la arquitectura de *Transformers* y mecanismos de auto-atención bidireccional (**BERT**) representan el estándar de oro en procesamiento del lenguaje natural (NLP) médico [27, 28].

La literatura en informática médica destaca que el preentrenamiento monolingüe en el idioma nativo de la práctica clínica, como el modelo **BETO** (`dccuchile/bert-base-spanish-wwm`), captura con una precisión infinitamente superior las sutilezas sintácticas, acrónimos de escalas psiquiátricas y la jerga médica local en español en comparación con los vocabularios dispersos de los modelos multilingües generalistas [27, 28]. El ajuste fino (*fine-tuning*) de estas capas de atención permite proyectar el discurso libre del informe médico en un espacio vectorial continuo (*embeddings*)

donde la cercanía geométrica correlaciona directamente con la similitud diagnóstica, capturando patrones semánticos ocultos inaccesibles para el análisis estadístico convencional [27].

La elección específica de la arquitectura **BETO** (`dccuchile/bert-base-spanish-wwm-cased`) como modelo lingüístico principal de este estudio se fundamenta en la superioridad de los modelos monolíticos nativos frente a los multilingües generalistas [27, 28]:

1. **Efecto del Whole Word Masking (WWM):** Al enmascarar palabras completas durante el preentrenamiento (en lugar de sub-tokens o caracteres aislados), BETO aprende las relaciones de concordancia de género, número y terminología compleja de la jerga psiquiátrica en castellano con una cohesión semántica óptima [28].
2. **Preservación de la capitalización (Cased):** En el registro clínico hospitalario manual, el uso de mayúsculas es crítico para identificar acrónimos médicos (e.g., PANSS, BPRS), siglas de escalas de gravedad o la codificación de variantes diagnósticas del espectro esquizofrénico. La evaluación empírica confirma que la variante *cased* de BETO captura y retiene este valor semántico diferenciador frente a las variantes *uncased* [27].

2.4.3. Clasificación en Espacios Latentes Continuos (Perceptrón Multicapa)

Un puente metodológico crítico entre ambos paradigmas surge al abordar técnicas de balanceo sintético mediante Autoencoders Variacionales (VAE) [9]. Dado que la red generativa del VAE proyecta y reconstruye las comorbilidades de los pacientes directamente en un espacio latente continuo y denso de 768 dimensiones, el uso de tokenizadores y modelos lingüísticos BERT estándar resulta físicamente incompatible al no disponer de una secuencia textual lineal de entrada [9, 28].

Para resolver esta limitación de diseño de software, el estado del arte dicta desacoplar la capa de clasificación textual y delegar el aprendizaje predictivo en una red neuronal *feed-forward* profunda de tipo **Perceptrón Multicapa (MLP)** [9, 29]. El clasificador MLP está diseñado para ingestar y procesar vectores numéricos continuos multidimensionales directamente, mapeando de forma óptima las variables latentes sintéticas generadas por el VAE mediante capas lineales densas y regularización de descarte para estimar la probabilidad final del subtipo de esquizofrenia de forma local y libre de sesgos predictivos [9, 29].

La Tabla 2.1 sintetiza las propiedades técnicas de las principales familias algorítmicas evaluadas en la literatura médica.

A partir de este marco metodológico de referencia, y dada la naturaleza dual del conjunto de datos del presente estudio (compuesto tanto por códigos diagnósticos normativos como por descripciones en texto libre), se justifican a continuación las decisiones arquitectónicas adoptadas para cada una de las modalidades de datos procesadas.

2.5. La Paradoja Multimodal y la Solución de Ingeniería Propuesta

Un hallazgo crítico documentado en los meta-análisis de inteligencia artificial aplicada a la psiquiatría es la denominada **Paradoja Multimodal** [9]. A pesar de la presunción teórica de que fusionar fuentes de información heterogéneas (datos clínicos estructurados, texto libre, señales electrofisiológicas o neuroimagen) debería optimizar la precisión predictiva, los modelos multimodales reales suelen reportar rendimientos significativamente inferiores a las modalidades unimodales aisladas, registrando sensibilidades promedio de apenas el 63 % y especificidades del 65 % [9].

La literatura atribuye este colapso a dos factores: la amplificación del ruido estadístico intrínseco de cada señal durante las fases de normalización y la dificultad técnica para armonizar datos de naturalezas físicas e informáticas incompatibles (e.g., concatenación directa de variables continuas de alta dimensionalidad con códigos discretos dispersos) [9, 19].

Para sortear esta limitación del estado del arte, este proyecto propone una **arquitectura híbrida desacoplada** [25]. En lugar de realizar una fusión temprana mediante la concatenación de variables en bruto, el sistema procesa cada flujo de información de forma independiente según su naturaleza óptima: el texto libre se codifica semánticamente mediante los embeddings densos de BETO [27], los datos tabulares se entrenan con clasificadores de ensamble (LightGBM) [9], y ambos vectores se integran de manera relacional y visual a través del Grafo de Conocimiento en Neo4j [25]. Asimismo, la clasificación de los datos vectoriales generados por el VAE se delega en un Perceptrón Multicapa (MLP) diseñado ad hoc, el cual procesa las 768 dimensiones continuas de los embeddings de forma óptima sin requerir la intervención del tokenizador lingüístico [9].

Algoritmo	Análisis Técnico y Metodológico
Random Forest	Fortalezas: Excelente control de la varianza mediante <i>bagging</i> [26]. Línea base de alta estabilidad frente a datos ruidosos o nulos [19]. Limitaciones: Menor capacidad para capturar dependencias de largo alcance o semántica compleja [27]. Procesamiento: Requiere imputación de faltantes y vectorización clásica del texto [19].
XGBoost	Fortalezas: Optimización del gradiente regularizado ($L1$ y $L2$) ante matrices dispersas (CIE-9/10) [9, 26]. Limitaciones: No diferenciable; dificulta su integración extremo a extremo [26]. Procesamiento: Control de colinealidad y preprocesamiento de nulos tabulares [19].
LightGBM	Fortalezas: Crecimiento por hojas de alta velocidad y bajo consumo de memoria [26]. Excelente para segmentar el espacio del VAE [9]. Limitaciones: Riesgo de sobreajuste en subconjuntos pequeños sin restricciones [26]. Procesamiento: Sensible a la calibración de hiperparámetros de profundidad [9].
Transformers (BETO)	Fortalezas: Comprensión contextual bidireccional de jerga psiquiátrica en castellano [27, 28]. Limitaciones: Alto coste computacional; requiere GPU no disponible en terminales locales [25]. Procesamiento: Tokenización nativa, normalización y optimizador AdamW con decaimiento de pesos [28].
Perceptrón Multicapa (MLP)	Fortalezas: Clasificación óptima de embeddings densos de 768 dimensiones del VAE [9]. Limitaciones: Opacidad algorítmica (caja negra) y riesgo de sobreajuste [25, 29]. Procesamiento: Exige regularización estricta por descarte y capas de tamaño decreciente [29].

Tabla 2.1: Comparativa técnica de algoritmos de IA aplicados a la predicción de resultados en esquizofrenia.

A este obstáculo metodológico de carácter matemático se suma una limitación práctica fundamental en el estado del arte: la brecha en la transferencia tecnológica y el desarrollo de herramientas de soporte real [25]. Una gran parte de las investigaciones analizadas en la psiquiatría computacional se desarrollan exclusivamente en entornos de laboratorio o mediante el uso de código aislado (como *scripts* de investigación de un solo uso). Raras veces este conocimiento teórico se transfiere a soluciones de software funcionales, accesibles y adaptadas a la rutina diaria de una consulta psiquiátrica [25]. Limitaciones como la falta de interfaces web interactivas o la ausencia de módulos utilitarios cotidianos, como un conversor automatizado entre sistemas de codificación como el ICD (CIE-9 y CIE-10), impiden que la ciencia de datos actúe como un verdadero Sistema de Soporte a la Decisión Clínica (CDSS) en el entorno hospitalario real [25]. Un ejemplo actual podrían ser los portales oficiales españoles (como eCIEMaps del Ministerio de Sanidad [30]) están diseñados exclusivamente para consultas individuales manuales, lo que impide su integración en flujos masivos de ciencia de datos

2.5.1. Gestión de Datos Sintéticos y el Desbalanceo en Psiquiatría

El desbalanceo de clases extremo es una barrera persistente en la psiquiatría computacional, provocado por la baja frecuencia epidemiológica de trastornos específicos frente a la alta prevalencia de otros (como la esquizofrenia paranoide), lleva a buscar soluciones.

La literatura de vanguardia propone el uso de **Autoencoders Variacionales (VAE)** [9]. Un VAE es una red neuronal generativa probabilística que aprende la distribución del espacio latente continuo de las características clínicas de las clases minoritarias, permitiendo generar vectores sintéticos de comorbilidades clínicamente plausibles y estables, en forma de embeddings de 768 dimensiones.

Capítulo 3

Datos y preparación del dataset

Este capítulo aborda el origen, la estructura y el ciclo de transformación técnica al que fueron sometidos los datos clínicos utilizados en este proyecto. Dado que el éxito de los modelos de aprendizaje automático y la fiabilidad de la analítica de grafos dependen directamente de la calidad del dato de entrada, las siguientes secciones detallan desde la naturaleza inicial de la fuente hasta los procesos críticos de curación y el posterior modelado relacional.

3.1. Fuente de datos

El conjunto de datos que constituye la base analítica y experimental de este Trabajo de Fin de Grado proviene de una recopilación de registros clínicos en el Complejo Asistencial Universitario de León (CAULE), y después esta recopilación fue entregada al grupo de investigación ALBA de la Universidad de León para su posterior estudio. El *dataset* original se presenta en un formato tabular Excel y consta de un total de 3134 registros independientes, donde cada fila representa una instancia clínica anonimizada asociada al ingreso de un paciente diagnosticado con esquizofrenia o alguna de sus variantes afines.

Con el fin de cumplir estrictamente con los marcos normativos vigentes en materia de protección de datos ,específicamente el Reglamento General de Protección de Datos (RGPD) y la Ley Orgánica de Protección de Datos y Garantía de los Derechos Digitales (LOPDGDD), la fuente de datos fue sometida a un proceso previo de anonimización irreversible realizado por un comité de ética del propio CAULE. De este modo, se eliminó cualquier identificador directo (como nombres, documentos de identidad o números de historia clínica real), garantizando el anonimato absoluto de

los sujetos sin alterar la validez estadística de las variables clínicas y epidemiológicas. El dataset esta conformado por ingresos desde el año 2007 al 2019.

Estructuralmente, el *dataset* se compone de un conjunto de 37 columnas que recogen diferentes dimensiones del perfil del paciente, mas unas 7 columnas adicionales que añaden información recopilatoria. Para facilitar su análisis técnico, estas variables o columnas se han categorizado en 5 bloques principales descritos en las siguientes figuras.

Información del Paciente

Esta categoría engloba datos relacionados con la edad, sexo y nacionalidad del paciente, que pueden ser relevantes para el análisis epidemiológico y la identificación de patrones demográficos asociados a la esquizofrenia

Variable	Nº Historia
Tipo de Dato	Alfanumérico
Descripción	Identificador único anonimizado del historial clínico del paciente.

Variable	Fecha Nacimiento
Tipo de Dato	Fecha
Descripción	Fecha de nacimiento del paciente.

Variable	Edad en años
Tipo de Dato	Entero
Descripción	Edad del paciente calculada en años en el momento del registro.

Variable	Sexo (Desc)
Tipo de Dato	Cadena (String)
Descripción	Descripción textual del sexo biológico del paciente.

Variable	País de Nacimiento
Tipo de Dato	Cadena (String)
Descripción	País de origen o nacimiento del individuo.

Variable	Provincia
Tipo de Dato	Cadena (String)
Descripción	Provincia de residencia asociada al registro.

Variable	Municipio Residencia (Cód)
Tipo de Dato	Alfanumérico
Descripción	Código numérico oficial del municipio de residencia.

Variable	Municipio Residencia (Des)
Tipo de Dato	Cadena (String)
Descripción	Nombre del municipio de residencia.

Variable	Código Postal
Tipo de Dato	Alfanumérico
Descripción	Código postal del domicilio del paciente.

Información del Ingreso

Esta categoría junta datos relacionados con la fecha de ingreso, duración de la estancia hospitalaria, motivo de ingreso y tipo de alta, que pueden ser útiles para analizar la evolución clínica y los factores asociados a la hospitalización

Variable	Fecha Ingreso
Tipo de Dato	Fecha
Descripción	Fecha en la que se produce el ingreso hospitalario.

Variable	Año
Tipo de Dato	Entero
Descripción	Año de registro del alta o del proceso clínico.

Variable	Fecha Alta
Tipo de Dato	Fecha
Descripción	Fecha de alta del paciente.

Variable	Servicio Alta (Código)
Tipo de Dato	Alfanumérico
Descripción	Código del servicio médico que gestiona el alta.

Variable	Sección Alta (Código)
Tipo de Dato	Alfanumérico
Descripción	Código de la sección específica encargada del alta.

Historial Clínico

Bloque central del dataset que recopila todo el historial medicos del paciente mediante los codigos medicos ICD-9 e ICD-10, incluyendo tanto trastornos mentales como enfermedades físicas.

Variable	Diag 01 Principal (cod)
Tipo de Dato	Cadena (String)
Descripción	Código identificador del diagnóstico principal que motivó el ingreso o atención.

Variable	Diag 02 al Diag 20 (cod)
Tipo de Dato	Cadena (String)
Descripción	Bloque secuencial de 19 variables opcionales que registran las comorbilidades secundarias del paciente según la complejidad de su caso.

Diagnóstico final

Nuestra metrica mas importante y la pieza central, información sobre el diagnóstico definitivo del paciente, que puede incluir el subtipo de esquizofrenia o cualquier otra condición diagnóstica relevante.

Variable	DIAG PSQ
Tipo de Dato	Cadena (String)
Descripción	Código del diagnóstico psiquiátrico de control definitivo propuesto por un especialista.

Recopilación de Datos

Categoría dedicada a la recopilación de los datos en distintos formatos para el enriquecimiento de la investigación.

Variable	Conjunto Dx
Tipo de Dato	Cadena (String)
Descripción	Agrupación de diagnósticos asociados al paciente en una única columna.

Variable	DIAG PSQ ICD-9
Tipo de Dato	Cadena (String)
Descripción	Código equivalente en la clasificación ICD-9 para la patología psiquiátrica principal.

Variable	DIAG PSQ Des. Español
Tipo de Dato	Cadena (String)
Descripción	Descripción literal en castellano del diagnóstico psiquiátrico principal.

Variable	DIAG PSQ Des. Inglés
Tipo de Dato	Cadena (String)
Descripción	Descripción literal en inglés del diagnóstico psiquiátrico principal.

Variable	Conjunto Dx ICD-9
Tipo de Dato	Cadena (String)
Descripción	Agrupación de los códigos equivalentes en ICD-9 para el historial clínico.

Variable	Conjunto Dx Des. Español
Tipo de Dato	Cadena (String)
Descripción	Agrupación de descripciones en español del historial clínico.

Variable	Conjunto Dx Des. Inglés
Tipo de Dato	Cadena (String)
Descripción	Agrupación de descripciones en inglés del historial clínico.

3.2. Variables utilizadas

3.2.1. Variables predictoras o características (*Features*)

El conjunto de variables de entrada seleccionadas para el entrenamiento y optimización de los modelos predictivos (XGBoost, Random Forest y arquitecturas basadas en BERT) se centra exclusivamente en la dimensión clínica del paciente. Se ha prescindido deliberadamente de factores administrativos para evitar sesgos informáticos, focalizando el aprendizaje del sistema en el historial de codificación diagnóstica.

Las características operativas que constituyen el vector de entrada del modelo se desglosan en dos componentes fundamentales:

- **Diagnóstico Principal (Diag 01 Principal (cod)):** Esta variable categórica representa la patología primaria o el motivo principal que desencadenó la atención médica o el ingreso hospitalario del individuo. Actúa como el anclaje semántico del perfil del paciente, aportando el peso estadístico base en las matrices de decisión de los algoritmos de aprendizaje supervisado.
- **Historial de Diagnósticos Secundarios (Diag 02 al Diag 20):** Este bloque, compuesto por 19 variables indexadas, encapsula el perfil pluripatológico del paciente. Clínicamente, representa las comorbilidades concomitantes, trastornos crónicos subyacentes o manifestaciones secundarias que presenta el sujeto de estudio de manera simultánea.

Desde el punto de vista del procesamiento de datos, la inclusión de este bloque de 20 variables en paralelo permite a los modelos de árboles de decisión evaluar interacciones complejas de características. El algoritmo no analiza el impacto de una patología de forma aislada, sino que es capaz de ponderar cómo la coexistencia de determinados diagnósticos secundarios altera drásticamente la probabilidad probabilística de las diferentes variantes del espectro esquizofrénico, maximizando la precisión del clasificador multiclase.

3.2.2. Variable objetivo (*Target*)

El eje central sobre el cual pivota la totalidad del estudio analítico y el entrenamiento de los algoritmos de Inteligencia Artificial es el diagnóstico psiquiátrico final, establecido empíricamente por el personal médico experto en el momento del alta.

Dentro del *dataset*, esta información se consolida principalmente en la variable DIAG PSQ (y sus proyecciones codificadas o semánticas, como DIAG PSQ ICD-9 y DIAG PSQ Descripción Español). En el paradigma del aprendizaje automático supervisado, esta columna asume el rol de variable dependiente o *Target*.

En la práctica, esta variable constituye la «verdad fundamental» (*ground truth*) que los modelos de clasificación (XGBoost, Random Forest y BERT) aprenden a inferir a partir del historial de diagnósticos del paciente. Al representar la confirmación clínica innegable de la patología psiquiátrica (con especial interés en los trastornos del espectro esquizofrénico), su exactitud es el pilar indiscutible que permite calcular, validar y justificar todas las métricas de rendimiento y precisión del proyecto.

3.2.3. Variables para el análisis estructural y geográfico

Para el desarrollo del módulo cartográfico y el estudio epidemiológico espacial, la selección de variables se vio condicionada por una fase previa de evaluación de la calidad del dato (*Data Quality Assessment*). Aunque el *dataset* original disponía de múltiples campos de localización geomorfológica —tales como País de Nacimiento, Provincia, Municipio Residencia (Cód) o Municipio Residencia (Des)—, el análisis de completitud reveló que estas variables sufrían de una alta tasa de valores nulos, registros incompletos o codificaciones imprecisas que imposibilitaban su uso directo.

Ante esta restricción metodológica, se determinó utilizar la variable Código Postal como el eje conductor exclusivo para el análisis geográfico, fundamentando esta decisión en dos criterios técnicos:

- **Integridad y completitud del registro:** A diferencia de los campos municipales o provinciales, la columna Código Postal se encontraba cumplimentada en la totalidad de los registros del histórico de pacientes (100 % de *completeness*), careciendo de ruido informático o fallas de formato. Esto garantizó la robustez de las consultas espaciales sin requerir técnicas artificiales de imputación de datos que pudiesen sesgar los resultados.
- **Resolución y granularidad espacial:** Desde la perspectiva analítica, la escala provincial resulta demasiado amplia y difusa para detectar patrones de prevalencia clínica significativos. El código postal, al actuar como una unidad de división administrativa micro-local, ofrece un nivel de granularidad óptimo. Esto permite mapear la distribución de los trastornos del espectro esquizofrénico a nivel de distritos sanitarios específicos y subzonas de la provincia, facilitando

la identificación de posibles focos o clústeres socio-ambientales de forma mucho más precisa.

3.2.4. Variables derivadas y de enriquecimiento semántico (*Feature Engineering*)

Durante la fase de preprocesamiento, se observó la necesidad de expandir la dimensionalidad del *dataset* original para flexibilizar la experimentación con los distintos modelos de aprendizaje automático. Por ello, se llevó a cabo un proceso de ingeniería de características que dio lugar a la creación de siete nuevas columnas.

El objetivo principal de estas variables derivadas es disponer del historial clínico y de la variable objetivo en múltiples formatos (códigos históricos, agrupaciones y lenguaje natural bilingüe). Esto permite evaluar el rendimiento de los algoritmos ante diferentes representaciones del mismo dato (por ejemplo, alimentando al modelo BERT con texto en inglés frente a texto en español).

Estas siete variables se dividen conceptualmente en dos bloques funcionales:

1. Enriquecimiento de la variable objetivo (Target):

- **DIAG PSQ ICD-9:** Representa la traducción inversa del diagnóstico psiquiátrico principal al estándar histórico ICD-9. Su función es mantener la trazabilidad con sistemas médicos antiguos (*legacy systems*).
- **DIAG PSQ Descripción Español:** Traducción del código a lenguaje natural en castellano. Es esencial para validar clínicamente los resultados sin requerir memorización de códigos por parte del usuario.
- **DIAG PSQ Descripción Inglés:** Traducción literal obtenida vía API externa. Resulta crítica para los modelos de procesamiento de lenguaje natural (NLP) avanzados, dado que arquitecturas como BERT presentan un mayor grado de madurez y precisión cuando procesan *embeddings* en lengua inglesa.

2. Agrupación y enriquecimiento del historial predictivo:

- **Conjunto Dx:** Es una variable de agregación que concatena los múltiples diagnósticos secundarios de un paciente en una única cadena estructurada. Facilita la inyección de datos tabulares en modelos que requieren una entrada de texto secuencial unificada.

- **Conjunto Dx ICD-9:** Mapeo relacional del conjunto anterior hacia la codificación ICD-9, garantizando la uniformidad del formato si se decide entrenar modelos exclusivamente con el estándar histórico.
- **Conjunto Dx Descripción Español y Conjunto Dx Descripción Inglés:** Transforman el vector de comorbilidades (códigos) en párrafos de texto descriptivo. Estas columnas son el insumo principal para probar la capacidad de atención y comprensión contextual de los modelos transformadores (LLMs) frente al uso de vectores numéricos tradicionales en árboles de decisión.

En conclusión, la generación de este bloque semántico no solo actúa como un recopilador de soporte documental, sino que proporciona el entorno de pruebas multimodal necesario para determinar empíricamente qué representación del conocimiento clínico maximiza la capacidad predictiva del sistema.

3.2.5. Variables excluidas y justificación del descarte

En todo proyecto de aprendizaje automático, la reducción selectiva de la dimensionalidad es un paso crítico para garantizar la robustez de los modelos. Mantener variables irrelevantes, redundantes o incompletas introduce ruido estadístico, aumenta innecesariamente el coste computacional y eleva el riesgo de sobreajuste (*overfitting*).

Tras una fase de filtrado analítico, se procedió a la exclusión definitiva de 12 variables del *dataset* original:

- **Variables de gestión administrativa (Servicio Alta (Código) y Sección Alta (Código)):** Estos campos describen la estructura logística e institucional del centro hospitalario en el momento del alta. Dado que reflejan flujos organizativos internos y no variables sintomatológicas o clínicas del sujeto, se omitieron para evitar que los algoritmos correlacionaran artificialmente una sección médica concreta con un diagnóstico psiquiátrico específico, previniendo así un sesgo operativo severo.
- **Variables temporales y cronológicas (Fecha Ingreso, Año y Fecha):** El diseño experimental de este estudio está planteado como una clasificación estática transversal, orientada a evaluar el perfil de comorbilidades concurrentes. Al no abordarse un análisis predictivo de series temporales, las fechas exactas aportaban una variabilidad excesiva (*high cardinality*) sin valor clínico para el entrenamiento de redes neuronales o árboles de decisión.

- **Variables demográficas generales (Fecha Nacimiento, Edad en años, Sexo (Desc) y País de Nacimiento):** Aunque estas variables poseen valor epidemiológico descriptivo, se constató que la firma diagnóstica contenida en el vector de las 20 columnas de codificación médica poseía un peso predictivo infinitamente superior. La inclusión de la edad o el sexo biológico introducía correlaciones espúreas en el clasificador multiclase, por lo que se prefirió aislar los modelos para que aprendieran exclusivamente de la semántica de las patologías.
- **Variables geográficas de baja calidad (Provincia, Municipio Residencia (Cód) y Municipio Residencia (Des)):** Tal y como se justificó en la sección anterior, el análisis de calidad detectó una tasa crítica de valores ausentes e inconsistencias en estos campos. El valor de estas variable ha sido eclipsado por la variable Código Postal, que se mantuvo como el único referente geográfico para el estudio espacial.

3.3. Limpieza y Preprocesamiento de Datos

Una vez definidas las variables de interés, se procedió a diseñar un pipeline de preprocesamiento y limpieza de datos empleando la librería Pandas en Python. El objetivo de esta fase es transformar un conjunto de registros administrativos crudos en una matriz de información limpia, homogénea y optimizada para los modelos de aprendizaje automático y la base de datos relacional de grafos.

El flujo de depuración implementado se divide en cuatro bloques secuenciales:

3.3.1. Anonimización y Seguridad de la Información

Dado que se trabaja con datos médicos de alta sensibilidad sujetos al Reglamento General de Protección de Datos (RGPD), el primer paso crítico consistió en verificar la completa anonimización de la muestra. Se eliminó cualquier columna que pudiera contener datos nominativos directos, transformando el identificador del paciente en el campo alfanumérico ciego Nº **Historia**. Este proceso garantiza que es matemáticamente imposible revertir la identidad del paciente, permitiendo trabajar en un entorno de desarrollo seguro.

3.3.2. Filtrado de Registros e Imputación de Valores Nulos

En lugar de recurrir a técnicas artificiales de imputación de datos (como la media o modas) que podrían alterar la realidad clínica de la muestra, se optó por una política de filtrado estricto basada en la calidad del dato:

- Se descartaron de forma automática aquellos registros que presentaban valores nulos en la variable objetivo (DIAG PSQ) o en el diagnóstico principal (Diag 01 Principal).
- Tras constatar la integridad absoluta del campo Código Postal (100 % de registros válidos), se eliminaron las filas remanentes con valores atípicos o ausentes en los campos de control geográfico secundarios.

3.3.3. Sanitización y Normalización Textual (NLP Prep)

Para preparar los campos de texto libre (las descripciones de los diagnósticos) de cara al entrenamiento del modelo basado en transformadores (BERT), se aplicó una función de limpieza lingüística estructurada:

- **Normalización de caja:** Conversión de todo el texto a minúsculas para evitar que el modelo diferencie una misma palabra por su posición en la frase.
- **Eliminación de caracteres especiales:** Supresión de signos de puntuación redundantes, dobles espacios en blanco y caracteres no alfanuméricos que introducen ruido en los *tokens*.
- **Corrección tipográfica base:** Homogeneización de términos recurrentes o abreviaturas médicas típicas del registro hospitalario manual.

3.3.4. Unificación Semántica mediante Mapeo de Códigos

El último hito del preprocesamiento consistió en resolver la brecha temporal entre las codificaciones ICD-9 e ICD-10 presentes en el histórico. Utilizando el motor del conversor desarrollado en este proyecto, se transformaron de forma masiva los códigos antiguos a sus equivalencias modernas estandarizadas. Este paso permitió unificar el criterio de comorbilidades en el bloque de las 20 columnas de diagnósticos, consolidando un *dataset* simétrico donde cada fila comparte exactamente el mismo espacio semántico y normativo internacional, rompiendo la brecha de interoperabilidad identificada en el estado del arte.

3.3.5. Generalización y Normalización de Diagnóstica

En el contexto del aprendizaje automático, un nivel excesivo de detalle en la codificación puede resultar contraproducente, provocando la fragmentación artificial de las muestras y la aparición de clases escasas sin casi representatividad estadística.

Con el objetivo de optimizar el espacio de características y consolidar la fuerza predictiva de la variable objetivo, se aplicó una regla de generalización y truncado de códigos. Tras realizar una inspección sobre las distintas variantes de diagnósticos psiquiátricos finales, se identificó el código F20.89 (*Otras esquizofrenias*) como el único registro en todo el histórico que presentaba esta especificación decimal o extra. Mediante esta transformación, las instancias etiquetadas bajo F20.89 fueron reasignadas y consolidadas de forma transparente dentro de la clase principal F20 (*Esquizofrenia*), evitando así la creación de una subcategoría marginal en los diagnósticos objetivo que carecía de relevancia clínica y estadística.

3.4. División del Conjunto de Datos: Entrenamiento, Validación y Test

Para garantizar la capacidad de generalización de los modelos predictivos y evaluar su rendimiento ante escenarios clínicos reales con pacientes no vistos previamente, se diseñó un protocolo riguroso de partición del conjunto de datos. En el ámbito del aprendizaje automático (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*), evaluar un modelo con los mismos datos con los que ha entrenado no solo puede favorecer un ajuste excesivo (*overfitting*), sino que además produce métricas artificialmente optimistas. En la práctica, esto ocurre porque las medidas obtenidas sobre los datos ya vistos no reflejan adecuadamente el comportamiento del modelo ante nuevos registros clínicos, y con un conjunto de test independiente muy probablemente su capacidad de generalización sería considerablemente menor.

Para mitigar este riesgo, el *dataset* depurado se fragmentó en tres subconjuntos independientes y disjuntos. Esta operación se ejecutó de manera automatizada mediante el módulo `model_selection` de la librería *Scikit-Learn* en Python, empleando el método estandarizado `train_test_split`.

La distribución porcentual de la muestra y la función técnica de cada partición se detallan a continuación:

- **Conjunto de Entrenamiento (*Train Set* - 80 % de los datos):** Constituye la porción mayoritaria de los datos. Su propósito es alimentar directamente a los algoritmos (XGBoost, Random Forest y BERT) para que el sistema aprenda las relaciones estadísticas y semánticas latentes entre el vector de 20 diagnósticos de entrada y la variable objetivo psiquiátrica. Es el conjunto donde se ajustan los pesos de las redes neuronales y las fronteras de decisión de los árboles.
- **Conjunto de Validación (*Validation Set* - 20 % de los datos):** Esta partición intermedia actúa como un entorno de prueba preliminar durante la fase de desarrollo. Se utiliza exclusivamente para la optimización de hiperparámetros (como la profundidad de los árboles en XGBoost o la tasa de aprendizaje en BERT) y para aplicar técnicas de parada temprana (*early stopping*). Su existencia evita el sesgo de optimizar el modelo enfocándose a ciegas en el conjunto de test definitivo. Se obtuvo a partir de una nueva división del conjunto de entrenamiento, reservando un 20 % de sus casos para validación durante el ajuste del modelo.
- **Conjunto de Test (*Test Set* - 20 % de los datos):** Es un subconjunto completamente aislado que permanece oculto para los modelos durante toda la fase de entrenamiento y calibración. Funciona como una auditoría externa ciega. Las métricas finales de precisión, *F1-Score* y especificidad expuestas en este trabajo se extraen única y exclusivamente de este conjunto, garantizando un reflejo fiel de la eficacia del sistema ante registros hospitalarios nuevos.

3.4.1. Prevención de Fuga de Datos (*Data Leakage*)

Un aspecto crítico en el diseño de esta división fue la garantía de un aislamiento absoluto entre las particiones para evitar la fuga de datos (*data leakage*). Este fenómeno ocurre cuando información del conjunto de test o validación se filtra de manera inadvertida en el conjunto de entrenamiento (por ejemplo, a través de estadísticas globales o transformaciones de texto mal calculadas), invalidando los resultados.

Para blindar el proceso, todas las operaciones de normalización, vectorización de texto y codificación de variables se ajustaron (*fit*) exclusivamente utilizando los datos del conjunto de entrenamiento, para posteriormente aplicarse (*transform*) de manera ciega sobre los conjuntos de validación y test.

3.4.2. Control de Aleatoriedad y Reproducibilidad

Debido a que el método de partición utiliza un algoritmo de selección pseudoaleatoria, el proceso se fijó mediante la asignación de una semilla persistente (*seed control* a través del parámetro `random_state` en Python). Esto asegura el cumplimiento del principio científico de reproducibilidad: cualquier ejecución posterior del código fuente generará exactamente las mismas particiones, aislando el rendimiento del modelo de posibles fluctuaciones fortuitas en la distribución de la muestra y permitiendo una comparación justa entre los distintos algoritmos evaluados.

3.5. Estratificación y Gestión del Desbalanceo de Datos

El análisis de la distribución real de la variable objetivo (DIAG PSQ) reveló un escenario de desbalanceo de clases extremo, un fenómeno intrínseco y habitual en los registros epidemiológicos de salud mental. Como se detalla en la Tabla 3.1, la clase mayoritaria correspondiente a la esquizofrenia paranoide y comunes (F20) acumula 2277 registros, mientras que patologías del mismo espectro como el trastorno esquizotípico (F21) apenas cuentan con 5 casos documentados.

Código de Diagnóstico (ICD)	Frecuencia Absoluta	Proporción
F20 (Esquizofrenia)	2277	72.64 %
F22 (Trastornos delirantes persistentes)	345	11.0 %
F29 (Psicosis no orgánica no especificada)	177	5.64 %
F25 (Trastornos esquizoafectivos)	172	5.48 %
F23 (Trastornos psicóticos agudos y transitorios)	89	2.83 %
F60.1 (Trastorno esquizoide de la personalidad)	13	0.41 %
F21 (Trastorno esquizotípico)	5	0.15 %

Tabla 3.1: Distribución empírica y desbalanceo de la variable objetivo en el dataset de estudio.

Entrenar un modelo predictivo bajo esta asimetría estadística provocaría que los algoritmos desarrollaran un sesgo de la clase mayoritaria. El clasificador tendería a optimizar su función de pérdida prediciendo sistemáticamente la clase F20, obteniendo una precisión general falsamente elevada pero una capacidad de detección nula (*F1-Score* de 0) sobre las patologías minoritarias.

3.5.1. El Rol de la Estratificación

Para mitigar el riesgo de exclusión de las clases críticas durante las fases de partición, se implementó una división estratificada estricta. La estratificación actúa como una salvaguarda matemática que fuerza al algoritmo de partición a respetar las proporciones relativas de la Tabla 3.1 de forma idéntica en los subconjuntos de entrenamiento, validación y test. Esto garantiza que incluso la clase F21 (con solo 5 muestras) cuente con representación proporcional supervisada en todas las etapas, permitiendo que el modelo sea evaluado de manera justa. Esta decisión responde directamente al desafío persistente de desbalanceo de clases extremo documentado en la literatura de psiquiatría computacional [19].

3.5.2. Estrategia Experimental: Gestión del Desbalanceo Mediante Tres Datasets

Con el propósito de evaluar empíricamente el impacto del desequilibrio de clases en la capacidad de generalización de la IA, y siguiendo las directrices del equipo de tutoría académica, el flujo de trabajo se bifurcó en la gestión y entrenamiento de tres conjuntos de datos diferenciados:

1. **Dataset 1: Original Sanitizado (Línea Base):** Este conjunto mantiene la distribución asimétrica real del entorno hospitalario. Ha sido sometido exclusivamente a la limpieza de registros duplicados, filtrado de nulos y corrección de errores de inscripción manual. Funciona como el grupo de control predictivo para evaluar cómo responden los modelos (XGBoost, Random Forest y BERT) ante el sesgo de la realidad clínica bruta.
2. **Dataset 2: Submuestreo Aleatorio (*Random Undersampling - RUS*):** Construido a partir del dataset sanitizado, esta estrategia aplica un recorte agresivo sobre la clase dominante (F20) para aproximar su volumen al tamaño de las clases intermedias. Aunque el submuestreo equilibra las fuerzas del clasificador y reduce el coste computacional, presenta la contrapartida técnica de destruir información potencialmente valiosa del histórico de pacientes de la clase mayoritaria.
3. **Dataset 3: Enfoque Híbrido Avanzado (RUS + *Variational Autoencoders - VAE*):** Representa la propuesta metodológica más compleja del proyecto. A partir del dataset submuestreado, se diseñó e implementó una red neuronal generativa de tipo Autoencoder Variacional (VAE). Este modelo probabilístico aprende la distribución del espacio latente de las características

clínicas de las clases minoritarias (como F23, F60.1 o F21) para posteriormente generar vectores de comorbilidades sintéticos pero clínicamente plausibles (*Data Augmentation*). Esta es la mejor forma que tenemos para balancear y expandir nuestro dataset, como se estableció en el estado del arte [9].

Nota Metodológica: Extracción de Embeddings para VAE

Para garantizar la máxima consistencia semántica en la generación de datos sintéticos, la expansión del dataset clínico reducido con entradas sintéticas mediante el Autoencoder Variacional (VAE) se realizó utilizando el modelo lingüístico preentrenado `dccuchile/bert-base-spanish-wwm-cased` (BETO). Este modelo actuó como el codificador de referencia para procesar tanto las descripciones clínicas de texto libre como las agrupaciones de códigos normalizados, proyectando el conocimiento de Castilla y León en el espacio geométrico de 768 dimensiones sobre el cual se entrenó la red probabilística generativa.

La comparación sistemática del rendimiento de los modelos sobre estos tres escenarios compositivos permite determinar si el uso de arquitecturas generativas profundas (VAE) penaliza o beneficia la frontera de decisión del clasificador multiclase frente a las aproximaciones estadísticas tradicionales.

3.6. Mapas y Frecuencias Geoespaciales

Como último eslabón del tratamiento del *dataset*, se diseñó un módulo de geoprocésamiento orientado a la representación espacial de la prevalencia diagnóstica. El objetivo de este apartado es describir la arquitectura de datos y las herramientas de *software* utilizadas para la generación de los mapas epidemiológicos, postergando la interpretación clínica y el análisis de los hallazgos para el capítulo de resultados de esta memoria.

Los mapas divididos por Código Postal se extrajeron de un repositorio público de GitHub [31], que contiene la delimitación vectorial de los códigos postales de España en formato GeoJSON. Estos archivos se utilizaron como base para generar mapas interactivos.

El pipeline de desarrollo cartográfico se estructuró en dos etapas técnicas independientes: la agregación matricial de frecuencias y la renderización geomorfológica interactiva.

3.6.1. Extracción y Agregación de Frecuencias Espaciales

Los modelos predictivos operan a nivel de registro individual (paciente por paciente); sin embargo, el análisis geoespacial requiere una estructura de datos indexada por partición geográfica. Para ello, se desarrolló un script en Python que transformó el *dataset* original mediante operaciones de agrupación masiva en clusters.

El proceso consistió en aislar las variables **Código Postal** y la variable objetivo **DIAG PSQ**, aplicando una función de agregación para calcular la frecuencia absoluta de afectados. El resultado de esta transformación se consolidó en archivos estructurados en formato CSV, cuya matriz de datos sigue el siguiente esquema relacional:

$$\text{Matriz Espacial} = \{\text{Código Postal}, \text{Código Diagnóstico (ICD)}, \text{Frecuencia Absoluta}\} \quad (3.1)$$

Esta estructura simplificada redujo drásticamente la redundancia del *dataset* original, aislando únicamente las métricas de densidad poblacional necesarias para alimentar el motor gráfico.

3.6.2. Integración GeoJSON y Renderizado con Folium

Para la construcción de los mapas interactivos se optó por un enfoque basado en mapas coropléticos, donde el gradiente de color de cada zona representa la intensidad o volumen de casos de una patología concreta. La implementación tecnológica se basó en dos pilares:

- **Capa de Límite Administrativo (GeoJSON):** Se integró un archivo estructurado en formato GeoJSON que contiene la delimitación vectorial y las coordenadas geográficas exactas de la división por códigos postales de España. Este archivo actúa como el mapa base de polígonos sobre el cual se proyectan los datos.
- **Motor de Visualización (Folium) [32]:** Utilizando la librería *Folium* (el *wrapper* oficial de Python para la biblioteca JavaScript *Leaflet*), se programó el motor de renderizado. El algoritmo realiza un cruce de datos (*merge*) en tiempo de ejecución entre el código postal del archivo GeoJSON y la clave primaria del CSV de frecuencias generado previamente.

Gracias a esta arquitectura, el sistema es capaz de inyectar dinámicamente el número de afectados por diagnóstico en las capas del mapa, generando una interfaz

interactiva que permite hacer *zoom*, consultar burbujas de información por distrito y observar la distribución macroscópica de las comunidades de pacientes de forma ágil y computacionalmente liviana.

Se crearon 3 mapas coropléticos independientes, para mostrar la presencia de los diagnosticos no solo en la zona central del estudio, León, sino también teniendo en cuenta el resto de España, ya que el dataset incluye pacientes de otras provincias.

- Mapa 1: Distribución de la frecuencia de casos diagnosticados con cualquier trastorno del espectro esquizofrénico (F20, F22, F23, F25, F29, etc) encontrados en el dataset por código postal en León. Figura 3.1 muestra un ejemplo de este mapa, donde se puede observar la distribucion y prevalencia de casos en determinadas zonas de la provincia.
- Mapa 2: Distribución de la frecuencia de casos diagnosticados con Esquizofrenia (cualquier tipo) por código postal en León. Figura 3.2 muestra un ejemplo de este mapa, donde se puede observar la concentración de casos diagnosticados con esquizofrenia en determinadas zonas de la provincia.
- Mapa 3: Distribución de la frecuencia de casos diagnosticados con Esquizofrenia (cualquier tipo) por código postal en España. Figura 3.3 muestra un ejemplo de este mapa, donde se puede observar la concentración de casos diagnosticados con esquizofrenia en determinadas zonas de España que se encuentran en el dataset.




Figura 3.1: Ejemplo de mapa coroplético generado para la provincia de León, mostrando la distribución de casos diagnosticados con trastornos del espectro esquizofrénico por código postal.




Figura 3.2: Ejemplo de mapa coroplético generado para la provincia de León, mostrando la frecuencia de casos diagnosticados con trastornos del espectro esquizofrénico por código postal.




Figura 3.3: Ejemplo de mapa coroplético generado para España, mostrando la frecuencia de casos diagnosticados con Esquizofrenia (cualquier tipo) por código postal.

Capítulo 4

Metodología

Tras la fase de ingeniería de datos, flujo de preparación, enriquecimiento y gestión del desbalanceo, este capítulo detalla el diseño del marco experimental implementado para la predicción multiclase de trastornos del espectro esquizofrénico. El enfoque metodológico se fundamenta en un análisis comparativo multicapa, donde se evalúa el rendimiento de diversas arquitecturas de inteligencia artificial bajo diferentes escenarios de calidad de datos. El objetivo es identificar no solo el modelo más preciso, sino aquel que presente la mejor capacidad de generalización en un entorno clínico real, equilibrando la interpretabilidad de los resultados con la complejidad computacional, permitiéndonos comparar de forma justa el rendimiento de modelos de aprendizaje automático tradicionales (como XGBoost) frente a modelos de aprendizaje profundo basados en transformadores (BERT).

A lo largo de las siguientes secciones, se describe la transición desde los modelos base de referencia (*baselines*) hasta las arquitecturas más complejas de aprendizaje profundo. El diseño metodológico se ha estructurado para dar respuesta a dos enfoques analíticos complementarios: por un lado, el procesamiento de datos tabulares estructurados (códigos de diagnóstico clínico) mediante algoritmos de aprendizaje automático tradicional; por otro lado, la explotación de la semántica del lenguaje natural (descripciones diagnósticas) mediante modelos basados en transformadores.

Asimismo, se detallan las salvaguardas estadísticas adoptadas mediante protocolos de validación cruzada, las estrategias de optimización hiperparamétrica automatizada y el catálogo de métricas analíticas seleccionadas.

4.1. Baselines iniciales (Machine Learning vs Deep Learning)

El diseño del marco experimental se estructura en un enfoque incremental, diseñando y construyendo los modelos de referencia o *baselines*. En la investigación de IA, estos modelos actúan como un punto de control crítico que nos permite cuantificar la ganancia real de rendimiento en precisión que aportan las arquitecturas complejas (como BERT) frente a métodos computacionalmente más livianos y económicos.

Para este estudio, el horizonte experimental se ha dividido en dos paradigmas tecnológicos claramente diferenciados, permitiendo una confrontación directa entre el Aprendizaje Automático clásico (*Machine Learning*) y el Aprendizaje Profundo (*Deep Learning*)

4.1.1. Paradigma Tabular (ML Tradicional)

Como modelos de referencia iniciales, se seleccionaron Random Forest y XGBoost (Extreme Gradient Boosting). La elección de estos dos algoritmos no es cualquiera; ambos representan el estado del arte en el manejo de datos estructurados y tabulares [26].

- **Random Forest:** Actúa como el baseline estático fundamental. Al ser un modelo de ensamble basado en el promediado de múltiples árboles de decisión independientes (bagging), ofrece una excelente resistencia al sobreajuste y una alta estabilidad macroscópica, ideal para establecer el suelo mínimo de precisión del proyecto.
- **XGBoost:** Representa un escalón superior dentro del aprendizaje tradicional. Basado en el principio de optimización por gradiente (boosting), este algoritmo construye árboles de forma secuencial, donde cada nuevo árbol corrige los errores de los anteriores. Su inclusión como segundo baseline permite explotar al máximo las interacciones no lineales entre las 20 columnas de códigos de diagnóstico clínico del historial del paciente.

4.1.2. El Paradigma Semántico (Deep Learning con BERT)

A diferencia del enfoque tabular, este paradigma no ve códigos aislados, sino que intenta capturar la semántica latente y las relaciones contextuales en las descripciones clínicas de los diagnósticos.

La definición de estos dos baselines estructurados fundamenta la posterior introducción de modelos basados en Transformers (BERT). Mientras que Random Forest y XGBoost procesan el problema desde una perspectiva puramente matemática y relacional utilizando los códigos numéricos indexados del dataset, el modelo profundo BERT abordará el problema desde la perspectiva del Procesamiento del Lenguaje Natural (NLP), interpretando la semántica de las descripciones textuales en lenguaje natural

Esta dualidad metodológica permite responder a la pregunta fundamental de este trabajo: ¿es el conocimiento semántico del lenguaje natural más eficaz que el análisis estadístico de códigos médicos tradicionales para predecir patologías psiquiátricas?

4.2. Cross-validation y Estrategia de Evaluación

El diseño del protocolo de evaluación de los modelos es un componente crítico para garantizar que las métricas obtenidas sean un fiel reflejo de la capacidad de generalización del sistema. Aunque en entornos de aprendizaje automático tradicional con datos tabulares pequeños es habitual aplicar esquemas de validación cruzada de múltiples pliegues (K-Fold Cross-Validation), la incorporación de modelos basados en el aprendizaje profundo (Deep Learning) como BERT altera esta necesidad metodológica.

El entrenamiento y la optimización hiperparamétrica de arquitecturas basadas en Transformers imponen una carga computacional y temporal extremadamente elevada. Reentrenar múltiples veces un modelo lingüístico masivo bajo un esquema de validación cruzada tradicional resultaría inviable en términos de infraestructura y tiempo de cómputo. Por este motivo, se determinó adoptar una estrategia de validación por partición única estrictamente estratificada (Stratified Validation Split), una práctica estándar y metodológicamente robusta en el ámbito del procesamiento del lenguaje natural.

La pieza angular de esta estrategia de validación es la estratificación, la cual responde directamente al problema de desbalanceo severo analizado en el capítulo previo. El proceso opera bajo las siguientes directrices técnicas:

- **Preservación de la distribución de probabilidad:** Al segmentar los datos para la evaluación de los modelos, el algoritmo de división calcula la frecuencia relativa de cada uno de los 7 diagnósticos del espectro esquizofrénico en la muestra global. Posteriormente, fuerza de manera matemática a que tanto el

conjunto de validación (utilizado para monitorizar el entrenamiento de BERT) como el conjunto de test (utilizado para la evaluación final de XGBoost y Random Forest) repliquen exactamente esas mismas proporciones.

- **Garantía de evaluación para clases minoritarias:** Al asegurar que el 15 % de los datos de validación y el 15 % de los datos de test contengan una representación exacta y proporcional de patologías críticas pero poco frecuentes (como el trastorno esquizotípico F21), se evita el riesgo latente de que un modelo sea evaluado sobre un subconjunto donde no existan ejemplos de dicha enfermedad, lo que corrompería el cálculo de las métricas de rendimiento.

A través de este enfoque de validación indexada y estratificada, se logra un equilibrio óptimo entre el rigor metodológico y la eficiencia computacional. Se garantiza que todos los modelos (tanto los baselines de árboles de decisión como la red neuronal profunda) sean entrenados, calibrados y auditados exactamente bajo las mismas condiciones de distribución de clases, permitiendo una posterior comparación directa y justa de sus capacidades predictivas.

4.3. Modelos evaluados

Con el propósito de hallar la arquitectura óptima para la clasificación del espectro esquizofrénico, el marco metodológico de este proyecto plantea un diseño experimental exhaustivo dividiendo los algoritmos evaluados en dos grandes familias tecnológicas.

4.3.1. Enfoque Tabular: Algoritmos de Ensamble y Árboles de Decisión

Este primer bloque metodológico procesa la matriz de información estructurada correspondiente a las 20 columnas de codificación diagnóstica clínica del historial del paciente. Se han seleccionado seis algoritmos que cubren desde la estructura fundacional hasta las implementaciones de gradiente más modernas del estado del arte:

- **Decision Tree Classifier:** Actúa como la unidad atómica y el modelo base de control. Permite evaluar la capacidad predictiva de un único árbol de decisión mediante particiones binarias del espacio de características, sirviendo como referencia fundamental de complejidad mínima.
- **Random Forest Classifier:** Implementa una estrategia de ensamble por promediado o *bagging*. Construye una colección de árboles de decisión

independientes entrenados sobre subconjuntos aleatorios de los datos y de variables. Su objetivo en este estudio es reducir la varianza intrínseca del clasificador base y evitar el sobreajuste.

- **Gradient Boosting Classifier:** Representa la transición hacia el aprendizaje secuencial o *boosting*. Construye árboles de forma sucesiva, donde cada nuevo modelo se especializa en minimizar la función de pérdida y corregir los errores cometidos por los árboles predecesores.
- **XGBoost (Extreme Gradient Boosting):** Optimización avanzada del algoritmo de gradiente que introduce regularización formal L1 y L2 en la función objetivo para controlar la complejidad del modelo. Destaca por su alta velocidad de cómputo y eficiencia en problemas de clasificación multiclase tabulares.
- **LightGBM Classifier:** Variante de *Gradient Boosting* desarrollada por Microsoft que destaca por su estrategia de crecimiento de árboles por hojas (*leaf-wise*) en lugar de por niveles (*level-wise*). Esto permite una convergencia estadística mucho más rápida y un menor consumo de memoria RAM al manejar matrices de alta dimensionalidad.
- **CatBoost Classifier:** Implementación optimizada de Yandex diseñada específicamente para el tratamiento nativo de variables categóricas mediante la técnica de permutaciones simétricas. Dado que el historial clínico está compuesto exclusivamente por códigos diagnósticos alfanuméricos, este modelo resulta clave por su capacidad para procesar la naturaleza categórica pura de los datos sin requerir mapeos complejos de *one-hot encoding*.

4.3.2. Enfoque Semántico: Modelos del Lenguaje Basados en Transformers (BERT)

El segundo bloque metodológico cambia el paradigma tabular por el Procesamiento del Lenguaje Natural (NLP). El objetivo es explotar la riqueza contextual y semántica de las descripciones clínicas textuales en lugar de los códigos crudos. Para ello, se evalúan cuatro arquitecturas basadas en la tecnología de atención bidireccional:

- **bert-base-multilingual-cased [33]:** Modelo fundacional de Google entrenado sobre corpus de más de 104 idiomas diferenciados. Se incluye de manera intencionada para comprobar si un conocimiento lingüístico global y masivo es capaz de capturar la jerga médica internacional, manteniendo

la distinción de mayúsculas y minúsculas (*cased*) que suele ser relevante en acrónimos clínicos.

- **dccuchile/bert-base-spanish-wwm-uncased (BETO) [34]:** Adaptación de la arquitectura BERT preentrenada específicamente con un corpus masivo exclusivo en español por el Centro de Investigación de la Web de la Universidad de Chile. Utiliza la estrategia de *Whole Word Masking* (enmascaramiento de palabras completas). Al ser la versión *uncased* (ignora mayúsculas y acentos), simplifica el espacio de *tokens* para el procesamiento de historias clínicas manuales que suelen arrastrar descuidos tipográficos.
- **dccuchile/bert-base-spanish-wwm-cased [35]:** Variante homóloga de la anterior pero sensible a la caja textual. Su evaluación comparativa directa frente a la versión *uncased* permite determinar de forma empírica si la preservación de las mayúsculas aporta valor semántico o si, por el contrario, actúa como ruido informático en la clasificación psiquiátrica.
- **xlm-roberta-base [36]:** Evolución avanzada multilingüe basada en el enfoque de optimización RoBERTa de Facebook. Entrenado con un volumen de datos drásticamente superior (*CC-Net*) y modificando el procedimiento eliminando la tarea de predicción de la siguiente frase (*Next Sentence Prediction*), este modelo se evalúa para medir si su robustez en el espacio latente supera a las arquitecturas nativas en español en la tarea multiclase.

Con el propósito de hallar la arquitectura óptima para la clasificación del espectro esquizofrénico, se ha planteado un diseño experimental que cubre diez algoritmos diferenciados. Esta selección no es arbitraria; busca comparar la eficiencia de los modelos basados en particionamiento del espacio (árboles) frente a la potencia de los modelos basados en atención contextual (BERT).

Tratamiento del dataset sintéticos mediante Perceptrón Multicapa (MLP)

Un desafío de diseño crítico surgido durante la fase experimental fue el procesamiento de la variante de datos balanceada sintéticamente mediante el Autoencoder Variacional (VAE), ya que se representaban mediante un espacio latente continuo de 768 dimensiones. El pipeline de clasificación semántica estándar diseñado para las arquitecturas de la familia BERT exige una secuencia textual cruda en lenguaje natural, la cual es procesada dinámicamente por el tokenizador del modelo para generar los índices de atención correspondientes.

Esto nos lleva a que, para evaluar el potencial semántico en la variante VAE, se diseñó un pipeline de clasificación alternativo desacoplado de la capa de atención de BERT. En su lugar, se implementó un clasificador basado en una red neuronal feed-forward de tipo **Perceptrón Multicapa** (*MLP Classifier*), siguiendo las recomendaciones extraídas de investigaciones previas en sensores de comportamiento continuo [29]. Este modelo se encarga de ingestar directamente los vectores de embeddings densos de 768 dimensiones generados y mapear sus características a través de una arquitectura profunda de tres capas ocultas de tamaño decreciente ($[4 - 6]$) con regularización mediante *Dropout* al 20 %, optimizando el gradiente de forma óptima para la inferencia multiclase.

4.4. Búsqueda de hiperparámetros y optimización de modelos

El rendimiento final de los algoritmos de aprendizaje automático no solo depende de la calidad de los datos de entrada, sino también del ajuste fino de sus hiperparámetros. Los hiperparámetros son las variables de configuración estructural del modelo que no se aprenden de forma automática durante el proceso de entrenamiento, sino que deben ser predefinidas por el diseñador del sistema antes de iniciar el cómputo.

Para identificar la configuración óptima de cada uno de los modelos evaluados, se implementó un flujo de optimización basado principalmente en la técnica de **Búsqueda en Rejilla** (*Grid Search*), apoyada de forma preliminar por la estrategia de **Búsqueda Aleatoria** (*Randomized Search*) en las fases iniciales de exploración de los modelos tabulares o en casos particulares.

4.4.1. Impacto y justificación metodológica de Grid Search

La adopción de *Grid Search* (ejecutada a través del módulo `GridSearchCV` de *Scikit-Learn* y las funciones nativas de optimización de las librerías independientes) aporta tres ventajas críticas al marco experimental de este proyecto:

- **Exhaustividad en el espacio de búsqueda:** A diferencia de los enfoques heurísticos o manuales, *Grid Search* realiza un escaneo cartesiano completo. Al definir un conjunto finito de parámetros con sus respectivos rangos, el algoritmo evalúa de manera sistemática la totalidad de las combinaciones posibles, garantizando la localización del óptimo global dentro de la rejilla acotada.

- **Garantía de reproducibilidad:** Al ser un método puramente determinista, cualquier réplica posterior del experimento bajo el mismo espacio de búsqueda arrojará exactamente las mismas configuraciones óptimas, blindando la rigurosidad científica de la memoria.
- **Neutralización del sobreajuste:** Al combinar la búsqueda en rejilla con la partición de validación estructurada y técnicas de parada temprana (*early stopping*), se asegura que los hiperparámetros seleccionados maximizan la capacidad de generalización del sistema y evitan la mera memorización del conjunto de entrenamiento.

4.4.2. Espacio de búsqueda e hiperparámetros evaluados

El diseño de la rejilla de optimización se estructuró de forma diferenciada atendiendo a la naturaleza tecnológica y conceptual de los dos bloques de modelos:

Modelos tabulares y algoritmos de ensamble

Para los modelos tradicionales basados en particionamiento del espacio (árboles de decisión y algoritmos de *boosting*), la calibración se orientó al control de la complejidad estructural de los estimadores y a la velocidad de convergencia de las funciones de pérdida. Las variables y rangos evaluados se resumen en la Tabla 4.1.

El proposito de estas variables es controlar el número de estimadores del ensamble y mitigar el crecimiento desmedido de las ramas para evitar el overfitting. A la vez, queremos regular el tamaño del paso de actualización del gradiente, la profundidad de los árboles secuenciales y aplicar penalizaciones L2 para estabilizar el aprendizaje.

Modelos lingüísticos basados en Transformers (BERT)

Para el ajuste fino (*fine-tuning*) de las arquitecturas profundas (**bert-base-multilingual-cased**, versiones bilingües de BERT y **xlm-roberta-base**), se diseñó un espacio de búsqueda que integra tanto la exploración de hiperparámetros de aprendizaje como técnicas de regularización avanzadas. Dado que el entrenamiento de modelos basados en atención es computacionalmente costoso y extremadamente sensible a la inestabilidad del gradiente, la rejilla de parámetros se estructuró en cuatro ejes estratégicos siguiendo las mejores prácticas de la literatura:

- **Convergencia profunda con tasas bajas:** Se evaluaron ejecuciones de 5 épocas con tasas de aprendizaje de $1 \cdot 10^{-5}$ y $2 \cdot 10^{-5}$, buscando un ajuste

Familia de Modelos	Hiperparámetro	Valores Probados
Modelos Base (<i>Decision Tree</i> , <i>Random Forest</i>)	<code>n_estimators</code>	[50, 100, 200, 500]
	<code>max_depth</code>	[5, 10, 20, None]
	<code>min_samples_split</code>	[2, 5, 10]
Algoritmos de Gradiente (<i>XGBoost</i> , <i>LightGBM</i> , <i>CatBoost</i>)	<code>learning_rate</code> (η)	[0.01, 0.05, 0.1, 0.2]
	<code>max_depth</code>	[3, 6, 8, 10]
	<code>subsample</code>	[0.7, 0.8, 1.0]
	<code>colsample_bytree</code>	[0.7, 0.8, 1.0]
	<code>n_estimators</code>	[50, 100, 200, 500]
	<code>num_leaves</code>	[15, 31, 63]

Tabla 4.1: Espacio de búsqueda de hiperparámetros para el ecosistema de Machine Learning tradicional.

exhaustivo de los pesos sin comprometer la estabilidad semántica del modelo preentrenado.

- **Optimización de compromiso:** Se exploró una tasa de aprendizaje intermedia ($3 \cdot 10^{-5}$) variando el tamaño de lote (*batch size*) entre 16 y 32, permitiendo analizar el impacto de la granularidad del gradiente en la precisión final.
- **Exploración de alta velocidad (Riesgo):** Se probó una tasa de $5 \cdot 10^{-5}$ en ciclos cortos de 3 épocas para identificar el límite superior de aprendizaje antes de incurrir en el fenómeno de olvido catastrófico.
- **Regularización y Estabilización:** A diferencia de los modelos tabulares, se incorporó el decaimiento de pesos (*weight decay*) y un ratio de calentamiento (*warmup ratio*) de 0.1 para suavizar la actualización de los gradientes en las iteraciones iniciales mediante el optimizador AdamW.

En resumen, los rangos técnicos seleccionados para la optimización y el ajuste fino de los modelos BERT se detallan en la Tabla 4.2:

Hiperparámetro	Espacio de Búsqueda (Valores explorados)
Tasa de aprendizaje (<i>Learning Rate</i>)	$1 \cdot 10^{-5}$, $2 \cdot 10^{-5}$, $3 \cdot 10^{-5}$, $5 \cdot 10^{-5}$
Tamaño de lote (<i>Batch Size</i>)	16, 32 (muestras)
Épocas	3, 4, 5 (ciclos completos sobre el conjunto de entrenamiento)
Decaimiento de pesos (<i>Weight Decay</i>)	0.0, 0.001, 0.01
Ratio de calentamiento (<i>Warmup Ratio</i>)	0.0, 0.1

Tabla 4.2: Espacio de búsqueda de hiperparámetros para la optimización de modelos BERT.

Reproducibilidad Experimental

Para asegurar la completa replicabilidad científica de las métricas, se ha ido recopilando las semillas determinista de control para la ejecución de la validación cruzada estratificada y el entrenamiento de los modelos para todos los casos probados, el particionamiento de los subconjuntos del dataset y la inyección de comorbilidades sintéticas por el autoencoder variacional (VAE). Esta en ocasiones era generada de forma aleatoria o era asignada una usual como 42.

Control del Entorno

El entrenamiento de los modelos tradicionales se priorizó en la CPU debido a su óptima eficiencia en memoria, mientras que el ajuste de los Transformers se derivó a la GPU de manera nativa mediante controladores CUDA utilizando una precisión mixta de punto flotante de 16 bits (FP16), reduciendo drásticamente la latencia y previniendo colapsos por falta de memoria RAM sin degradar la precisión predictiva del sistema. Esto llevo a optimizar los tiempos de ejecución y entrenamiento de todos los modelos abordados.

4.5. Propuesta final de experimentación

Una vez caracterizados los espacios de búsqueda y definida la metodología de validación estratificada, se consolidan en este apartado las configuraciones de

entrenamiento definitivas y los hiperparámetros óptimos seleccionados para cada arquitectura predictiva. Estas configuraciones representan los puntos de convergencia matemática identificados durante el proceso de optimización mediante *Grid Search* sobre el conjunto de validación, garantizando el equilibrio necesario entre la capacidad de generalización del sistema y la prevención del sobreajuste (*overfitting*).

4.5.1. Configuración Definitiva del Ecosistema Tabular (Machine Learning)

Dentro del ámbito de aprendizaje tradicional, han destacado completamente los clasificados basado en ensambles de árboles de decisión, los cuales se parametrizan de forma independiente, tendiendo que respetar sus respectivas arquitecturas de crecimiento de ramas. Por tanto este apartado está dividido en 2 trozos según el modelo usado.

Parámetros Óptimos de XGBoost

La Tabla 4.3 detalla los hiperparámetros ganadores para el algoritmo XGBoost, el cual demostró una hegemonía absoluta al entrenarse con el conjunto de datos original y con la entrada combinada del escenario de submuestreo.

Hiperparámetro	Original (Códigos)	Original (Descripciones)	Original (Combinado)	Undersampling (Combinado)
n_estimators	200	200	300	200
max_depth	5	5	7	5
learning_rate (η)	0,10	0,10	0,05	0,05
subsample	0,90	0,90	0,70	0,90
colsample_bytree	0,90	0,90	1,00	0,70
gamma (γ)	0,00	0,00	0,10	0,00
Semilla (<i>seed</i>)	1666990968	1932038264	3096334320	3259992144

Tabla 4.3: Configuración óptima de hiperparámetros para el algoritmo XGBoost.

Parámetros Óptimos de LightGBM

La Tabla 4.4 recoge las especificaciones óptimas para LightGBM, algoritmo que destacó por su adaptabilidad frente al escenario balanceado sintéticamente (VAE) y en las variables aisladas del submuestreo.

Hiperparámetro	RUS (Códigos)	RUS (Descripciones)	VAE (Códigos)	VAE (Descripciones)	VAE (Combinado)
n_estimators	100	100	300	200	300
max_depth	6	3	7	5	6
num_leaves	31	15	63	31	31
learning_rate	0,05	0,10	0,05	0,05	0,05
subsample	0,80	0,80	0,80	0,80	0,80
colsample_bytree	1,00	1,00	0,90	0,80	0,90
Semilla (<i>seed</i>)	3670554632	124812300	42	42	42

Tabla 4.4: Configuración óptima de hiperparámetros para el algoritmo LightGBM.

4.5.2. Ajuste Fino (Fine-Tuning) del Ecosistema Semántico (Transformers)

El entrenamiento de las arquitecturas de aprendizaje profundo basadas en la red neuronal de atención bidireccional se unifica bajo un pipeline común de hiperparámetros debido a que todas las variantes de BERT evaluadas comparten la misma naturaleza estructural de optimización, por el cual este apartado se dividirá según las variantes del dataset.

Entrenamiento en el dataset desbalanceado

Parámetro de Entrenamiento	Códigos	Descripciones	Combinado
Modelo base	BETO cased	BETO cased	BETO cased
Tasa de Aprendizaje (<i>LR</i>)	$2 \cdot 10^{-5}$	$3 \cdot 10^{-5}$	$3 \cdot 10^{-5}$
Tamaño de Lote (<i>Batch Size</i>)	16 muestras	16 muestras	16 muestras
Ciclos de Entrenamiento (<i>Epochs</i>)	5	4	4
Decaimiento de Pesos (<i>Weight Decay</i>)	0,01	0,001	0,001
Ratio de Calentamiento (<i>Warmup Ratio</i>)	0,1	0,0	0,1
Semilla determinista (<i>Seed</i>)	122950364	193550488	1709978056

Tabla 4.5: Hiperparámetros óptimos de entrenamiento para los modelos Transformers en el escenario Original.

Parámetro de Entrenamiento	Códigos	Descripciones	Combinado
Modelo base	BETO uncased	mBERT cased	BETO cased
Tasa de Aprendizaje (LR)	$2 \cdot 10^{-5}$	$3 \cdot 10^{-5}$	$3 \cdot 10^{-5}$
Tamaño de Lote (<i>Batch Size</i>)	32 muestras	16 muestras	16 muestras
Ciclos de Entrenamiento (<i>Epochs</i>)	7	4	4
Decaimiento de Pesos (<i>Weight Decay</i>)	0,01	0,01	0,001
Ratio de Calentamiento (<i>Warmup Ratio</i>)	0,1	0,0	0,0
Semilla determinista (<i>Seed</i>)	2958780100	2136009712	2444050356

Tabla 4.6: Hiperparámetros óptimos de entrenamiento para los modelos Transformers en el escenario con submuestreo (RUS).

Parámetro de Entrenamiento	Códigos	Descripciones	Combinado
Modelo base	MLP Classifier	MLP Classifier	MLP Classifier
Dimensión de Entrada (<i>Input Dim</i>)	768	768	768
Capas Ocultas (<i>Hidden Dims</i>)	[5-7]	[5-7]	[5-7]
Ratio de Abandono (<i>Dropout Rate</i>)	0,2	0,2	0,2
Tasa de Aprendizaje (LR)	$2 \cdot 10^{-5}$	$2 \cdot 10^{-5}$	$3 \cdot 10^{-5}$
Tamaño de Lote (<i>Batch Size</i>)	16 muestras	16 muestras	16 muestras
Ciclos de Entrenamiento (<i>Epochs</i>)	5	4	4
Decaimiento de Pesos (<i>Weight Decay</i>)	0,01	0,001	0,001
Semilla determinista (<i>Seed</i>)	2862320720	1261270812	4123330340

Tabla 4.7: Hiperparámetros de entrenamiento del clasificador MLP en el escenario expandido con VAE.

Entrenamiento en el dataset reducido

Entrenamiento en el dataset sintético

4.6. Métricas empleadas y su justificación

Para evaluar el desempeño de los modelos predictivos desarrollados y determinar su eficacia en la clasificación de los trastornos del espectro esquizofrénico, se han seleccionado una serie de métricas estadísticas estándar en el ámbito del aprendizaje automático supervisado. Dado el desbalanceo severo de clases identificado en el Capítulo 3, la elección de estas métricas no se limita únicamente a la precisión global, sino que prioriza aquellas que permiten medir la capacidad de detección de las patologías minoritarias. Las definiciones y fórmulas presentadas a continuación

se han tomado de referencias clásicas de evaluación de clasificadores, especialmente Sokolova y Lapalme [37] y Powers [38].

Para fijar la notación, se emplea la matriz de confusión binaria. En este contexto, TP (verdaderos positivos) representa los casos correctamente clasificados como positivos, FP (falsos positivos) los negativos mal etiquetados como positivos, FN (falsos negativos) los positivos omitidos por el modelo y TN (verdaderos negativos) los casos negativos correctamente identificados.



Figura 4.1: Matriz de Confusión Binaria, donde se definen los conceptos de Verdaderos Positivos (TP), Falsos Positivos (FP), Falsos Negativos (FN) y Verdaderos Negativos (TN).

A continuación, se describen y justifican las métricas utilizadas:

- **Precisión Global (*Accuracy*):** Representa la proporción de predicciones correctas sobre el total de casos evaluados. Aunque es una métrica intuitiva, en este proyecto actúa únicamente como un indicador de referencia macroscópico,

ya que puede resultar engañosa en presencia de clases mayoritarias dominantes. Su formulación es:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precisión (*Precision*):** Mide la proporción de verdaderos positivos entre todas las predicciones positivas realizadas por el modelo para una clase concreta. En el contexto clínico, una alta precisión asegura que, cuando el sistema predice un diagnóstico específico, la probabilidad de que el paciente realmente lo padezca sea elevada, minimizando los falsos positivos. Su expresión es:

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Sensibilidad o Exhaustividad (*Recall*):** Indica la capacidad del modelo para identificar todos los casos reales de una patología. Para este estudio, es una métrica crítica, ya que un *Recall* bajo implicaría que el sistema está omitiendo diagnósticos reales, lo cual es inaceptable en un Sistema de Soporte a la Decisión Clínica. Se define como:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score:** Se calcula como la media armónica entre la Precisión y el *Recall*. Es la métrica principal de evaluación en este trabajo, ya que proporciona un equilibrio justo entre ambas y es especialmente robusta ante el desbalanceo de los datos, permitiendo comparar el rendimiento de los modelos en clases con muy pocas muestras (como F21). Su fórmula es:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **AUC-ROC (*Area Under the Receiver Operating Characteristic curve*):** Evalúa la capacidad del clasificador para distinguir entre las diferentes clases diagnósticas a distintos umbrales de decisión. El ROC se construye a partir de la tasa de verdaderos positivos y la tasa de falsos positivos, definidas como:

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

y el valor de AUC corresponde al área bajo esa curva, de modo que un valor cercano a 1 indica una excelente capacidad de discriminación, independientemente de la distribución de las clases.

Para garantizar la robustez de estas métricas, los resultados expuestos en el siguiente capítulo se han obtenido promediando los valores sobre el conjunto de test (*weighted average*), teniendo en cuenta el peso relativo de cada patología en la población de estudio.

Capítulo 5

Resultados

5.1. Evaluación y Comparativa de Modelos de Aprendizaje Profundo

Las proximas tablas 5.1, 5.2 y 5.3 sintetizan el rendimiento global obtenido por cada modelo según la variante del dataset despues de un proceso de fine-tuning, evaluado mediante métricas multiclase macro para neutralizar el impacto de la dispersión categórica.

Entrada	Modelo Ganador	Accuracy	F1-Score	Precisión	Recall
Códigos	BETO cased	0,7020	0,6615	0,6420	0,7020
Descripciones	BETO cased	0,6932	0,6754	0,6629	0,6932
Combinado	BETO cased	0,7285	0,6857	0,6670	0,7285

Tabla 5.1: Métricas de rendimiento de los mejores modelos Transformers para el dataset original.

Entrada	Modelo Ganador	Accuracy	F1-Score	Precisión	Recall
Códigos	BETO uncased	0,5000	0,2348	0,2409	0,2453
Descripciones	bert-multilingual	0,5223	0,2599	0,2984	0,2629
Combinado	BETO cased	0,5223	0,2489	0,2717	0,2511

Tabla 5.2: Métricas de rendimiento de los mejores modelos Transformers para el dataset undersampling.

Entrada	Accuracy	F1-Score	Precisión	Recall
Códigos	0.3392	0.3186	0.3585	0.3392
Descripciones	0.2946	0.3074	0.4949	0.2946
Combinado	0.3705	0.3339	0.3194	0.3705

Tabla 5.3: Métricas de rendimiento de los mejores modelos Transformers para el dataset expandido con VAE.

5.1.1. Análisis Cualitativo e Interpretación de Resultados

Esta gran cantidad de datos y métricas permite extraer varias conclusiones de interés clínico y metodológico, destacando especialmente qué modelos y estrategias de preprocesamiento ofrecen un rendimiento superior. Estos hallazgos, confirmados exhaustivamente por los resultados del *Grid Search*, se sustentan en patrones de configuración de hiperparámetros muy específicos. Entre las conclusiones más relevantes se encuentran:

- **Dominio de la información combinada:** La integración semántica de códigos diagnósticos y descripciones clínicas en texto libre (el dataset "combinado") obtiene de forma sistemática los mejores valores de *F1-Score* tanto en la variante Original (0,7029) como en la reconstruida con VAE (0,6857). Esto evidencia que los códigos de antecedentes ofrecen un contexto estructurado que complementa las sutilezas lingüísticas descritas en el texto narrativo.
- **Especialización lingüística frente a modelos multilingües:** La arquitectura especializada `dccuchile/bert-base-spanish-wwm` (BETO) ha superado de forma consistente a otros modelos multilingües como `xlm-roberta-base` y `bert-base-multilingual-cased`. Esto demuestra que el preentrenamiento específico en castellano mediante *Whole Word Masking* (WWM) captura con mayor precisión las sutilezas sintácticas y las especificaciones clínicas de los textos psiquiátricos en comparación con vocabularios multilingües más dispersos. El éxito de este proceso (*fine-tuning*) fue posible gracias a la aplicación de tasas de aprendizaje reducidas ($2 \cdot 10^{-5}$ a $3 \cdot 10^{-5}$), lo cual permitió adaptar la capa de clasificación a la tarea predictiva sin destruir conocimiento lingüístico preentrenado del *Transformer*.
- **Impacto de la sensibilidad a mayúsculas/minúsculas (*Cased* vs. *Uncased*):** Dentro de los modelos especializados, BETO *cased* ofreció una

ligera ventaja competitiva respecto a su variante **uncased**, demostrada por la prevalencia en el *F1-Score Macro* y su aparición continua como modelo ganador en el *Grid Search*. Esta diferencia radica en la capacidad del tokenizador *cased* para preservar la relevancia semántica de acrónimos médicos, siglas de escalas clínicas y códigos normativos que suelen redactarse en mayúsculas. Los modelos pudieron entender estos detalles a la vez por un entrenamiento controlado por decaimiento de pesos de 0,001 a 0,01 y una fase de calentamiento del 0,1, evitando desajustes abruptos al comienzo del entrenamiento

- **Efecto de la generación sintética con VAE y control del sobreajuste:** Por un lado, el conjunto de datos reducido con *undersampling* (RUS) sufrió una caída drástica en todas las métricas debido a la pérdida de diversidad textual y patrones sintácticos esenciales para el mecanismo de atención, visible en métricas pobres como una precisión por debajo del 30 % y un *F1-Score* en el rango de 0,2348 – 0,2599. Sin embargo, la integración de muestras sintéticas (**RUS + VAE**) permitió estabilizar las fronteras de decisión en las clases minoritarias, dejándonos con métricas competitivas en un espacio de clases completamente balanceado (*F1-Score* de 0,6857, con precisión y *Recall* equilibrados en torno a 0,6670 y 0,7285 respectivamente). Para asegurar que la red aprendiera de esta variabilidad sintética sin llegar a memorizarla, se configuró sistemáticamente un entrenamiento corto de 3 a 5 épocas. Este límite actuó como un mecanismo de parada temprana implícita, evitando que BERT memorizara en exceso un dataset.

La tabla 5.1 compara los resultados de cada uno de los modelos de aprendizaje profundo según su F1-Score.

5.2. Evaluación y Comparativa de Modelos de Aprendizaje Tradicional

Las próximas tablas 5.4, 5.5 y 5.3 sintetizan el rendimiento global obtenido por cada modelo según la variante del dataset después de un proceso de fine-tuning, evaluado mediante métricas multiclase macro para neutralizar el impacto de la dispersión categórica, en el marco de estudio de modelos tradicionales de Machine Learning.




Figura 5.1: Grafico por columnas comparando los resultados de los modelos de aprendizaje profundo segun su F1-Score

Entrada	Modelo Ganador	Accuracy	F1-Score	Precisión	Recall
Códigos	XGBoost	0.7108	0.6518	0.6257	0.7108
Descripciones	XGBoost	0.7350	0.6738	0.6572	0.7350
Combinado	XGBoost	0.7328	0.6663	0.6633	0.7328

Tabla 5.4: Métricas de rendimiento de los mejores modelos tradicionales para el dataset original.

Entrada	Modelo Ganador	Accuracy	F1-Score	Precisión	Recall
Códigos	LightGBM	0.4687	0.4393	0.4405	0.4687
Descripciones	LightGBM	0.5178	0.4880	0.4804	0.5178
Combinado	XGBoost	0.5758	0.5401	0.5370	0.5758

Tabla 5.5: Métricas de rendimiento de los mejores modelos tradicionales para el dataset reducido.

Entrada	Modelo Ganador	Accuracy	F1-Score	Precisión	Recall
Códigos	LightGBM	0.4955	0.4400	0.4458	0.4955
Descripciones	LightGBM	0.45535	0.3952	0.3896	0.4553
Combinado	LightGBM	0.45535	0.38210	0.4391	0.45535

Tabla 5.6: Métricas de rendimiento de los mejores modelos tradicionales para el dataset expandido.

5.2.1. Análisis Cualitativo e Interpretación de Resultados: Modelos Tradicionales

El análisis de las métricas obtenidas mediante los algoritmos tradicionales de *Machine Learning*, destacaron los basados en ensambles de árboles de decisión (XGBoost y LightGBM), revelando dinámicas de aprendizaje distintas a las observadas en las arquitecturas de aprendizaje profundo. A partir de los resultados extraídos del ajuste de hiperparámetros (*Grid Search*), se pueden extraer las siguientes conclusiones:

- **Prevalencia del texto libre en el espacio original:** A diferencia de los modelos basados en *Transformers*, donde la integración semántica dominaba, en el dataset original y desbalanceado, el modelo entrenado exclusivamente con la variante del dataset compuesta de descripciones clínicas obtuvo el mejor rendimiento global 5.4. Empleando XGBoost, esta variante alcanzó una *Accuracy* de 0,7351 y un *F1-Score* de 0,6739 5.4. Este desempeño supera ligeramente a la versión del dataset "combinado", que registró un *F1-Score* de 0,6663, y al dataset basado únicamente en "códigos", que se situó en 0,6518 5.4. Esto sugiere que, al utilizar técnicas clásicas de extracción de características (basadas en *n-grams* de 1 a 2), el texto de las descripciones proporciona suficiente densidad informativa sin necesidad de los códigos estandarizados.
- **Hegemonía del algoritmo XGBoost en entornos completos:** En el escenario sin balancear ("Original"), la arquitectura XGBoost demostró ser consistentemente la opción más robusta para los tres conjuntos de datos (códigos, descripciones y combinado). Las configuraciones óptimas convergieron en parámetros conservadores, destacando una profundidad máxima (*max_depth*) de 5 a 7, tasas de aprendizaje entre 0,05 y 0,1, y un rango de 200 a 300 estimadores (*n_estimators*).

- **Predominio del algoritmo LightGBM en el escenario expandido con VAE:** Para la variante balanceada artificialmente mediante Autoencoders Variacionales (VAE), la arquitectura LightGBM demostró ser consistentemente la opción más adaptativa y robusta para las tres modalidades de entrada (códigos, descripciones y combinado). Esta hegemonía frente a los vectores de comorbilidades sintéticos se atribuye a su estrategia de crecimiento de árboles por hojas (*leaf-wise*) en lugar de por niveles (*level-wise*). Esta característica le otorga una flexibilidad matemática muy superior para trazar fronteras de decisión complejas e identificar patrones sutiles dentro del espacio latente continuo e interpolado que genera el VAE. Además, su óptima gestión de matrices dispersas y de alta dimensionalidad mitigó con éxito el riesgo de sobreajuste (*overfitting*) ante la replicación de las clases minoritarias, liderando el rendimiento tradicional con un *F1-Score* de 0,4400 para la entrada de códigos y de 0,3952 para la de descripciones clínicas.
- **Impacto del balanceo mediante *Undersampling*:** La aplicación de técnicas de submuestreo para balancear las clases provocó una degradación drástica en el rendimiento general de los modelos tradicionales. La reducción masiva de ejemplos en las clases mayoritarias restó capacidad de generalización a los árboles de decisión. Esto es especialmente notorio en el dataset de "códigos", donde el modelo LightGBM colapsó hasta alcanzar un *F1-Score* de 0,4393 y una precisión del 0,4405.
- **Resiliencia de la información combinada en escenarios empobrecidos:** Si bien el dataset "combinado" no fue el líder indiscutible en el conjunto original, demostró ser la estrategia más robusta frente a la drástica pérdida de datos ocasionada por el *undersampling*. En este escenario adverso, el modelo XGBoost entrenado con datos combinados logró retener el mayor poder predictivo del bloque, alcanzando un *F1-Score* de 0,5401, una precisión de 0,5370 y un *Recall* de 0,5759. Esto confirma que, cuando escasea el volumen de datos, la fusión de características tabulares (códigos) y textuales (descripciones) ayuda a estabilizar las fronteras de decisión.

La tabla 5.2 compara los resultados de cada uno de los modelos de aprendizaje tradicional según su *F1-Score*.




Figura 5.2: Grafico por columnas comparando los resultados de los modelos de aprendizaje tradicional segun su F1-Score.

5.3. Análisis de resultados

El análisis cuantitativo de los resultados obtenidos a lo largo de las distintas fases experimentales proporciona una perspectiva crítica de las capacidades y límites de la Inteligencia Artificial aplicada a la psiquiatría clínica. El estudio comparativo multicapa, estructurado sobre dos familias algorítmicas claramente diferenciadas, clasificadores tradicionales basados en ensamble de árboles (*Machine Learning*) y modelos de lenguaje basados en atención contextual bidireccional (*Deep Learning* con *Transformers*), revela dinámicas de aprendizaje complejas que varían de manera drástica según la técnica de balanceo aplicada y la modalidad de entrada seleccionada.

A continuación, se discuten los tres hallazgos cardinales que fundamentan la selección del modelo óptimo para el sistema de soporte propuesto.

5.3.1. Hegemonía del Enfoque Combinado y de los Modelos de Lenguaje en el Espacio Original

En el escenario base sin balancear (**Dataset Original**), que reproduce con fidelidad la distribución epidemiológica real del entorno hospitalario, se observa que

la integración semántica de códigos diagnósticos y descripciones clínicas en texto libre (entrada **Combinada**) alcanza el rendimiento óptimo global 5.1. La arquitectura especializada **BETO cased** lidera este bloque con un *F1-Score* de 0,6857 y una precisión general de 0,7285. Este comportamiento nos confirma que las descripciones narrativas en texto libre albergan matices semánticos que, al fusionarse con el contexto estructurado de los códigos de comorbilidades secundarias, proporcionan una firma diagnóstica mucho más robusta y tolerante al ruido textual, confirmando nuestra propuesta de una **Paradoja Multimodal** que propusimos en el estado del arte, siguiendo los estudios de Saboori Amleshi [9].

No obstante, la evaluación revela que los algoritmos tradicionales de *Machine Learning* representan una alternativa de extraordinaria solidez. El modelo **XGBoost** entrenado exclusivamente con las **Descripciones clínicas** 5.4 alcanzó una exactitud (*Accuracy*) de 0,7350 y un *F1-Score* de 0,6738, situándose a una diferencia marginal de apenas un 1,19% del mejor modelo profundo. Este hito demuestra que el texto de las descripciones procesado mediante técnicas clásicas de extracción de características (*n*-gramas) provee una alta densidad informativa por sí mismo, permitiendo a los árboles secuenciales de XGBoost trazar fronteras de decisión estables sin requerir costosos mapas vectoriales multidimensionales de *embeddings*.

5.3.2. El Colapso del Submuestreo (RUS) y la Resiliencia de la Entrada Combinada

La aplicación de técnicas de submuestreo aleatorio (**RUS**) para equiparar artificialmente las frecuencias de la variable objetivo provocó una degradación drástica en el rendimiento general de ambos paradigmas tecnológicos 5.5 5.2. Al reducir de manera agresiva la presencia de la clase mayoritaria (Esquizofrenia paranoide, F20), se sustrajo una parte fundamental de la variabilidad clínica y de las trayectorias de comorbilidad del histórico de pacientes, impidiendo que tanto las neuronas de BETO como las ramas de los árboles generalizaran correctamente.

Este colapso es especialmente visible en los modelos de lenguaje, donde las métricas de precisión se desplomaron por debajo del 30% 5.2, evidenciando que el mecanismo de auto-atención de los *Transformers* requiere corpus masivos y diversos para ajustar sus pesos de forma consistente. En el bloque tradicional, la reducción extrema de muestras provocó que el modelo de códigos basado en LightGBM colapsara hasta un *F1-Score* de 0,4393. Ante este escenario adverso de escasez de datos, la modalidad **Combinada** demostró ser la más resiliente y robusta, logrando estabilizar

las fronteras de decisión y retener un poder predictivo significativamente mayor que las variables aisladas, con un *F1-Score* de 0,5401 utilizando XGBoost 5.5.

5.3.3. La Reconstrucción con VAE y la Especialización de LightGBM

La inyección de muestras sintéticas en las clases minoritarias mediante el uso de redes generativas continuas (**VAE**) permitió estabilizar las fronteras de decisión y mitigar el sesgo hacia la clase mayoritaria sin incurrir en la pérdida de información que penaliza al submuestreo clásico. Sin embargo, este escenario expuso una clara divergencia en la compatibilidad de los algoritmos con los datos sintéticos:

- **La inadaptación de los Transformers al espacio latente continuo:**
Los modelos basados en BERT sufrieron una pérdida notable de rendimiento, registrando exactitudes por debajo del 37 % 5.3. Esto se debe a que la generación probabilística del VAE actúa a nivel de vectores de características matemáticas continuas, lo que altera las sutilezas morfosintácticas y la coherencia semántica del texto lineal que la capa del tokenizador de BERT necesita para realizar la codificación lingüística .
- **La hegemonía matemática de LightGBM frente a variables artificiales:**
Por el contrario, la arquitectura tradicional **LightGBM** se alzó como la ganadora indiscutible para las tres variantes de entrada en este escenario expandido 5.6. Este predominio se atribuye a su estrategia de crecimiento de árboles por hojas (*leaf-wise*), la cual le confiere una flexibilidad excepcional para segmentar el espacio latente continuo e interpolado que genera el VAE, trazando límites de división asimétricos sumamente precisos sin llegar a memorizar el ruido sintético ni incurrir en sobreajuste (*overfitting*).

5.4. Justificación de la Propuesta Final y Transferencia Tecnológica

Para consolidar un Sistema de Soporte a la Decisión Clínica (**CDSS**) que resulte verdaderamente viable y adoptable en la rutina asistencial del Servicio de Salud de Castilla y León (**SACYL**), el diseño del proyecto debe equilibrar con rigor la precisión teórica con el coste de implantación y la latencia del sistema.

Aunque la arquitectura profunda BETO Combinado entrenada sobre el conjunto original ofrece la métrica de *F1-Score* más elevada (0,6857), la ejecución de inferencias en tiempo real con modelos lingüísticos de cientos de millones de parámetros exige disponer de aceleración por hardware (GPU). Los terminales informáticos de las consultas psiquiátricas reales (que operan con clientes ligeros y sistemas de historia clínica como MEDORA) carecen de estos recursos de cómputo. Ejecutar dichos modelos en CPU generaría una latencia de respuesta inasumible en la práctica clínica diaria, vulnerando los requisitos no funcionales de usabilidad y rendimiento del sistema.

Por lo tanto, la **Propuesta Final** de este trabajo se decanta por el uso de los clasificadores basados en ensamble de árboles (**XGBoost** y **LightGBM**) entrenados sobre el dataset balanceado sintéticamente con **VAE**. Esta arquitectura híbrida garantiza:

1. **Robustez frente al desbalanceo extremo:** Protegiendo la capacidad de detección de patologías críticas de baja frecuencia (como F21) mediante un espacio de clases perfectamente balanceado.
2. **Inferencia ultrarrápida y local:** Reduciendo la latencia a milisegundos sin requerir GPUs ni conexión asíncrona a servidores externos, facilitando su encapsulamiento nativo y modular en la interfaz ágil de Streamlit desarrollada.
3. **Interpretabilidad Relacional Directa:** Sustentando la probabilidad matemática del predictor tabular con la inspección visual de las comorbilidades activas en el grafo de Neo4j.

En síntesis, las métricas del proyecto confirman que el uso complementario de grafos de conocimiento y clasificadores tabulares tradicionales constituye la opción de ingeniería más solvente, económica y viable para la modernización tecnológica del diagnóstico de la esquizofrenia en entornos hospitalarios reales.

Al marcar los modelos que han mostrado el mayor potencial y las mejores métricas, las figuras 5.3 y 5.4 nos muestran la evolución del entrenamiento de los 2 modelos que más han destacado por sus resultados mediante una curva ROC. Los modelos son el BETO-cased en el dataset desbalanceado combinado y el clasificador LIGHTBGM para el dataset sintético por códigos, respectivamente.




Figura 5.3: Curva ROC para el modelo BETO-cased en el dataset desbalanceado combinado

5.5. Estudio de grafos

A continuación, se presentan los hallazgos derivados de la aplicación de algoritmos de detección de comunidades y de centralidad sobre la red relacional, para ofrecer una perspectiva topológica de la salud mental de la muestra de Castilla y León.

5.5.1. Análisis de Comunidades

La detección de comunidades se ejecutó aplicando el **algoritmo de Louvain**, un algoritmo heurístico que agrupa de forma iterativa los nodos con una alta densidad de conexión interna. La elección de este método se fundamenta en su consolidación en el estado del arte como el algoritmo de optimización de modularidad óptimo para el modelado relacional en bases de datos de salud orientadas a grafos, permitiendo segregar con total precisión computacional los perfiles de comorbilidades concurrentes sin requerir la inyección de sesgos manuales de agrupamiento previo [21, 22]. El resultado de este análisis se visualiza en la Figura 5.5, donde la red general se divide en clústeres diferenciados por gradientes cromáticos.




Figura 5.4: Curva ROC para el clasificador ROC en el dataset sintético por codigos

La alta modularidad de la red confirma que las comorbilidades asociadas a los trastornos del espectro esquizofrénico no se distribuyen de manera aleatoria en la población. Por el contrario, se estructuran en módulos clínicos bien definidos:

- **Módulo Psiquiátrico Nuclear (Espectro Psicótico):** Concentra las distintas variantes de la esquizofrenia (F20.0, F20.1, F20.3) y trastornos delirantes o esquizoafectivos (F22, F25), evidenciando la proximidad diagnóstica y la continuidad de síntomas dentro del propio espectro.
- **Módulo de Patología Somática y de Conducta:** Agrupa enfermedades físicas crónicas y hábitos nocivos que suelen coexistir con el trastorno mental severo, como enfermedades cardiovasculares, respiratorias y metabólicas.

Para facilitar la interpretación médica y eliminar el ruido relacional de la red total, se generó un filtro topológico para conservar únicamente aquellos diagnósticos con más de dos conexiones 5.6. Esta simplificación permite al personal médico identificar los núcleos comórbidos más estables y recurrentes, aislando conexiones esporádicas o anecdóticas dentro del histórico de 12 años analizado.



Figura 5.5: Mapa de comunidades de diagnosticos general.




Figura 5.6: Mapa de comunidades de diagnosticos con mas 2 conexiones.

5.5.2. Análisis de Centralidad y Comorbilidades

Para identificar los diagnósticos que actúan como "puentes" en el historial de los pacientes, se evaluó la red mediante métricas de centralidad, centrándose en el grado de conexión (*Degree Centrality*) y la intermediación (*Betweenness Centrality*). La Figura 5.7 ilustra con claridad este fenómeno relacional, filtrando por los diagnósticos con más de 50 apariciones en el dataset.

Siguiendo su relevancia y centralidad, los nodos que representan variantes de la esquizofrenia aparecen con el color rojo, siendo los puntos principales del grafo.

Aunque a la vez los nodos azules, asociados a los diagnósticos secundarios, nos aportan información y conexiones de gran valor clínico:

1. **El Síndrome Metabólico como comorbilidad física dominante:** Se observa una fuerte adyacencia y aristas gruesas que conectan la *Esquizofrenia paranoide* y *Otros tipos de esquizofrenia* con la *Hipertensión esencial*, la *Diabetes mellitus tipo 2* y la *Hipercolesterolemia pura*. Este hallazgo topológico nos confirma que los pacientes con esquizofrenia presentan un riesgo metabólico drásticamente elevado, inducido tanto por el estilo de vida como por los efectos adversos de los fármacos antipsicóticos atípicos suministrados a los pacientes, corroborando empíricamente la teoría de la medicina de redes analizada en el estado del arte [1, 20].
2. **La alta prevalencia de trastornos por uso de sustancias (TUS):** El nodo de *Dependencia de nicotina* y el *Abuso de alcohol* presentan una centralidad de intermediación crítica, actuando como puentes de conexión relacional entre los clústeres psiquiátricos y las patologías pulmonares o hepáticas. El *Abuso de cannabis* también se muestra estrechamente conectado a los núcleos psicóticos activos, sugiriendo su rol como catalizador o factor desencadenante de brotes agudos.
3. **Factores Psicosociales y de Apoyo:** Nodos como *Problemas relacionados con el apoyo social y el entorno* e *Incumplimiento del tratamiento* demuestran una alta intermediación. Topológicamente, actúan como conectores entre las variantes graves del trastorno y las recaídas hospitalarias, subrayando la importancia de un enfoque terapéutico que trascienda lo puramente farmacológico.

5.6. Estudio de mapas

El estudio en profundidad de comunidades y mapas se centro en la identificación de patrones geoespaciales y la segmentación territorial de los diagnósticos psiquiátricos. Para ello, se han empleado técnicas de análisis de redes y visualización geográfica para comprender cómo se distribuyen las patologías del espectro esquizofrénico en la provincia de León, junto a la elaboración de hipótesis sobre los factores que influyen en su distribución.




Figura 5.7: Mapa de centralidad de diagnosticos con mas de 50 apariciones.

5.6.1. Segmentación Geográfica mediante K-Means

Para el correcto desempeño del algoritmo K-Means, las variables diagnósticas fueron estandarizadas mediante *StandardScaler*:

$$z = \frac{x - \mu}{\sigma} \quad (5.1)$$

Donde x es la frecuencia del diagnóstico, μ la media poblacional y σ la desviación estándar. Esta transformación es imprescindible para evitar que las patologías de alta frecuencia dominen el cálculo de la distancia euclidiana sobre diagnósticos menos comunes pero clínicamente relevantes. La determinación del número de clústeres óptimo se realizó mediante el **Método del Codo** (*Elbow Method*), evaluando la inercia o suma de cuadrados intra-clúster (*SSE*):

$$SSE = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2 \quad (5.2)$$




Figura 5.8: Curva de Inercia para la Determinación del Número Óptimo de Clústeres.

Como se observa en la curva de inercia, el punto de inflexión decisivo se sitúa en $K = 4$. A partir de dicho valor, las reducciones en la inercia resultan marginales, garantizando un modelo con alta parsimonia y máxima capacidad explicativa.

5.6.2. Análisis de Dominancia Clínica

Para evaluar la "identidad clínica" de cada código postal independientemente del volumen poblacional, se identificó la patología predominante mediante la función de argumento máximo:

$$\text{Patología Predominante}_i = \arg \max_j (\text{Frecuencia}_{i,j}) \quad (5.3)$$

Los resultados muestran una especialización espacial marcada dentro del mapa urbano: ciertos códigos postales presentan una clara hegemonía de diagnósticos del espectro de la esquizofrenia ($F20$), mientras que en barrios contiguos el perfil virante hacia trastornos delirantes ($F22$) o esquizoafectivos ($F25$). Esta segregación diagnóstica sugiere la influencia de determinantes ambientales locales o diferencias en los criterios de derivación asistencial, como podemos observar en la figura 5.9.




Figura 5.9: Mapa de Dominancia Clínica de Códigos Postales.

5.6.3. Índice de Comorbilidad y Complejidad Asistencial

Se definió el **Índice de Comorbilidad Media** ($\bar{C}_{CP}$) por código postal a partir de la suma de diagnósticos secundarios activos:

$$\bar{C}_{CP} = \frac{1}{N_{CP}} \sum_{k=1}^{N_{CP}} \left(\sum_{m=2}^{20} \mathbb{I}(\text{Diag}_{m,k}) \right) \quad (5.4)$$

Donde N_{CP} es el número de pacientes en el código postal y $\mathbb{I}$ es una función indicadora que adopta el valor 1 si existe un diagnóstico secundario registrado y 0 en caso contrario.

Identificación de Zonas Frágiles

El mapa de comorbilidad permite cartografiar la **carga real de cuidados** en cada micro-área geográfica, donde se identificaron códigos postales con medias superiores a 4.5 diagnósticos secundarios por paciente. Estas "zonas calientes" señalan comunidades con un alto grado de cronicidad y fragilidad física/mental simultánea, requiriendo un abordaje asistencial intensivo y multidisciplinar por parte de los servicios sanitarios.




Figura 5.10: Mapa de Comorbilidad Media por Código Postal.

5.6.4. Efecto de Proximidad y Sesgo de Detección

Se contempla la hipótesis del **s sesgo de detección geográfico**: la cercanía física a centros asistenciales de referencia (como el Complejo Asistencial Universitario de León u Hospital HM Regla) incrementa la tasa de diagnóstico capturada. Este fenómeno no implica necesariamente una mayor morbilidad real, sino una mayor tasa de contacto con el sistema sanitario.

5.6.5. Hallazgo Principal: El Contraste Urbano-Rural

Los resultados cartográficos revelan un patrón estructural claro:

- **Entorno Rural (Homogeneidad territorial):** La práctica totalidad de la provincia queda subsumida en un único clúster predominante. Este grupo refleja una baja frecuencia absoluta de diagnósticos específicos registrados, lo cual sugiere dos posibles explicaciones: la dispersión poblacional o la existencia de barreras de acceso al diagnóstico especializado.




Figura 5.11: Mapa de clústeres geográficos.

- **Entorno Urbano (Segregación en León Capital):** En el núcleo urbano de la capital convergen la totalidad de los 4 clústeres identificados. Esto demuestra que la densidad poblacional fragmenta el perfil de atención de la salud mental en micro-áreas diferenciadas.

5.7. Conversión de códigos

Uno de los resultados más relevantes y diferenciadores de este trabajo, más allá del ámbito estrictamente predictivo, ha sido la construcción y validación de un recurso de datos estructurado para la conversión y correspondencia bidireccional entre las codificaciones CIE-9 y CIE-10 (*ICD-9-CM* e *ICD-10-CM*) adaptado íntegramente al contexto clínico en español.

Durante la fase de revisión del estado del arte e inspección de recursos disponibles, se identificó una clara fragmentación en el ecosistema actual. Por un lado, los portales oficiales, como el motor de búsqueda del Ministerio de Sanidad de España, están concebidos exclusivamente para consultas puntuales e individualizadas a través de

interfaces web, lo que impide su integración directa en analítica masiva de datos. Por otro lado, aunque existen en la literatura y repositorios abiertos diversos recursos de mapeo, como pueden ser la especificación oficial de equivalencias de la CMS (*Centers for Medicare & Medicaid Services*) [39], las tablas cruzadas del NBER [40], archivos de mapeo histórico [41], repositorios comunitarios en GitHub [42–44] o conjuntos de datos aislados en Hugging Face [45], todos ellos presentan limitaciones críticas como:

- Se encuentran orientados de forma casi exclusiva al idioma inglés.
- Aparecen incompletos, fragmentados, desactualizados o limitados a un subconjunto específico de patologías.
- Carecen de una estructura unificada, limpia e interoperable lista para su ingesta en entornos modernos de ciencia de datos.

El recurso público más extenso y prometedor localizado en español fue el dataset alojado en Hugging Face por Martín García [45], el cual destacaba por incluir las descripciones diagnósticas nativas en castellano y un volumen amplio de registros. Sin embargo, este archivo presentaba serias limitaciones técnicas para su uso directo: carecía de una estructura tabular limpia, contenía inconsistencias de formato, errores de parseo y vacíos en las equivalencias normativas entre ambas versiones del CIE. Para arreglar estos fallos, se procedió a una depuración y reestructuración inicial del dataset, saneando los errores de codificación de texto y normalizando su formato, combinandolo e integrandolo con el resto de recursos publicos disponibles [39–44].

El dataset resultante, se ha estructurado en un formato tabular de 3 columnas y 108054 filas, donde cada fila representa una correspondencia única entre códigos de ambas normativas. Las columnas incluyen:

- **Mapeo bidireccional estructurado:** Correspondencia directa entre códigos tridimensionales y específicos de la CIE-9 y la CIE-10.
- **Estandarización lingüística:** Integración de las descripciones diagnósticas oficiales en español, facilitando la traducción semántica del texto libre a códigos estandarizados o viceversa.
- **Optimización para procesamiento masivo:** Estructura optimizada para su carga en memoria en entornos de ciencia de datos (*Dataframes*) o su ingesta en bases de datos relacionales y de grafos.

Este dataset universal nos da 2 aplicaciones muy importantes:

1. **Transferencia tecnológica e integración en *software*:** Este conjunto de datos ha constituido el motor lógico sobre el que se programó el módulo conversor y la principal función de la herramienta web en **Streamlit**. Esto permite sustituir la búsqueda manual y fragmentada en repositorios web por una consulta automatizada e instantánea, integrable en flujos de trabajo clínico.
2. **Recurso reutilizable para la comunidad científica y médica:** El dataset resultante sirve mas alla del proposito de esta investigacion, constituyendo un artefacto independiente e universal listo para ser aprovechado por investigadores y profesionales sanitarios para la migración automatizada de conjuntos de datos históricos sin riesgo de inconsistencias semánticas.

Capítulo 6

Aplicación desarrollada

6.1. Ecosistema Tecnológico Integrado y Flujo de Datos

Para comprender el alcance práctico de esta investigación y la base en la que se sustenta la aplicación web, es preciso analizar cómo interactúan y se retroalimentan las múltiples tecnologías evaluadas a lo largo del proyecto. En lugar de concebir el resultado como un sistema de producción monolítico y cerrado, este trabajo se consolida como un **ecosistema experimental interconectado**. En él, cada herramienta de software y modelo matemático asume un rol específico para transformar un registro clínico plano en una estructura de conocimiento interpretable.

La Figura 6.1 ilustra este mapa de sinergia tecnológica, estructurado en cuatro niveles de abstracción que guían el recorrido del dato clínico desde su ingesta hasta su explotación visual:

1. **Capa de Datos y Persistencia:** Constituye los cimientos del estudio. Aquí coexisten los ficheros estructurados (el *dataset* original de 3134 registros de Castilla y León, junto a sus variantes, el recurso unificado de traducción semántica de 108.054 correspondencias ICD) junto con la base de datos relacional **Neo4j** y el almacén físico de modelos entrenado.
2. **Capa de Inteligencia Artificial e Inferencia:** Es el núcleo predictivo del flujo. Representa la fase experimental donde las técnicas de balanceo sintético (**VAE**) alimentan los clasificadores de aprendizaje automático tradicional (como




Figura 6.1: Mapa de sinergia tecnológica y flujo de información del proyecto.

LightGBM, **XGBoost** o **RandomForest**) y donde se evalúa el potencial semántico de los modelos basados en *Transformers* (como **BETO** o **roBERTa**).

3. **Capa de Lógica de Negocio y Entorno (Backend)**: Actúa como el motor del ecosistema, programado íntegramente en **Python**. Este nivel gestiona de manera determinista las dependencias de bajo nivel mediante entornos aislados en **Mamba**, canaliza el *pipeline* de limpieza y preprocesamiento de variables, y orquesta las consultas en lenguaje **Cypher** hacia el servidor de grafos de Neo4j.
4. **Capa de Presentación e Interacción (Frontend)**: Representado por la interfaz ligera construida en **Streamlit**. Este nivel nos permite unificar y dar representación a 3 de los hitos mas importantes de este trabajo en forma de un conversor de códigos ICD individual y por lotes (interoperabilidad semántica), la renderización de la conectividad de comorbilidades (analítica de grafos con Pyvis) y la representación de la dominancia patológica provincial (visualización cartográfica interactiva con Folium).

Este enfoque modular y desacoplado garantiza que, aunque se trate de tecnologías con naturalezas de diseño radicalmente distintas (bases de datos NoSQL, clasificadores tabulares y modelos de lenguaje profundos), todas ellas cooperen de forma armónica para aportar valor al campo de estudio clínico.

6.2. Objetivo y Visualización

El módulo de visualización de la aplicación se ha diseñado bajo el principio de simplicidad y eficiencia en la interfaz de usuario (*UI/UX*). El objetivo principal es evitar la sobrecarga cognitiva del personal sanitario, transformando los resultados numéricos de los modelos predictivos y las consultas complejas a la base de datos de grafos en representaciones visuales intuitivas y directamente interpretables durante la práctica clínica.

Esta decisión de desarrollar una plataforma web propia responde a las severas limitaciones que presentan las herramientas de conversión y consulta disponibles actualmente en el internet. Frente a estas carencias, la aplicación web desarrollada en **Streamlit** consolida en un único entorno centralizado tres pilares funcionales:

1. **Procesamiento por lotes e instantáneo**: Permite la conversión individual y masiva entre CIE-9 y CIE-10 en castellano sin restricciones de volumen ni publicidad.

2. **Exploración gráfica de comorbilidades y mapas de estudio:** Renderiza de forma interactiva las redes relacionales almacenadas en Neo4j y mapas de frecuencias, permitiendo al clínico navegar visualmente por las asociaciones entre diagnósticos o estudiar la distribución de diagnósticos.
3. **Consulta de diagnósticos:** Fácil visualización de las distintas formas y lenguajes con los que se pueden representar diagnósticos clínicos.

6.3. Requisitos

Para garantizar un desarrollo de software riguroso y alineado con las metodologías ágiles de ingeniería, la herramienta web desarrollada en **Streamlit** se ha diseñado siguiendo unas especificaciones y requisitos a cumplir, recopilados entre Requisitos Funcionales (RF), Requisitos No Funcionales (RNF) y las Historias de Usuario (HU) asociadas.

6.3.1. Requisitos Funcionales

6.3.2. Requisitos No Funcionales

6.3.3. Historias de Usuario

6.4. Elementos de la interfaz y paneles de datos

Mi aplicación web centra su potencial visual en la estructuración limpia de formularios de texto, tablas de datos dinámicas y paneles interactivos. Dado que el objetivo primordial del sistema es la conversión ágil de códigos ICD y la clasificación semántica en tiempo real, el diseño da prioridad absoluta al texto y a la legibilidad de los diagnósticos frente a las representaciones gráficas convencionales.

Como ejemplo de la sencillez y facilidad de uso de la web, la interfaz de usuario en la pestaña de Buscador Individual se articula en torno a dos bloques visuales fundamentales que constan de un campo de texto libre optimizado donde el facultativo introduce la descripción clínica o el diagnóstico en lenguaje natural. Visualmente, el sistema responde de forma síncrona, eliminando elementos distractores y presentando el resultado del conversor ICD-9 a ICD-10 de manera jerárquica mediante cajas de texto contrastadas, permitiendo una validación visual inmediata.

Código	Descripción del Requisito Funcional (RF)
RF-01	Búsqueda polivalente individual: El sistema debe permitir la consulta de diagnósticos mediante tres criterios de entrada conmutables: código CIE-10, código CIE-9 o descripción textual libre en castellano.
RF-02	Sugerencias dinámicas y autocompletado: La interfaz de búsqueda debe pre-filtrar y mostrar un listado de sugerencias según lo escrito en la búsqueda por el usuario, mitigando errores tipográficos manuales.
RF-03	Mapeo relacional de correspondencias: Al seleccionar un diagnóstico, el sistema debe recuperar y presentar de forma estructurada todas sus equivalencias de forma bidireccional.
RF-04	Consulta asíncrona internacional: El sistema debe incorporar un botón para realizar peticiones asíncronas a la API externa de la <i>National Library of Medicine</i> y recuperar la descripción oficial en inglés del diagnóstico seleccionado.
RF-05	Ingesta de archivos por lotes: El sistema debe permitir al usuario arrastrar y cargar ficheros estructurados en formato CSV para su traducción masiva.
RF-07	Parametrización dinámica del mapeo: El usuario debe poder seleccionar dinámicamente qué columna del CSV contiene los datos, su formato de origen y qué nuevas columnas de mapeo (CIE-9, CIE-10, inglés o castellano) desea añadir al archivo resultante.
RF-08	Exportación persistente de informes: El sistema debe habilitar un botón de descarga para persistir la tabla resultante del procesamiento masivo en un archivo CSV local codificado en UTF-8
RF-09	Renderizado interactivo de mapas y redes: El sistema debe encapsular y renderizar mapas coropléticos (Folium) y grafos de comunidades (Pyvis) interactivos en contenedores web, soportando acciones de zoom, arrastre y burbujas informativas.

Tabla 6.1: Catálogo de Requisitos Funcionales del sistema.

Código	Descripción del Requisito No Funcional (RNF)
RNF-01	Tiempo de respuesta y latencia: El tiempo de inferencia del buscador individual no superará los 3 segundos; el procesamiento por lotes no excederá los 30 segundos para archivos de hasta 10.000 registros; y la carga de mapas interactivos no superará los 15 segundos en CPU local.
RNF-02	Navegación plana (UI/UX): La interfaz web debe cumplir con el paradigma de jerarquía plana, permitiendo conmutar entre los módulos principales (conversor individual, por lotes y mapas) con un máximo de dos clics.
RNF-03	Usabilidad (UX/UI): La interfaz debe ser intuitiva, accesible desde navegadores web convencionales y no requerir conocimientos de programación por parte del clínico.
RNF-04	Privacidad y seguridad por diseño (RGPD): La aplicación operará estrictamente sobre datos anonimizados sin persistir información personal identificativa (como IP, nombres, etc.) de forma local o en bases de datos temporales.
RNF-05	Tolerancia a fallos de red: Si la API externa de la NLM no está disponible o presenta un retardo superior a 5 segundos, el sistema debe capturar el error sin colapsar la interfaz, notificando al clínico y deshabilitando temporalmente dicha opción de traducción.
RNF-06	Portabilidad y despliegue modular: El backend debe estar desarrollado de forma modular en Python, permitiendo su encapsulamiento y despliegue inmediato en la intranet hospitalaria mediante contenedores Docker.
RNF-07	Interoperabilidad y Portabilidad: El backend debe basarse en formatos abiertos y estándar (CSV, GeoJSON, ejecutable de Python).

Tabla 6.2: Catálogo de Requisitos No Funcionales del sistema.

Código: HU-01	Título: Conversión e Interoperabilidad CIE-9 / CIE-10
Rol del usuario	Personal Administrativo / Clínico.
Descripción	Como usuario del sistema, quiero consultar la equivalencia exacta entre códigos históricos CIE-9 y modernos CIE-10, utilizando autocompletado y traducciones internacionales en inglés, para agilizar el flujo de documentación médica
Prioridad	Alta.
Dependencias	RF-01, RF-02, RF-03, RF-04, RNF-01, RNF-02, RNF-05, RNF-07.
Criterios de Aceptación	■ CA-1.1: El módulo debe permitir búsquedas bidireccionales por código o por texto descriptivo. ■ CA-1.2: Debe mostrarse de forma clara la correspondencia oficial y su descripción en español, en tarjetas de alto contraste. ■ CA-1.3: El botón de consulta asíncrona a la API de la NLM debe recuperar la descripción oficial en inglés en menos de 3 segundos. ■ CA-1.4: El buscador interactivo debe tolerar errores tipográficos mediante un listado síncrono de sugerencias dinámicas a medida que se escribe.

Tabla 6.3: Especificación de la Historia de Usuario HU-01: Mapeo CIE.




Figura 6.2: Diseño de la interfaz principal de la aplicación: panel de conversión de códigos e histórico de registros.

Código: HU-02	Título: Análisis Espacial e Inspección Cartográfica
Rol del usuario	Epidemiólogo / Investigador.
Descripción	Como epidemiólogo, quiero explorar mapas coropléticos interactivos y grafos relacionales de comunidades para estudiar la dominancia y la cronicidad compleja de los trastornos del espectro esquizofrénico en Castilla y León.
Prioridad	Media.
Dependencias	RF-09, RF-10, RNF-01, RNF-02, RNF-06
Criterios de Aceptación	■ CA-2.1: El mapa coroplético debe renderizar un gradiente de color proporcional a la frecuencia de casos sobre la geometría. ■ CA-2.2: Al pasar el cursor sobre un código postal, debe mostrarse el número de afectados o datos sobre la zona. ■ CA-2.3: El visor debe permitir hacer zoom y desplazamiento fluido por todo el territorio. ■ CA-2.4: El sistema debe detectar automáticamente cualquier nuevo archivo interactivo HTML guardado en el servidor para actualizar el panel de acceso rápido sin requerir alteraciones en el código fuente de Streamlit.

Tabla 6.4: Especificación de la Historia de Usuario HU-02: Análisis Espacial.

6.5. Navegación

La arquitectura de navegación de la aplicación web se ha concebido bajo el paradigma de jerarquía plana, minimizando la profundidad de los menús para reducir drásticamente el número de interacciones necesarias para obtener la información. En el entorno de una consulta psiquiátrica real, la eficiencia temporal y la simpleza es crítica; por lo tanto, el flujo de usuario se ha modelado para ser lineal, rápido y completamente libre de distracciones.

El recorrido del profesional médico a través de la herramienta sigue una secuencia lógica que emula su propio proceso clínico:

1. **Punto de entrada y selección contextual:** Mediante un menú de navegación simplificado (ubicado en una barra superior), el facultativo puede alternar de manera instantánea entre las funcionalidades principales del sistema (como el conversor de códigos ICD individual o el conversor de archivos), sin necesidad de recargar la plataforma ni perder el contexto de la sesión.

Código: HU-03	Título: Exportación de Códigos Convertidos CIE-9 a CIE-10
Rol del usuario	Facultativo / Gestor de Datos Clínicos.
Descripción	Como gestor de datos, quiero cargar archivos masivos de diagnósticos para automatizar su traducción semántica e interoperabilidad documental, descargando de forma segura los resultados en un archivo estructurado independiente.
Prioridad	Alta.
Dependencias	RF-05, RF-06, RF-07, RF-08, RNF-01, RNF-02, RNF-03, RNF-07
Criterios de Aceptación	■ CA-3.1: La interfaz debe incorporar un botón visible que permita la descarga directa de la tabla de resultados en formato estandarizado <code>.csv</code>, sin tener que recargar la página web ni exponer datos. ■ CA-3.2: El usuario debe poder mapear dinámicamente qué columnas desea traducir, el formato de entrada, y qué atributos adicionales desea inyectar al archivo final procesado. ■ CA-3.3: El archivo descargado debe incluir correctamente las columnas mapeadas que se han seleccionado, respetando la codificación UTF-8 para evitar errores en caracteres especiales. ■ CA-3.4: La interfaz debe habilitar un área de arrastre (<i>Drag & Drop</i>) que valide de forma asíncrona la estructura del CSV, renderizando una vista previa estricta de las primeras 5 filas para verificación del usuario

Tabla 6.5: Especificación de la Historia de Usuario HU-03: Exportación de Códigos Convertidos por Lotes.

2. **Introducción directa de parámetros:** Al acceder al módulo deseado, el centro de la pantalla presenta de forma exclusiva los campos de entrada de texto, para el conversor individual, o de archivos, para el conversor por lotes. o la selección de figuras, en el visualizador. Esta ausencia de submenús obliga al sistema a guiar visualmente al usuario hacia la acción principal: introducir la descripción clínica/código de diagnóstico del paciente o el archivo que se desea convertir.
3. **Despliegue dinámico de resultados:** Una vez ejecutada la consulta, la navegación evita deliberadamente el uso de ventanas emergentes (*pop-ups*) o redirecciones a nuevas páginas.

Este diseño de un solo nivel garantiza que cualquier miembro del personal sanitario, independientemente de su grado de alfabetización digital, pueda asimilar el manejo de la herramienta en apenas unos minutos, manteniendo su atención focalizada en el diagnóstico del paciente y no en el uso del *software*.

Por otro lado, cuando el usuario conmuta la interfaz hacia la pestaña de *Conversor por Lotes*, la arquitectura de la aplicación cambia hacia un modelo de flujo de trabajo guiado por estados secuenciales (*State-driven Workflow*). Este diseño impide que el usuario cometa errores de configuración al bloquear las opciones avanzadas hasta que se verifiquen con éxito los pasos previos:

6.6. Accesibilidad de la aplicación

La accesibilidad de la plataforma se ha planteado desde una perspectiva práctica y funcional, adaptando los criterios estándar de diseño web a las necesidades específicas del entorno clínico hospitalario. Siguiendo las directrices de simplicidad establecidas en las secciones previas, la accesibilidad de la aplicación no se basa en menús de configuración complejos, sino en un diseño nativamente inclusivo que reduce las barreras de uso para todo el personal sanitario.

Este enfoque se consolida a través de tres pilares fundamentales de diseño:

- **Legibilidad y contraste visual adaptativo:** Conscientes de que los terminales informáticos de las consultas médicas presentan una gran variabilidad en la calidad de sus pantallas y condiciones de iluminación, la interfaz utiliza una paleta de colores de alto contraste. Las fuentes tipográficas y los tamaños de los elementos textuales se han seleccionado para permitir un escaneo visual rápido, asegurando que los códigos de diagnóstico y los textos




Figura 6.3: Diagrama de flujo de la aplicación web, mostrando la secuencia de interacción del usuario desde la selección de funcionalidad hasta la obtención de resultados.

clínicos sean legibles sin provocar fatiga ocular durante jornadas laborales prolongadas.

- **Accesibilidad semántica mediante estándares clínicos:** La mayor barrera de accesibilidad en el software médico suele ser la falta de familiaridad con la interfaz. Esta aplicación mitiga dicho problema integrando de forma nativa los estándares de codificación *International Classification of Diseases* (ICD-9 e ICD-10). Al estructurar la entrada y salida de datos bajo la misma nomenclatura internacional que los psiquiatras utilizan diariamente en sus informes, el sistema resulta inmediatamente comprensible y accesible desde el primer uso, eliminando la necesidad de formación técnica previa.
- **Eficiencia y ligereza tecnológica:** Al estar construida sobre un marco de trabajo web ágil, la aplicación prescinde de animaciones pesadas o elementos flotantes que dificulten la navegación a usuarios con habilidades digitales básicas. Esta ligereza técnica asegura también que la plataforma sea accesible desde ordenadores antiguos o clientes ligeros (*thin clients*) integrados en la red hospitalaria local, garantizando un tiempo de respuesta rápido e independiente de las capacidades del *hardware* del puesto de trabajo.

6.7. Conversor de ICD

El módulo denominado «Conversor y Buscador de Diagnósticos» constituye el núcleo operativo de la interfaz de usuario. Su propósito principal es resolver la brecha de interoperabilidad semántica existente entre los sistemas de registro históricos (basados en la clasificación ICD-9) y los estándares de codificación modernos (ICD-10), proporcionando un entorno de traducción simétrica y consulta ágil para el facultativo.

Tal y como se observa en el diseño implementado (véase la Figura 6.4), el módulo se despliega en dos modalidades de trabajo primarias: un *Buscador Individual* para consultas en tiempo real durante la consulta clínica, y un *Conversor por Lotes* orientado al procesamiento masivo de historiales.

Las características funcionales clave integradas en este panel son las siguientes:

- **Flexibilidad de entrada multidireccional:** El sistema rompe la rigidez de los buscadores clínicos tradicionales al permitir al psiquiatra conmutar el criterio de búsqueda entre tres variantes: código ICD-10, código ICD-9 o descripción textual en lenguaje natural. Un motor de sugerencias dinámico

filtra los registros del *dataset* curado a medida que el usuario escribe, mitigando errores tipográficos.

- **Mapecto relacional de correspondencias:** Al seleccionar un diagnóstico específico —como, por ejemplo, la *Esquizofrenia paranoide* (F20.0)—, la aplicación realiza una consulta indexada y presenta los resultados estructurados en tres tarjetas de datos diferenciadas por contraste cromático. Este panel revela visualmente la relación de correspondencia compleja (de uno a muchos) entre el estándar actual y el histórico, listando todos los códigos ICD-9 asociados (como 295.30 a 295.35).
- **Interoperabilidad internacional vía API externa:** Como característica de valor añadido, la interfaz incorpora un mecanismo de consulta externa integrado con la API de la *National Library of Medicine* (NLM) [46] de los Estados Unidos. Mediante un evento de activación asíncrono, el facultativo puede recuperar la descripción clínica oficializada en lengua inglesa, expandiendo la utilidad de la herramienta hacia entornos de investigación internacional o codificación cruzada global.

Conversor y Buscador de Diagnósticos (ICD-9 / ICD-10)

Buscador Individual Conversor por Lotes Mapas de Investigación

Búsqueda y Traducción de Diagnósticos

Buscar a partir de:

☒ ICD10 ☐ ICD9 ☐ Descripción

Escribe el ICD10 (o una parte) para buscar:

F20.0

Sugerencias encontradas (Selecciona una):

F20.0

Datos del Diagnóstico

ICD-9 Asociado(s): • 295.35 • 295.34 • 295.33 • 295.30 • 295.31 • 295.32	ICD-10 Asociado(s): • F20.0	Descripción (Español): • Esquizofrenia paranoide
--	---------------------------------------	--

Obtener descripción en Inglés (API NLM)

Figura 6.4: Módulo del Conversor Individual: interfaz de búsqueda polivalente y panel de resultados de correspondencias ICD-9/ICD-10.

6.8. Procesamiento masivo y automatización por lotes

La segunda funcionalidad de la herramienta es el módulo de procesamiento masivo, diseñado específicamente para dar respuesta a flujos de trabajo orientados a la investigación epidemiológica o a la migración a gran escala de bases de datos hospitalarias locales. Esta funcionalidad traslada la lógica de traducción semántica individualizada a un motor de transformación de conjuntos de datos tabulares en memoria.

Las características arquitectónicas y funcionamiento que definen este panel se desglosan a continuación:

1. **Fase de Ingesta e Inspección Estructural: 6.5** El flujo se inicia en un componente de arrastre de archivos (*Drag and Drop*) optimizado para archivos CSV, proporcionado por Streamlit. Tras la carga del fichero por parte del usuario, el sistema realiza de forma asíncrona un *parsing* primario y renderiza una previsualización interactiva limitada a las primeras 5 filas. Esto permite al facultativo comprobar visualmente si la estructura del archivo cargado coincide con sus expectativas antes de iniciar cualquier cómputo.
2. **Fase de Parametrización Dinámica: 6.6** Una vez validada la presencia del archivo, la interfaz desbloquea dinámicamente el panel de «Configuración de la conversión». En este punto, la navegación es puramente selectiva: el sistema lee las cabeceras del CSV original y rellena automáticamente un menú desplegable para que el usuario elija qué columna exacta contiene los datos a convertir, el formato de origen (ICD-9, ICD-10 o descripción) y las conversiones deseadas para el conjunto de datos resultante (códigos cruzados, descripciones en castellano o descripciones internacionales).
3. **Ejecución, Validación y Persistencia 6.7:** Tras presionar el botón de procesamiento, el sistema ejecuta las transformaciones en segundo plano, notificando el éxito de la operación mediante una alerta visual integrada de éxito. Finalmente, el flujo concluye revelando una tabla de resultados enriquecida y habilitando de forma síncrona el botón de descarga, cerrando el ciclo de vida del dato dentro de la sesión web sin provocar interrupciones en la pantalla principal.



Figura 6.5: Módulo del Conversor por Lotes: interfaz de carga de archivos




Figura 6.6: Módulo del Conversor por Lotes: Panel de previsualización de datos cargados y selección de criterios de conversión.




Figura 6.7: Módulo del Conversor por Lotes: Resultados de la conversión seleccionada, con opción de descarga en formato CSV.

6.9. Visualizador de Mapas

Este modulo constituye la herramienta de exploración analítica y representación gráfica de los multiples mapas y graficos generados durante la investigacion de este trabajo, mediante un entorno interactivo que facilita el estudio de estas figuras.

Como se observa en la captura 6.8, la interfaz se estructura en una seccion principal de un panel superior de selección de mapas a visualizar configurado mediante una cuadrícula adaptativa de botones de acceso rápido. Bajo de este se renderizara los modelos espaciales y relacionales en un contenedor.

Las características funcionales clave integradas en este panel son las siguientes:

- **Carga y navegación dinámica de recursos visuales:** La arquitectura del sistema integra un mecanismo de detección automática en el sistema de archivos local que escanea el directorio de almacenamiento en tiempo real. Esta característica permite que cualquier nuevo mapa o red exportada en formato HTML por librerías analíticas especializadas (como *Folium* o *Pyvis*) sea reconocido e incorporado de forma transparente a la interfaz de forma dinámica, eliminando la necesidad de modificar el código fuente.
- **Renderizado interactivo mediante encapsulamiento HTML/JS:** Haciendo uso de componentes de incrustación avanzada, la interfaz ejecuta los paquetes HTML/JavaScript en un contenedor, permitiendo que los graficos y mapas sean interactivables por su programacion de JavaScript.



Figura 6.8: Módulo de Visualizador de Mapas.

Capítulo 7

Planificación y Gestión del Proyecto

En el ámbito de la ingeniería de *software* y la ciencia de datos, la adopción de una metodología de gestión resulta indispensable para garantizar el cumplimiento de los objetivos dentro de los plazos establecidos. Este capítulo detalla el marco metodológico utilizado, el desglose de iteraciones (*Sprints*), la asignación de las Historias de Usuario y el cronograma temporal del proyecto.

7.1. Metodología de Desarrollo: Scrum Adaptado

De cara a organizar el proyecto de manera eficiente, se ha seguido una metodología ágil basada en **Scrum adaptado** al contexto de investigación y desarrollo individual. Seguir esta metodología me permitira afrontar mejor las incertidumbres de un proyecto de investigación mediante ciclos iterativos e incrementales.

El proyecto se organizó para una duración estimada de **24 semanas** (6 meses), estructurada en 8 Sprints de 3 semanas de duración cada uno (a excepción del último Sprint dedicado a la memoria final).

7.2. Desglose de Sprints y Asignación de Tareas

A continuación, se detalla el alcance funcional y técnico desarrollado en cada una de las fases del proyecto:

Sprint 1: Análisis y Limpieza del Dataset

Fase inicial orientada a la ingesta, auditoría y sanitización de la matriz de datos clínica.

- *Tareas realizadas:* Descarte de 12 variables irrelevantes para evitar ruido, filtrado de nulos, estandarización del texto descriptivo para modelos de lenguaje y generalización de los códigos. Auditoría inicial de seguridad (ENS/RGPD).

Sprint 2: Conversor de Códigos ICD

Diseño del archivo de equivalencias entre los estándares ICD-9, ICD-10 y descripciones clínicas.

- *Tareas realizadas:* Mapeo bidireccional ICD-9 → ICD-10, estructuración de descripciones clínicas en español e inglés y generación de equivalencias en el dataset.

Sprint 3: Creación y Estudio de Mapas de Prevalencia

Elaboración de mapas de prevalencia para visualizar la distribución geográfica de los casos del espectro esquizofrénico en la provincia.

- *Tareas realizadas:* Agregación de frecuencias por código postal, integración de cartografía vectorial en formato GeoJSON de España y generación de visores coropléticos mediante la librería *Folium*.

Sprint 4: Formación de la Base de Datos de Grafos

Migración del paradigma tabular del dataset a un modelo NoSQL orientado a grafos para la exploración de comorbilidades.

- *Tareas realizadas:* Instalación y configuración de **Neo4j**, modelado del esquema de entidades (*Paciente*, *Diagnóstico*) y relaciones clínicas, y escritura de consultas avanzadas en lenguaje *Cypher*.

Sprint 5: Entrenamiento de Modelos ML y DL

Construcción del núcleo predictivo mediante la experimentación sobre los 3 datasets (Original, RUS y VAE) mediante la división estratificada.

- *Tareas realizadas:* Entrenamiento de 6 clasificadores tabulares (*Decision Tree*, *Random Forest*, *Gradient Boosting*, *XGBoost*, *LightGBM*, *CatBoost*) y ajuste fino (*fine-tuning*) de 4 modelos de lenguaje basados en Transformers (*bert-base-multilingual-cased*, *BETO cased/uncased*, *xlm-roberta-base*).

Sprint 6: Evaluación y Comparación de Resultados

Comparación técnica del rendimiento y resultados de los modelos entrenados.

- *Tareas realizadas:* Ejecución de la Búsqueda en Rejilla (*Grid Search*), cálculo de métricas de rendimiento (F1-Score, Precisión, Sensibilidad, AUC) y selección del modelo ganador.

Sprint 7: Desarrollo de la aplicación web

Construcción de una página web unificando los módulos desarrollados en los Sprints anteriores.

- *Tareas realizadas:* Programación de la interfaz interactiva en **Streamlit**.

Sprint 8: Evaluación, Pruebas e Integración de la Memoria

Cierre del proyecto, verificación de calidad y documentación formal.

- *Tareas realizadas:* Pruebas de integración, auditoría final del cumplimiento del ENS y redacción de la memoria del TFG.

La Figura A.1 ilustra la evolución temporal de los Sprints.

7.3. Gestión y Mitigación de Riesgos

El desarrollo de un sistema de soporte a la decisión clínica basado en IA e infraestructura de grafos conlleva incertidumbres técnicas, operativas y normativas [47]. Siguiendo una metodología de gestión proactiva, se han identificado y evaluado los riesgos que podrían comprometer la integridad de los datos de salud o los plazos del proyecto.

7.3.1. Identificación de Riesgos

La Tabla 7.1 categoriza los riesgos detectados según su naturaleza y el área del proyecto a la que afectan.

7.3.2. Detalle de Riesgos y Acciones de Contención

A continuación, se desglosan los riesgos mediante fichas técnicas que definen su origen, impacto y el plan de mitigación aplicado.

ID	Descripción del Riesgo	Categoría	Tipo de Riesgo
R1	Incompatibilidad crítica de librerías y dependencias software.	Infraestructura	Técnico
R2	Agotamiento de memoria GPU/RAM durante el uso de LLMs.	Rendimiento	Técnico
R3	Sesgo de predicción derivado del desbalanceo de clases clínicas.	Calidad de Datos	Técnico
R4	Latencia excesiva en consultas relacionales complejas (Neo4j).	Escalabilidad	Técnico
R5	Fuga o acceso no autorizado a datos de salud anonimizados.	Seguridad	Regulatorio
R6	Sesgo de automatización: confianza excesiva del clínico en la IA.	Usabilidad	Ético/Social
R7	Incumplimiento de presupuesto y plazos por mala definición del problema.	Planificación	Gestión
R8	Cambios imprevistos en el alcance del proyecto.	Alcance	Gestión
R9	Restricción de tamaño para pesos pesados de BERT en GitHub.	Configuración	Técnico

Tabla 7.1: Resumen de riesgos identificados en el ciclo de vida del proyecto.

ID: R1	Incompatibilidad de dependencias del entorno
Descripción	Conflictos de versiones entre PyTorch, Transformers y conectores de Neo4j.
Categoría	Infraestructura / Entorno de desarrollo.
Precondición	Instalación simultánea de marcos de trabajo con dependencias nativas en C++.
Consecuencia	Inestabilidad del sistema y fallos en tiempo de ejecución de los modelos.
Mitigación	Uso del gestor de paquetes Mamba para la resolución determinista y creación de entornos aislados mediante archivos <code>environment.yml</code> . Desarrollado la decision en el proximo apartado.

ID: R2	Insuficiencia de recursos hardware (GPU/RAM)
Descripción	Errores de <i>CUDA Out Of Memory</i> durante el <i>fine-tuning</i> de BERT.
Categoría	Rendimiento computacional.
Precondición	Entrenamiento de modelos de lenguaje masivos sobre hardware limitado.
Consecuencia	Interrupción de la fase de experimentación y pérdida de progreso de cómputo.
Mitigación	Optimización mediante <i>gradient accumulation</i> , precisión mixta y reducción del <i>batch size</i> a 16 muestras.

ID: R3	Sesgo extremo por desbalanceo de clases
Descripción	Colapso del modelo hacia la clase mayoritaria (Esquizofrenia F20).
Categoría	Calidad de datos / Fiabilidad predictiva.
Precondición	Diferencia drástica entre frecuencias (como 2277 casos de F20 vs. 5 casos de F21).
Consecuencia	Incapacidad de detectar patologías minoritarias (F1-Score nulo).
Mitigación	Estrategia experimental tripartita: uso del dataset original desbalanceado, uso de submuestreo (RUS) y generación de datos sintéticos mediante VAE .

ID: R4	Cuellos de botella en la analítica de grafos
Descripción	Latencia elevada en la respuesta de la interfaz ante consultas Cypher complejas.
Categoría	Escalabilidad / Experiencia de usuario.
Precondición	Incremento del volumen de nodos y relaciones en la base de datos Neo4j.
Consecuencia	Degradación de la usabilidad clínica por tiempos de espera superiores a 30 segundos.
Mitigación	Indexación de propiedades críticas en Neo4j y uso de almacenamiento en caché (<code>@st.cache_resource</code>) en Streamlit.

ID: R5	Incumplimiento normativo de privacidad clínica
Descripción	Vulneración involuntaria del RGPD [2] o el ENS [3] por manejo de datos sensibles.
Categoría	Seguridad / Regulatorio.
Precondición	Presencia inadvertida de variables identificativas en el <i>dataset</i> de investigación.
Consecuencia	Sanciones legales graves y compromiso de la confidencialidad de los pacientes.
Mitigación	Protocolo de anonimización irreversible previo al análisis y descarte de 12 variables demográficas/administrativas en el Sprint 1.

ID: R6	Sesgo de automatización y error diagnóstico
Descripción	Tendencia del experto a confiar ciegamente en la probabilidad del sistema.
Categoría	Usabilidad / Ética clínica.
Precondición	Presentación de predicciones probabilísticas sin contexto explicativo.
Consecuencia	Delegación indebida de la decisión clínica y posibles diagnósticos erróneos.
Mitigación	Diseño del sistema exclusivamente como herramienta de apoyo (CDSS), integrando una capa visual de grafos para aportar interpretabilidad y varias advertencias.

7.3.3. Justificación Técnica y Gestión del Entorno Virtual mediante Mamba

El desarrollo de sistemas basados en Inteligencia Artificial exige la convivencia de múltiples librerías complejas con dependencias nativas en C/C++, controladores de GPU (CUDA) y marcos de trabajo heterogéneos (PyTorch, HuggingFace Transformers, Scikit-Learn, XGBoost, LightGBM, CatBoost y los conectores de Neo4j). En proyectos de esta envergadura, el uso de gestores de paquetes convencionales basados exclusivamente en *pip* suele derivar en un jaleo y caos de dependencias, donde la actualización o instalación de una librería corrompe los binarios compilados de otra.

Para prevenir este riesgo y garantizar la reproducibilidad absoluta del código, se descartó el gestor tradicional de *Conda* en favor de **Mamba** (un motor de gestión de paquetes de alto rendimiento reimplementado en C++, basandose en la misma

ID: R7	Desviación de plazos y presupuesto por mala definición inicial
Descripción	Retrasos significativos en las entregas de los Sprints o sobrecostes indirectos debido a la ambigüedad en la delimitación del problema o los objetivos clínicos.
Categoría	Gestión de Proyectos / Planificación.
Precondición	Falta de hitos intermedios claros, escasa comunicación con la dirección del trabajo o subestimación de la complejidad técnica de la analítica relacional.
Consecuencia	Prolongación del desarrollo más allá de las 24 semanas planificadas, incremento de los costes indirectos calculados en el presupuesto y retraso en la entrega final del TFG.
Mitigación	Adopción de la metodología ágil Scrum adaptada con la definición clara de 8 Sprints y el mantenimiento de un canal de comunicación continuo con el tutor para validar las tareas técnicas y ajustar el rumbo de la investigación.

ID: R8	Cambios imprevistos en el alcance del proyecto
Descripción	Inclusión de nuevos requisitos funcionales, herramientas de modelado o fuentes de datos durante las fases intermedias o de resultados.
Categoría	Gestión de Proyectos / Alcance.
Precondición	Entusiasmo técnico excesivo por parte del desarrollador al descubrir nuevas tecnologías o redefinición tardía del alcance funcional del sistema.
Consecuencia	Desbordamiento de las horas estimadas para el TFG, retraso en la fase de pruebas y desestabilización en la integración de la interfaz Streamlit con Neo4j o el clasificador final.
Mitigación	Congelación y delimitación estricta del catálogo de Requisitos Funcionales y No Funcionales. Cualquier mejora o propuesta detectada en fases posteriores se guarda para ser clasificada exclusivamente dentro del apartado de "Trabajos Futuros" de la memoria.

ID: R16	Límite de tamaño de archivos pesados en el repositorio de GitHub
Descripción	Imposibilidad de sincronizar con el repositorio remoto de GitHub los archivos de pesos optimizados de los modelos basados en BERT (<code>model.safetensors</code>), los cuales superan individualmente el límite estricto de 100 MB fijado por la plataforma.
Categoría	Gestión de Configuración / Infraestructura técnica.
Precondición	Intentar realizar un push al servidor remoto incluyendo los directorios locales de almacenamiento de checkpoints de Transformers (como el modelo <code>dccuchile/bert-base-spanish-wwm-cased</code>).
Consecuencia	Bloqueo inmediato del comando de sincronización de Git, imposibilidad de realizar copias de seguridad de la lógica del código y potencial corrupción del árbol de cambios local por subidas incompletas.
Mitigación	1. Inclusión de las extensiones <code>*.safetensors</code>, <code>*.bin</code> y <code>*.pt</code> en el archivo de exclusión <code>.gitignore</code>. 2. Desacoplamiento total del código de los pesos binarios: los modelos BERT se configuran para descargarse dinámicamente de forma asíncrona en tiempo de ejecución desde el repositorio oficial de Hugging Face mediante la función <code>from_pretrained()</code>, haciendo uso de la caché local del sistema operativo y garantizando que el código subido a GitHub sea ligero, portable e independiente de los pesos físicos entrenados.

Conda). La adopción de Mamba como eje de la infraestructura de desarrollo se justifica bajo 3 pilares técnicos fundamentales:

- **Motor de resolución C++ (*libsolv*):** A diferencia de Conda (cuyo motor de resolución en Python puede tardar decenas de minutos o bloquearse al calcular el árbol de dependencias de entornos complejos), Mamba utiliza la librería `libsolv` basada en algoritmos SAT. Esto reduce el tiempo de resolución del grafo de dependencias de minutos a escasos segundos, garantizando un estado coherente en todo momento.
- **Manejo nativo de binarios pesados y aceleración GPU:** Mamba gestiona con precisión quirúrgica las dependencias a nivel de sistema operativo y controladores CUDA. Esto permitió enlazar las versiones exactas de las librerías

C++ requeridas por PyTorch para la GPU sin conflictos con las extensiones optimizadas de la CPU utilizadas por los algoritmos de ensambles tabulares.

- **Garantía de reproducibilidad científica:** La totalidad del entorno virtual fue congelada en un archivo de especificación declarativa (`environment.yml`). Esto asegura que cualquier investigador o tribunal puede replicar el entorno de ejecución exacto (mismas versiones de Python, compiladores C++ y librerías de IA) en cualquier máquina sin variaciones en el comportamiento de los modelos.

Esta decisión de ingeniería garantiza que el *pipeline* experimental del proyecto es invulnerable a la obsolescencia o cambios no retrocompatibles en las librerías de terceros.

7.4. Gestión de Configuración y Control de Versiones mediante GitHub

La reproducibilidad científica y la integridad del código fuente son pilares fundamentales en cualquier desarrollo de ingeniería de software contemporáneo. Para garantizar el cumplimiento de estos principios en este trabajo de investigación, se ha implementado una estrategia estricta de gestión de configuración y control de versiones utilizando el sistema de control distribuido **Git**, respaldado por la plataforma en la nube **GitHub**.

El uso de GitHub ha aportado múltiples beneficios metodológicos a lo largo de las 24 semanas de desarrollo del proyecto:

- **Trazabilidad histórica y reversibilidad:** Cada hito técnico completado en los Sprints se ha consolidado mediante confirmaciones en commits de git atómicas y descriptivos, permitiendo auditar la evolución del código o revertir cambios ante la aparición de regresiones o conflictos de dependencias.
- **Gestión de ramas por Sprints:** Se ha aplicado un flujo de trabajo simplificado basado en ramas, aislando el desarrollo de nuevas características (como la interfaz de Streamlit o los scripts de Neo4j) de la rama principal, asegurando así un código siempre funcional para su demostración y evaluación.
- **Desacoplamiento de código y datos binarios:** Para mantener la agilidad del repositorio remoto y respetar los límites de almacenamiento físico de GitHub, se ha configurado una política rigurosa de exclusión mediante el archivo `.gitignore`. De este modo, se evita subir archivos de datos sensibles

(garantizando el RGPD), que se filtren contraseñas de bases de datos o binarios de gran peso, centralizando el repositorio exclusivamente en la lógica de negocio en Python.

Capítulo 8

Presupuesto

8.1. Recursos hardware utilizados

El desarrollo entero de este proyecto de investigación, incluyendo las fases de curación de datos, la ejecución de consultas en la base de datos orientada a grafos Neo4j, el entrenamiento de los modelos predictivos y el despliegue local de la interfaz web y demas, se ha llevado a cabo utilizando 2 estaciones de trabajo, una local (ordenador de sobremesa) y otra portable (ordenador portátil). Debido a la carga computacional requerida para el procesamiento de grafos en memoria y el ajuste de modelos de aprendizaje automático, detallo los costes en la Tabla 8.1 y 8.2.

Componente Hardware	Modelo y Especificaciones Técnicas
Procesador (CPU)	12th Gen Intel(R) Core(TM) i5-12400F 2.50 GHz
Memoria RAM	16 GB DDR4 a 3200 MHz
Tarjeta Gráfica (GPU)	Ej: NVIDIA GeForce RTX 3060 12GB
Almacenamiento	SSD NVMe M.2 de 1 TB
Periféricos	Monitor Full HD 24”, teclado y ratón ergonómicos.

Tabla 8.1: Especificaciones técnicas del equipamiento hardware en el ordenador de sobremesa.

Para calcular el coste real al usar este equipamiento sobre el proyecto, se aplica el concepto contable de amortización lineal. Considerando que la vida útil estándar de un equipo informático de estas características se estima en 4 años (48 meses), el coste imputable se calcula mediante la ecuación 8.1:

Componente Hardware	Modelo y Especificaciones Técnicas
Hardware Portátil	Acer Swift SFE16-42
Procesador (CPU)	AMD Ryzen 7 7735U
Memoria RAM	16 GB DDR4 a 3200 MHz
Tarjeta Gráfica (GPU)	Radeon Graphics x 16 integrada
Almacenamiento	SSD NVMe M.2 de 1 TB
Periféricos	Ratón ergonómicos.

Tabla 8.2: Especificaciones técnicas del equipamiento hardware en el ordenador portátil.

$$\text{Coste de Amortización} = \text{Precio de Adquisición} \times \left(\frac{\text{Meses de Uso}}{\text{Vida Útil (48 meses)}} \right) \quad (8.1)$$

Asumiendo un periodo de desarrollo del proyecto de 7 meses, la Tabla 8.3 desglosa el cálculo económico del impacto del hardware, aplicando el principio de amortización a los precios de mercado actuales de los componentes.

Elemento	Precio Original (€)	Tiempo de Uso (Meses)	Coste Imputable (€)
Estación de trabajo (PC)	1.100,00	7	145,83
Portátil	1.200,00	7	150,00
Periféricos y Monitor	150,00	7	21,88
Total Hardware			317,71 €

Tabla 8.3: Desglose de costes y amortización del hardware del proyecto.

8.2. Software y librerías empleadas

La selección del ecosistema de *software* para este proyecto se ha regido por los principios de eficiencia computacional, robustez comunitaria y, fundamentalmente, la filosofía del código abierto (*Open-Source*). El uso de herramientas libres nos garantiza la reproducibilidad de los experimentos realizados durante el desarrollo del proyecto, sino que anula por completo los costes de adquisición de licencias comerciales, maximizando la viabilidad económica del sistema desarrollado.

A continuación, se clasifican y justifican los recursos lógicos e informáticos empleados en las distintas fases del proyecto, los cuales se encuentran resumidos en la Tabla 8.4:

- **Entorno de desarrollo y lenguaje base:** Se ha utilizado el lenguaje de programación **Python** [48] debido a su hegemonía en el sector de la ciencia de datos. Como entorno de desarrollo (*IDE*) se empleó **Visual Studio Code** [49] junto con **Jupyter Notebooks** [50] para la fase de experimentación con modelos y trabajo con la base de datos, ambos bajo licencias de código abierto (MIT y BSD respectivamente).
- **Persistencia y analítica de grafos:** Para el modelado relacional y almacenamiento de datos se optó por **Neo4j (Community Edition)** [51], un sistema de gestión de bases de datos NoSQL orientado a grafos que opera bajo la licencia GPLv3, permitiendo el almacenamiento local u online y la ejecución de algoritmos topológicos sin coste.
- **Ciencia de datos y Machine Learning:** El procesamiento tabular de los 3134 registros y el entrenamiento predictivo se articularon mediante librerías científicas estándar de Python: **Pandas** [52] y **NumPy** [53] para la manipulación matricial; **Scikit-Learn** [54] para el preprocesamiento, imputación de datos y modelos clásicos; y **XGBoost** [55] para los modelos de optimización del gradiente.
- **Procesamiento del Lenguaje Natural y LLMs:** Para la integración de capacidades semánticas y el manejo de los modelos de lenguaje, se utilizaron las librerías de **Hugging Face (Transformers)** [56].
- **Despliegue de la aplicación web:** La interfaz gráfica interactiva dirigida a los expertos psiquiatras se desarrolló utilizando **Streamlit** [57], un marco de trabajo de código abierto en Python que permite desplegar aplicaciones web de datos de manera ágil y con un consumo mínimo de recursos en el servidor.

8.3. Estimación de costes

En este apartado se consolida el análisis económico del proyecto, integrando los costes directos de mano de obra invertidos en el proyecto y los costes indirectos derivados de la actividad. Al tratarse de un proyecto de carácter individual, el factor humano constaría de la contratación de un único perfil de Ingeniero de Datos o Científico de Datos Junior encargado de todas las fases del ciclo de vida del software y la investigación.

Software / Librería	Función Principal	Tipo de Licencia	Coste (€)
Python v3.13.5	Lenguaje de programación núcleo	Python Software Foundation	0,00
Neo4j Community Ed.	Base de datos orientada a grafos	GPLv3	0,00
VS Code / Jupyter Notebook	Entorno de desarrollo integrado	MIT / BSD	0,00
Scikit-Learn / XGBoost	Modelado predictivo y ML	BSD / Apache 2.0	0,00
Hugging Face / Transformers	Procesamiento de LLMs y NLP	Apache 2.0	0,00
Streamlit	Desarrollo de la interfaz web	Apache 2.0	0,00
Sistema Operativo	Windows 10	OEM	0,00
Sistema Operativo	Ubuntu Linux 24.04.4 LTS	GPL	0,00
Total Software			0,00 €

Tabla 8.4: Desglose de costes de licencias del software y librerías utilizadas.

8.3.1. Costes de personal (Mano de obra)

El volumen de trabajo estimado para la consecución de los objetivos de este Trabajo de Fin de Grado se alinea con la carga lectiva oficial de 12 créditos ECTS, lo que equivale a un total de 300 horas de dedicación. Dado que el proyecto se ha gestionado mediante una metodología ágil **Scrum adaptado**, el esfuerzo temporal se ha dividido formalmente entre las tareas técnicas de ingeniería de software/IA y las labores de gestión del proceso ágil:

- **Ingeniero de Datos / Desarrollador Junior (85 % de la carga temporal - 255 horas):** Comprende las tareas técnicas de preprocesamiento, modelado en grafos (Neo4j), formar el conversor de codigos, entrenamiento de modelos ML/DL, desarrollo de la aplicación web en Streamlit y validación de requisitos.
- **Scrum Master Junior (15 % de la carga temporal - 45 horas):** Asume la gestión del marco ágil, incluyendo la planificación y estimación de los 8 Sprints, las sesiones de revisión/retrospectiva y la mitigación de bloqueos técnicos.

Cabe señalar que el rol de **Product Owner** es asumido conceptualmente por el tutor del proyecto, por lo que no genera costes salariales adicionales imputables a este presupuesto.

Atendiendo a las tarifas de mercado actuales y convenios colectivos para perfiles tecnológicos de nivel de entrada, se fija una tarifa de 14,00 €/hora para el perfil técnico y de 16,00 €/hora para las labores de gestión ágil (incluyendo costes salariales y cargas sociales) [58]. El desglose detallado del coste de personal se presenta en la Tabla 8.5.

Perfil / Rol Funcional	Horas Dedicadas	Precio/Hora (€)	Coste Total (€)
Ingeniero de Datos Junior	255	14,00	3.570,00
Scrum Master Junior	45	16,00	720,00
Total Mano de Obra			4.290,00 €

Tabla 8.5: Desglose del coste de personal directo según roles metodológicos.

8.3.2. Costes indirectos y gastos generales

Los costes indirectos estaran compuestos por aquellos gastos que, sin estar ligados directamente a la programación o análisis, son indispensables para el desarrollo de la actividad física. Esto incluye el consumo de energía eléctrica de la estación de trabajo, la conexión a internet de banda ancha para la descarga de librerías o subida de modelos o código a Github, y el gasto logístico del espacio de oficina. Para simplificar y generalizar el modelo contable, se aplica un estándar industrial del 15 % sobre el coste total de la mano de obra directa:

$$\text{Costes Indirectos} = 4.290,00 \times 0,15 = 643,50 \text{ €} \quad (8.2)$$

8.3.3. Resumen del presupuesto total

Para concluir el análisis financiero, unificaremos todos los conceptos económicos desglosados a lo largo de este capítulo (como recursos hardware amortizados, licencias de software, mano de obra e indirectos) en una tabla 8.6, ofreciendo la valoración económica global del proyecto. Además, se incorpora un **margen de beneficio industrial** del 10 % sobre el coste total calculado, con el fin de cubrir posibles cambios de alcance, ajustes técnicos o imprevistos durante el desarrollo sin generar sobrecostes significativos para garantizar la viabilidad económica del proyecto.

$$\text{Margen de beneficio industrial} = 0,10 \times 5.322,00 = 532,20 \text{ €} \quad (8.3)$$

$$\text{Presupuesto total con margen} = 5.322,00 + 532,20 = 5.854,20 \text{ €} \quad (8.4)$$

Concepto Presupuestario	Coste Imputable (€)
Recursos Hardware (Amortización lineal)	317,71
Software y Librerías de Código Abierto	0,00
Costes de Personal (Mano de Obra Directa)	4.290,00
Costes Indirectos (15 % sobre mano de obra)	643,50
Margen de Beneficio Industrial (10 %)	532,20
PRESUPUESTO TOTAL DEL PROYECTO	5.854,20

Tabla 8.6: Resumen consolidado del presupuesto general del TFG.

8.4. Viabilidad de implantación o escalado

La solución tecnológica desarrollada en este trabajo ha sido diseñada bajo un paradigma modular y desacoplado, lo que facilita enormemente su transición desde un entorno de desarrollo local hacia un entorno de producción real dentro de la infraestructura de un servicio de salud pública, especialmente locales como el Servicio de Salud de Castilla y León (SACYL). A continuación, se evalúa la viabilidad de este sistema atendiendo a criterios de escalabilidad técnica, seguridad normativa y sostenibilidad económica.

Desde el punto de vista de la escalabilidad técnica, la elección de una base de datos NoSQL orientada a grafos como Neo4j garantiza un rendimiento óptimo incluso ante incrementos masivos en el volumen de datos. Si el sistema pasara de los 3134 registros analizados en esta memoria a gestionar el histórico completo de pacientes de la comunidad autónoma, las consultas relacionales de caminos cortos y la detección de comorbilidades mantendrían una complejidad temporal altamente eficiente gracias al principio de adyacencia libre de índices inherente a los grafos. Asimismo, para asegurar un despliegue ágil y homogéneo en la infraestructura servidores de la red sanitaria, el código de la interfaz y los modelos predictivos se han diseñado para ser empaquetados mediante tecnologías de contenedorización como Docker. Esto permite mitigar los conflictos de dependencias y replicar la aplicación de forma inmediata en cualquier nodo hospitalario.

En el marco de la seguridad y el cumplimiento legal, al tratarse de información de alta sensibilidad relacionada con la salud mental, la implantación real de la plataforma exige una alineación estricta con el Esquema Nacional de Seguridad [3] y el Reglamento General de Protección de Datos [2]. La aplicación no almacena credenciales ni datos biométricos directamente identificables de forma local; en su lugar, está concebida para desplegarse dentro de una Red Privada Virtual (VPN) corporativa y delegar la validación de usuarios en los sistemas de autenticación federada del propio servicio de salud (mediante certificados digitales del personal sanitario). De este modo, la consulta del conversor ICD y la ejecución de los módulos predictivos se realizan bajo un canal completamente cifrado, seguro y auditable.

Finalmente, la viabilidad económica representa una de las mayores fortalezas de la propuesta. Al haberse construido íntegramente sobre ecosistemas de código abierto, el coste de adquisición de licencias de *software* para la administración pública es nulo (0,00 €). El único coste recurrente derivaría del mantenimiento operativo y el alojamiento en la nube corporativa o en un servicio gestionado (como Neo4j AuraDB). Una instancia en la nube con capacidades computacionales intermedias, suficiente para soportar las consultas concurrentes de los facultativos de la región, supondría un coste operativo estimado de entre 40,00 € y 80,00 € mensuales, haciendo destacar el proyecto como una opción altamente rentable, eficiente y viable para el soporte a la decisión clínica.

Capítulo 9

Conclusiones y trabajo futuro

9.1. Principales aportaciones

El presente Trabajo de Fin de Grado ha permitido abordar de manera integral el análisis relacional y predictivo de comorbilidades en pacientes diagnosticados con trastornos del espectro esquizofrénico. Mediante un enfoque interdisciplinar que combina la ciencia de datos, los sistemas NoSQL y el desarrollo de software, se han consolidado hitos que aportan valor tanto al ámbito técnico como al clínico. A continuación, se detallan las principales aportaciones generadas en este proyecto:

- **Construcción de un recurso relacional estandarizado:** Se ha diseñado y unificado un conjunto de datos en formato tabular (CSV) que mapea de forma bidireccional los diagnósticos, descripciones clínicas en español y equivalencias entre las codificaciones ICD-9 e ICD-10. Esta aportación resuelve un problema crítico de intercambio de información de forma segura en la documentación psiquiátrica actual, que faltaba en el campo, facilitando la traducción ágil de términos médicos libres a códigos normativos. A la vez, se ha buscado una opción con la que obtener las descripciones clínicas en inglés
- **Modelado avanzado del entorno clínico mediante grafos:** La migración del paradigma tabular tradicional hacia una base de datos orientada a grafos en **Neo4j** representa una aportación metodológica clave. Este enfoque ha permitido estructurar las complejas redes de interconexión entre pacientes, sintomatologías y comorbilidades psiquiátricas, optimizando la eficiencia computacional en la exploración de caminos clínicos y vecindades diagnósticas.

- **Evaluación y validación de arquitecturas de aprendizaje automático:** Se ha implementado y comparado un flujo experimental multicapa que contrasta clasificadores tradicionales frente a modelos de lenguaje profundo. En el escenario original sin balancear, el modelo **BETO (modalidad Combinada)** demostró el mayor potencial teórico de clasificación, alcanzando un **F1-Score de 0,6857** y una exactitud del **72,85 %**. Sin embargo, atendiendo a los requisitos no funcionales de latencia y viabilidad de despliegue local en la infraestructura de CPU del SACYL, el clasificador **LightGBM** entrenado sobre el espacio balanceado sintéticamente mediante un Autoencoder Variacional (**VAE**) se consolida como la solución final de soporte más robusta, registrando un **F1-Score de 0,4400** en la entrada de códigos y garantizando una inferencia ágil y libre de sesgos predictivos.
- **Desarrollo de una herramienta de transferencia tecnológica:** Como elemento diferenciador y complementario, se ha diseñado y desplegado una aplicación web interactiva basada en **Streamlit**. Esta interfaz traduce las conversiones de códigos y las consultas de grafos en una herramienta visual, intuitiva y accesible para los profesionales de la psiquiatría, acercando los resultados de la investigación a la práctica clínica real en la consulta.

9.2. Contextualización en el Estado del Arte

La revisión exhaustiva de la literatura científica realizada en el Capítulo 2 ha evidenciado que el diagnóstico y monitoreo evolutivo de la esquizofrenia se encuentra en un punto de inflexión metodológico [9, 18]. El análisis del estado del arte ha permitido consolidar unas conclusiones cardinales que fundamentan y validan cada una de las decisiones de ingeniería de software e inteligencia artificial adoptadas en este Trabajo de Fin de Grado:

1. **Solución a la Paradoja Multimodal y al Desbalanceo:** La literatura clínica describe con preocupación la denominada **Paradoja Multimodal**, donde la concatenación masiva y temprana de variables heterogéneas amplifica el ruido estadístico degradando la capacidad predictiva [9]. Este proyecto ha resuelto dicha limitación teórica mediante una *arquitectura híbrida desacoplada*: se delega el procesamiento de comorbilidades discretas en modelos de ensamble basados en árboles (**LightGBM**), el análisis semántico de las descripciones clínicas en el modelo **BETO** [27, 28], y la clasificación de las comorbilidades

sintéticas densas generadas por el Autoencoder Variacional (**VAE**) en un clasificador **Perceptrón Multicapa (MLP)** [9, 29].

2. **Explicabilidad y Medicina de Redes:** El estado del arte convalidó que las bases de datos de grafos (**Neo4j**) y los algoritmos de detección de comunidades (**Louvain**) y centralidad (intermediación y grado) superan la rigidez tabular de las RDBMS tradicionales SQL [21]. Estas ofrecen al facultativo un plano relacional intuitivo para visualizar e interpretar cómo se interconectan el espectro psicótico con patologías somáticas dominantes [1, 20].
3. **Cierre de la brecha en la transferencia tecnológica:** Por último, la literatura evidencia un vacío crítico en la transferencia de los modelos analíticos desde entornos cerrados de laboratorio hacia herramientas de apoyo a la decisión clínica (CDSS) utilizables en tiempo real de consulta [25]. El desarrollo de la interfaz interactiva en **Streamlit**, que incorpora un motor asíncrono para el autocompletado CIE, un conversor masivo para unificar el histórico regional CIE-9/10 y compatibilidad para operar de manera local, demuestra que es viable transferir la ciencia de datos avanzada a una solución de software intuitiva y robusta para el personal médico del SACYL [25].

9.3. Limitaciones

A pesar de los resultados satisfactorios obtenidos en el desarrollo del proyecto, es fundamental adoptar una postura crítica y reconocer las restricciones intrínsecas asociadas tanto a los datos disponibles como a las metodologías tecnológicas aplicadas. La identificación de estas limitaciones es clave para interpretar correctamente el alcance del estudio:

- **Restricción geográfica y representatividad de la muestra:** El *dataset* analizado refleja la realidad clínica y los patrones de diagnóstico casi exclusivamente de la provincia de León. Por tanto, las frecuencias observadas y los mapas de distribución geográfica podrían estar influenciados por dinámicas socios locales o por los criterios de codificación específicos del personal médico de la región. Esto limita la generalización inmediata de los modelos predictivos a otros entornos hospitalarios nacionales o internacionales sin un proceso previo de reentrenamiento.
- **Desequilibrio severo de clases:** En el ámbito de la salud mental, la prevalencia de ciertos trastornos es usual. Durante el diseño del flujo predictivo

,especialmente en las fases iniciales focalizadas en la esquizofrenia (F20 y F20.89) y en la posterior expansión multiclase, el desequilibrio en la cantidad de registros por patología supuso un desafío técnico importante. Los algoritmos basados en árboles (XGBoost y Random Forest) y los modelos lingüísticos (BERT) tienden a verse penalizados por las clases minoritarias, requiriendo un esfuerzo extra de computación y ajuste de pesos, que no consigue combatir completamente el sesgo.

- **Calidad y ruido en las descripciones textuales:** El entrenamiento de los modelos BERT para clasificar diagnósticos a partir de texto libre se enfrenta a la naturaleza caótica de la jerga médica. Las descripciones clínicas reales a menudo contienen abreviaturas no estandarizadas, errores tipográficos o expresiones ambiguas. Aunque el proceso de limpieza y el conversor ICD mitigaron este problema, el ruido remanente en el lenguaje clínico introduce una barrera natural en la precisión absoluta de los transformadores.
- **Carácter exploratorio del análisis topológico:** Las métricas de análisis de grafos en Neo4j, tales como las técnicas de centralidad (*eigenvector*, *degree*) y los algoritmos preliminares de detección de comunidades, se ejecutaron con un enfoque exploratorio. Debido a las limitaciones de cómputo de la infraestructura local y al uso de la versión *Community* de la base de datos, no se profundizaron en dinámicas de grafos dinámicos o temporales, quedando estos estudios como una primera radiografía relacional del mapa de comorbilidades.

9.4. Posibles mejoras futuras

A partir de las conclusiones obtenidas y las limitaciones identificadas en este trabajo, se abren diversas líneas de investigación y desarrollo tecnológico que permitirían expandir las capacidades del sistema y mejorar su precisión analítica. Las propuestas de trabajo futuro se estructuran en los siguientes vectores esenciales:

- **Evolución hacia arquitecturas de lenguaje médicas especializadas:** Aunque los modelos BERT estándar entrenados para clasificación multiclase han ofrecido un rendimiento sólido, una evolución natural consistiría en el *fine-tuning* de Modelos de Lenguaje Grandes (LLMs) especializados en el dominio biomédico (tales como *BioBERT* o *ClinicalBERT*). Estas arquitecturas están preentrenadas con corpus de textos clínicos y farmacéuticos, lo que permitiría una comprensión semántica mucho más precisa de las abreviaturas, la jerga médica local y la sintomatología compleja de la esquizofrenia.

- **Profundización en la minería de grafos y detección de comunidades:** El estudio topológico inicial realizado en Neo4j mediante métricas de centralidad sienta las bases para un análisis predictivo basado en topología. Como trabajo futuro, se propone explotar el algoritmo de detección de comunidades por algoritmo de Louvain para agrupar automáticamente a los pacientes según patrones de comorbilidad ocultos. Asimismo, se plantea la implementación de Redes Neuronales de Grafos (*Graph Neural Networks*, GNNs) para combinar los *embeddings* textuales de BERT con los *embeddings* estructurales de la red, prediciendo así la aparición de futuras patologías asociadas.
- **Escalado multi-provincial y análisis geo-epidemiológico avanzado:** Para superar la restricción geográfica actual, se plantea expandir el *dataset* integrando los registros clínicos de las restantes provincias de la comunidad autónoma. Esto permitiría correlacionar los mapas de frecuencia de diagnósticos con variables socioeconómicas, climatológicas o de acceso a recursos sanitarios, transformando la herramienta actual en un sistema de vigilancia epidemiológica predictivo de gran utilidad para la gestión de la salud pública, no solo de León, sino de toda la región.
- **Transición y escalabilidad a la normativa CIE-11:** Ampliar el módulo conversor y el sistema predictivo para dar soporte a la undécima revisión de la OMS. Esto implicaría aplicar un *fine-tuning* adicional a los modelos de lenguaje con este nuevo corpus terminológico, y extender la herramienta web para habilitar una pasarela de conversión cruzada entre CIE-9, CIE-10 y CIE-11, garantizando así la interoperabilidad y vigencia tecnológica de la aplicación a largo plazo.
- **Integración modular en sistemas de historia clínica electrónica (HCE):** Finalmente, el objetivo definitivo de la aplicación web desarrollada es su despliegue real. Una línea de desarrollo clave será transformar la interfaz actual en un módulo integrable (mediante APIs estándar de interoperabilidad médica como HL7 o FHIR) dentro de los sistemas informáticos de salud utilizados por los facultativos (por ejemplo, el sistema MEDORA en Castilla y León). Esto permitiría al psiquiatra consultar el conversor ICD y obtener las predicciones probabilísticas directamente durante la consulta, automatizando el flujo de trabajo clínico.

Bibliografía

- [1] C. A. Hidalgo, N. Blumm, A.-L. Barabási, and N. A. Christakis, “A dynamic network approach for the study of human phenotypes,” *PLoS Computational Biology*, vol. 5, no. 4, p. e1000353, 2009.
- [2] Parlamento Europeo y Consejo de la Unión Europea, “Reglamento (ue) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (rgpd),” *Diario Oficial de la Unión Europea*, vol. L, no. 119, pp. 1–88, 2016.
- [3] Jefatura del Estado, “Ley orgánica 3/2018, de 5 de diciembre, de protección de datos personales y garantía de los derechos digitales (lopdgdd),” *Boletín Oficial del Estado*, no. 294, pp. 119788–119857, 2018. Referencia: BOE-A-2018-16673.
- [4] Jefatura del Estado, “Ley 41/2002, de 14 de noviembre, básica reguladora de la autonomía del paciente y de derechos y obligaciones en materia de información y documentación clínica,” *Boletín Oficial del Estado*, no. 274, pp. 40126–40132, 2002.
- [5] Jefatura del Estado, “Ley 14/2007, de 3 de julio, de investigación biomédica,” *Boletín Oficial del Estado*, no. 159, pp. 28826–28848, 2007.
- [6] Jefatura del Estado, “Ley 14/2007, de 3 de julio, de investigación biomédica. título i: Comités de Ética de la investigación,” *Boletín Oficial del Estado*, no. 159, pp. 28826–28847, 2007. Referencia: BOE-A-2007-12945.
- [7] Ministerio de Sanidad, Servicios Sociales e Igualdad, “Real decreto 1090/2015, de 4 de diciembre, por el que se regulan los ensayos clínicos con medicamentos, los comités de Ética de la investigación con medicamentos (ceim) y el registro español de estudios clínicos,” *Boletín Oficial del Estado*, no. 307, pp. 121923–121966, 2015. Referencia: BOE-A-2015-14082.

-
- [8] Jefatura del Estado, “Real decreto 311/2022, de 22 de abril, por el que se aprueba el esquema nacional de seguridad en el ámbito de la administración electrónica,” *Boletín Oficial del Estado*, no. 100, pp. 1–36, 2022.
- [9] R. Saboori Amleshi, M. Ilaghi, M. Rezaei, M. Zangiabadian, H. Rezazadeh, G. Wegener, and S. Arjmand, “Predictive utility of artificial intelligence on schizophrenia treatment outcomes: A systematic review and meta-analysis,” *Neuroscience and Biobehavioral Reviews*, vol. 169, p. 105968, 2025.
- [10] C.-R. Phang, F. Noman, H. Hussain, C.-M. Ting, and H. Ombao, “Schizo-net: A novel Schizophrenia Diagnosis Framework Using Late Fusion Multimodal Deep Learning on Electroencephalogram-based Brain Connectivity Indices,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 31, pp. 924–935, 2023.
- [11] L. Montaña, T. Nieto, and N. Mayorga, “Esquizofrenia y tratamientos psicológicos: Una revisión teórica,” *Revista Vanguardia Psicológica*, vol. 4, no. 1, pp. 86–107, 2013.
- [12] R. S. Kahn, “On the origins of schizophrenia,” *American Journal of Psychiatry*, vol. 177, no. 4, pp. 291–297, 2020.
- [13] L. Hansen, M. Bernstorff, K. Enevoldsen, S. Kolding, J. G. Damgaard, E. Perfalk, K. L. Nielbo, A. A. Danielsen, and S. D. Østergaard, “Predicting diagnostic progression to schizophrenia or bipolar disorder via machine learning,” *JAMA Psychiatry*, vol. 82, no. 5, pp. 459–469, 2025.
- [14] S. R. Kay, A. Fiszbein, and L. A. Opler, “The positive and negative syndrome scale (PANSS) for schizophrenia,” *Schizophrenia Bulletin*, vol. 13, no. 2, pp. 261–276, 1987.
- [15] J. E. Overall and D. R. Gorham, “The brief psychiatric rating scale,” *Psychological Reports*, vol. 10, no. 3, pp. 799–812, 1962.
- [16] J. P. Zapata Ospina, A. M. Rangel Martínez-Villalba, and J. Garcí Valencia, “Psicoeducación en esquizofrenia,” *Revista Colombiana de Psiquiatría*, vol. 44, no. 3, pp. 143–149, 2015.
- [17] J. Ø. Berle, E. R. Hauge, K. J. Oedegaard, F. Holsten, and O. B. Fasmer, “Actigraphic registration of motor activity reveals a more structured behavioural pattern in schizophrenia than in major depression,” *BMC Research Notes*, vol. 3, no. 1, p. 150, 2010.
-

- [18] A. Tyagi, V. P. Singh, and M. M. Gore, “Towards artificial intelligence in mental health: a comprehensive survey on the detection of schizophrenia,” *Multimedia Tools and Applications*, 2022.
- [19] J. W. Lai, C. K. E. Ang, U. R. Acharya, and K. H. Cheong, “Schizophrenia: A survey of artificial intelligence techniques applied to detection and classification,” *International Journal of Environmental Research and Public Health*, vol. 18, no. 11, p. 6099, 2021.
- [20] A.-L. Barabási, N. Gulbahce, and J. Loscalzo, “Network medicine: A network-based approach to human disease,” *Nature Reviews Genetics*, vol. 12, no. 1, pp. 56–68, 2011.
- [21] K. A. Yousif and J. Calvillo Arbizu, “Real-time patient monitoring and ehr data integration using kafka and neo4j in healthcare environments,” *IEEE Access*, 2025. Proof of Concept Application.
- [22] P. Liu, Y. Huang, P. Wang, Q. Zhao, J. Nie, Y. Tang, L. Sun, H. Wang, X. Wu, and W. Li, “Construction of typhoon disaster knowledge graph based on graph database Neo4j,” in *Proceedings of the 2019 International Conference on Big Data and Knowledge Graphs*, pp. 112–120, Springer, 2019.
- [23] A. Raj and S. B. Somani, “Predicting terror attacks using Neo4j sandbox and machine learning algorithms,” *International Journal of Advanced Computer Science and Applications*, 2022.
- [24] A. Gogeoascoechea Hernández, “Precisión de los algoritmos deep learning en el diagnóstico de esquizofrenia: Revisión sistemática y metaanálisis,” 2025.
- [25] J. P. López, “Inteligencia artificial como herramienta de apoyo terapéutico en salud mental: Perspectiva América Latina. Revisión sistemática,” *Revista Electrónica Transformar*, vol. 7, no. 1, pp. 34–46, 2026.
- [26] L. Grinsztajn, E. Oyallon, and G. Varoquaux, “Why do tree-based models still outperform deep learning on typical tabular data?,” *Advances in Neural Information Processing Systems (NeurIPS Datasets and Benchmarks Track)*, vol. 35, pp. 507–520, 2022.
- [27] J. Vidal Marciel, “Algoritmo y empatía: El impacto de la Inteligencia Artificial en la salud mental,” *Nous. Boletín de Logoterapia y Análisis Existencial*, no. 27, pp. 79–103, 2023.

- [28] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Pérez, “Spanish pre-trained BERT model and evaluation data,” in *Practical ML for Developing Countries Workshop (NeurIPS)*, (Addis Ababa, Ethiopia), 2020.
- [29] A. Jiménez Arévalo, “Inteligencia artificial explicable para estimar la depresión y esquizofrenia en pacientes basadas en datos de sensores de IoT,” 2023.
- [30] Ministerio de Sanidad, Consumo y Bienestar Social, “eCIEMaps - Navegador de las Clasificaciones CIE-9-MC y CIE-10-ES.” https://www.eciemaps.sanidad.gob.es/browser/index_9_mc, 2023.
- [31] Inigo Flores, “Repositorio público de github con delimitación vectorial de códigos postales de españa en formato geojson.” <https://github.com/inigoflores/ds-codigos-postales>.
- [32] Folium Contributors, “Folium.” <https://python-visualization.github.io/folium/>.
- [33] Google, “Bert base multilingual cased model.” <https://huggingface.co/google-bert/bert-base-multilingual-cased>.
- [34] Google, “Bert base spanish wwm uncased model.” <https://huggingface.co/google-bert/bert-base-spanish-wwm-uncased>.
- [35] Google, “Bert base spanish wwm cased model.” <https://huggingface.co/google-bert/bert-base-spanish-wwm-cased>.
- [36] Google, “Xlm-roberta base model.” <https://huggingface.co/facebook/xlm-roberta-base>.
- [37] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [38] D. M. W. Powers, “Evaluation: from precision, recall and f-measure to roc, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [39] Centers for Medicare & Medicaid Services (CMS), “ICD-10-CM and GEMs Code Tables and Studies.” <https://www.cms.gov/medicare/coding-billing/icd-10-codes>, 2023. Accedido en 2024.
- [40] National Bureau of Economic Research (NBER), “ICD-9-CM and ICD-10-CM Crosswalk and General Equivalence

- Mappings.” <https://www.nber.org/research/data/icd-9-cm-and-icd-10-cm-and-icd-10-pcs-crosswalk-or-general-equivalence-mapping> 2018.
- [41] New Zealand Health Information Service (NZHIS), “ICD-9 to ICD-10 Mapping Documentation and Files.” <https://web.archive.org/web/20061129021417/http://www.nzhis.govt.nz/documentation/mapping/mappingfiles.html>, 2006. Archivo histórico conservado en Wayback Machine.
- [42] C. Clark, “ICD9 to ICD10 Mapping Repository.” <https://github.com/ClancyClark/ICD9to10mapping>, 2020.
- [43] B. Rattanasamphan, “ICD-9-CM to ICD-10-CM Mapping Tool.” <https://github.com/bhanratt/ICD9CMtoICD10CM>, 2019.
- [44] Atlas CUMC, “ICD10-ICD9 Codes Conversion Database.” <https://github.com/AtlasCUMC/ICD10-ICD9-codes-conversion>, 2017.
- [45] D. Martín García, “Dataset CIE-10 en Español (Diagnoses).” <https://huggingface.co/datasets/dmartingarcia/cie-10>, 2022.
- [46] National Library of Medicine (NLM), “ICD-10-CM Clinical Tables API Documentation.” <https://clinicaltables.nlm.nih.gov/apidoc/icd10cm/v3/doc.html>, 2024.
- [47] N. V. Kraguljac *et al.*, “Neuroimaging biomarkers in schizophrenia,” *American Journal of Psychiatry*, vol. 178, pp. 509–521, 2021.
- [48] Python Software Foundation, “Python programming language.” <https://www.python.org/>.
- [49] Microsoft, “Visual studio code.” <https://code.visualstudio.com/>.
- [50] Project Jupyter, “Project jupyter.” <https://jupyter.org/>.
- [51] Neo4j, Inc., “Neo4j graph database platform.” <https://neo4j.com/>.
- [52] Pandas Development Team, “Pandas.” <https://pandas.pydata.org/>.
- [53] NumPy Developers, “Numpy.” <https://numpy.org/>.
- [54] scikit-learn developers, “scikit-learn.” <https://scikit-learn.org/>.
- [55] xgboost developers, “Xgboost.” <https://xgboost.readthedocs.io/>.
- [56] Hugging Face, “Transformers.” <https://huggingface.co/docs/transformers/>.

-
- [57] Streamlit, “Streamlit.” <https://streamlit.io/>.
- [58] Laboria, “Salario promedio de un ingeniero de datos en españa.” <https://laboria.app/salario/ingeniero-datos/junior/>.
- [59] Consejo General de Colegios Oficiales de Médicos, *Código de Deontología Médica: Guía de Ética Médica*. Madrid: Organización Médica Colegial de España, 2022.
- [60] World Medical Association, *Declaración de Helsinki de la Asociación Médica Mundial: Principios éticos para las investigaciones médicas en seres humanos*. Ferney-Voltaire, Francia: World Medical Association, 2017.
- [61] C. Barros, C. A. Silva, and A. P. Pinheiro, “Advanced eeg-based learning approaches to predict schizophrenia: promises and pitfalls,” *Artificial Intelligence in Medicine*, vol. 114, p. 102039, 2021.
- [62] L. Del Fabro *et al.*, “Machine learning methods to predict outcomes of pharmacological treatment in psychosis,” *Translational Psychiatry*, vol. 13, p. 75, 2023.
- [63] M. S. Keshavan *et al.*, “Neuroimaging in schizophrenia,” *Neuroimaging Clinics*, vol. 30, pp. 73–83, 2020.
- [64] J. Qi and J. Tejedor, “Deep multi-view representation learning for multi-modal features of the schizophrenia and schizo-affective disorder,” *Proceedings of the Machine Learning in Signal Processing (MLSP)*, 2015.
- [65] ICD10Data, “Convert ICD-9-CM to ICD-10-CM Codes.” <https://www.icd10data.com/Convert>, 2024.
- [66] AAPC, “ICD-10 Codes Lookup and Converter.” <https://www.aapc.com/icd-10/codes/>, 2024.

Apéndice A

Anexos




Figura A.1: Cronograma del Proyecto - Diagrama de Gantt